

中图分类号:

学校代号: XXX

UDC:

密级:

学 号: xxx

XXX 大学硕士学位论文

(工程硕士)

面向立体仓库堆叠货物盘点的改进实例分割与 模型压缩方法研究

XXX

指导教师姓名、职称:

xxx

学科(专业)或领域名称:

计算机技术

学 生 所 属 学 院:

xxx

答 辩 委 员 会 主 席:

xxx

论 文 答 辩 日 期:

xxx

A Dissertation Submitted to XXX University
in Partial Fulfillment of the Requirement
for the Degree of Master of Engineering Science

Research on Improved Instance Segmentation and
Model Compression for Inventory Counting of Stacked
Goods in Automated Warehouses

Candidate: XXX

Supervisor: XXX

May 25, 2026
School of XXX
XXX University

学位论文独创性声明

本人郑重声明：所呈交的学位论文是我个人在导师的指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明，并表示了谢意。本人依法享有和承担由此论文所产生的权利和责任。

论文作者签名： 日期：

学位论文版权使用授权声明

本学位论文作者完全了解学校有关保存、使用学位论文的规定：“研究生在广东工业大学学习和工作期间参与广东工业大学研究项目或承担广东工业大学安排的任务所完成的发明创造及其他技术成果，除另有协议外，归广东工业大学享有或特有”。同意授权广东工业大学保留并向国家有关部门或机构送交该论文的印刷本和电子版本，允许该论文被查阅和借阅。同意授权广东工业大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印、扫描或数字化等其他复制手段保存和汇编本学位论文。保密论文在解密后遵守此规定。

论文作者签名： 日期：

指导教师签名： 日期：

摘要

随着现代物流与智能仓储技术的发展，立体仓库库存盘点对自动化、智能化和实时性提出了更高要求。针对传统人工盘点效率低、成本高，且在复杂堆叠场景下易出现漏盘与错盘的问题，本文面向立体仓库堆叠货物盘点任务，围绕复杂场景识别、数量推理与部署适配开展研究，主要包括改进实例分割模型、既有后处理数量估计流程的任务适配以及模型压缩与部署可行性分析三个方面。

针对货物遮挡明显、结构关系复杂以及现有实例分割模型易出现漏检与误检的问题，本文以 YOLO11s-Seg 为基线，提出改进模型 YOLO11-StackLite。该模型从注意力建模、下采样效率和空间结构表达三个方面进行优化，设计了通道拆分注意力模块 C2SASA、重排分组卷积模块 SSConv 和具有四向卷积结构的 C3k2_QDConv 模块，以增强复杂堆叠场景下的检测与分割能力。

针对仅依赖检测结果难以准确完成库存数量推断的问题，本文承接前期研究中的面积比后处理计数思路，完成其与改进实例分割模型输出的适配与集成。该部分工作的重点在于验证既有计数流程在本文模型输出条件下的适用性，而非重新提出新的计数理论。相关流程通过顶层满载检测和基于掩膜关键点的层间面积比估计，实现对堆叠货物层次结构的判别与数量推理；当仅检测到下层目标、视觉证据不足以支撑可靠推理时，则返回不可判定状态并交由系统复核。

考虑到仓储现场通常具有边缘部署需求，而高精度实例分割模型存在参数量较大、计算复杂度较高的问题，本文进一步开展了面向边缘部署需求的模型压缩研究。针对 YOLO11-StackLite，构建了由稀疏约束训练、结构化物理剪枝、保留通道权重迁移、剪枝后微调恢复以及蒸馏增强组成的轻量化方案，并从模型复杂度与任务指标两方面对其部署可行性进行分析。

在基于文献^[1]中的 Tobacco Cargo Stacking Dataset (TCSD) 并经本文整理后得到的 794 张有效图像上开展的实验结果表明：YOLO11-StackLite 在全量验证集上的平均 DA 和平均 CA 分别达到 95.88% 和 94.87%，在仅保留顶层未满载有效计数图像的困难场景中，平均 CA 和平均 DA 分别达到 80.90% 和 83.49%，整体结果优于主要对比模型；在压缩实验中，物理剪枝模型参数量由 9.4 M 降至 7.8 M，GFLOPs 由 34.9 降至 29.1，经微调恢复后平均 DA 和平均 CA 分别达到 94.82% 和 93.88%，经蒸馏增强后进一步达到

95.10% 和 94.02%。相关结果表明，本文方法在当前数据集与实验设置下表现出较好的任务适配性，并在模型复杂度与任务性能之间取得了较好的平衡，可为后续边缘设备上的实机部署验证提供实验依据。

关键词：立体仓库；堆叠货物盘点；实例分割；模型压缩

ABSTRACT

With the rapid development of modern logistics and intelligent warehousing, higher requirements are being placed on the automation, intelligence, and real-time performance of inventory counting in automated warehouses. Traditional manual inventory counting suffers from low efficiency, high labor cost, and poor reliability in complex stacked scenes. To address these problems, this thesis focuses on the inventory counting task of stacked goods in automated warehouses and studies methods for complex-scene recognition, quantity reasoning, and deployment-oriented adaptation. The main work includes an improved instance segmentation model, integration of a post-processing quantity estimation workflow, and model compression with deployment-feasibility analysis.

To address severe occlusion, complex structural relationships, and frequent missed or false detections in stacked cargo scenes, an improved instance segmentation model named YOLO11-StackLite is proposed based on YOLO11s-Seg. The proposed model is optimized from three aspects, namely attention modeling, downsampling efficiency, and spatial structure representation. Specifically, a channel-splitting attention module C2SASA, a shuffle-split convolution module SSConv, and a quad-direction convolution based module C3k2_QDConv are designed to enhance the detection and segmentation performance in complex stacked scenes.

Since it is difficult to accurately infer the total quantity of goods only from detection results, a prior area-ratio-based post-processing counting scheme is integrated with the proposed instance segmentation model. This workflow includes top-layer full-load detection and an interlayer area-ratio estimation algorithm driven by mask keypoints, which enable structural reasoning and quantity estimation for stacked goods and improve both the interpretability and accuracy of inventory counting.

Considering the demand for edge deployment in warehouse environments and the relatively high parameter scale and computational complexity of high-accuracy instance segmentation models, model compression is further studied for YOLO11-StackLite, and its deployment feasibility is analyzed from the perspective of model complexity and task performance. A lightweight pipeline composed of sparse-constrained training, structured phys-

ical pruning, preserved-channel weight transfer, post-pruning fine-tuning, and distillation enhancement is constructed. Specifically, BN scaling factors are regularized to enlarge channel-importance differences, structured physical pruning is applied to key modules such as C2SASA, C3k2_QDConv, and SSConv under module-aware constraints, and the retained weights are transferred to the compact model. Soft-target distillation and ReviewKD-inspired multi-layer feature distillation are then introduced to compensate for the performance degradation caused by compression, thereby improving the deployment adaptability of the model.

Experiments conducted on 794 valid images organized from the Tobacco Cargo Stacking Dataset (TCSD) in^[1] show that YOLO11-StackLite achieves an average DA of 95.88% and an average CA of 94.87% on the full validation set. On the more challenging subset containing only effective counting images with a non-full top layer, the average CA and DA reach 80.90% and 83.49%, respectively, and the overall results remain better than those of the main comparison models. In the compression experiment, the physically pruned model reduces the parameter count from 9.4 M to 7.8 M and GFLOPs from 34.9 to 29.1; after fine-tuning, the compact model reaches an average DA of 94.82% and an average CA of 93.88%, and after further distillation enhancement, these values improve to 95.10% and 94.02%, respectively. These results indicate that the proposed method is effective under the current dataset and experimental setting, shows good task suitability, achieves a reasonable balance between complexity and task performance, and can provide experimental evidence for subsequent real-device deployment evaluation.

Key words: automated warehouse; stacked goods inventory counting; instance segmentation; model compression

3.2.3 面向专用模块的通道重要性评估与剪枝率设定	37
3.2.4 剪枝流程设计	40
3.3 基于知识蒸馏的精度恢复方法	41
3.3.1 知识蒸馏原理	41
3.3.2 教师模型与学生模型构建	42
3.3.3 蒸馏信息选择与约束方式	42
3.3.4 蒸馏损失设计	43
3.4 压缩模型构建与训练流程	43
3.5 本章小结	44
第四章 实验与结果分析	46
4.1 实验数据集	46
4.2 评价指标	47
4.3 实验环境与参数设置	48
4.4 结果与分析	49
4.4.1 消融实验	49
4.4.2 不同实例分割模型性能对比	52
4.4.3 数量计算评估	53
4.4.4 计数误差来源分析	57
4.4.5 模型压缩实验	59
4.4.6 压缩结果分析	62
4.4.7 边缘部署可行性分析	63
4.5 本章小结	64
第五章 结论与展望	65
参考文献	68
攻读学位期间取得与学位论文相关的成果	75
致谢	76

CONTENTS

ABSTRACT(IN CHINESE).....	I
ABSTRACT(IN ENGLISH).....	III
CONTENTS(IN CHINESE).....	V
CONTENTS(IN ENGLISH).....	VI
Chapter 1 Introduction.....	1
1.1 Background and significance of research	1
1.2 Analysis of the research status at home and abroad.....	3
1.2.1	3
1.2.2	5
1.2.3	6
1.2.4	8
1.3 Main research content and organizational structure of this article	9
1.3.1	9
1.3.2	11
1.4 Summary	12
Chapter 2 Method for Stacked Cargo Inventory Based on Improved YOLO11s-Seg	14
2.1 Stacked Cargo Detection and Segmentation.....	14
2.1.1	14
2.1.2	16
2.2 Post-processing Counting Method.....	24
2.2.1	25
2.3 Summary	31
Chapter 3 Model Compression Method of YOLO11-StackLite for Edge Deployment	33
3.1 Analysis of Model Compression Requirements.....	34
3.2 Lightweight Method Based on Structured Channel Pruning	35
3.2.1 Principle of Network Slimming Based Structured Pruning.....	35
3.2.2 Selection of Pruning Targets in YOLO11-StackLite	36

3.2.3 Channel Importance Evaluation and Pruning Ratio Setting for Customized Modules.....	37
3.2.4 Pruning Process Design	40
3.3 Accuracy Recovery Method Based on Knowledge Distillation.....	41
3.3.1 Principle of Knowledge Distillation.....	41
3.3.2 Construction of Teacher and Student Models	42
3.3.3 Selection of Distillation Information and Constraint Strategy.....	42
3.3.4 Design of Distillation Loss	43
3.4 Construction and Training Process of the Compressed Model.....	43
3.5 Summary	44
Chapter 4 Experiments and Results	46
4.1 Dataset	46
4.2 Evaluation Metrics	47
4.3 Experimental Environment and Settings	48
4.4 Results and Discussion	49
4.4.1 Ablation Study	49
4.4.2 Comparison of Different Instance Segmentation Models.....	52
4.4.3 Counting Performance Evaluation	53
4.4.4 Error Analysis of Counting Results	57
4.4.5 Model Compression Experiments.....	59
4.4.6 Analysis of Compression Results	62
4.4.7 Feasibility Analysis for Edge Deployment	63
4.5 Summary	64
Chapter 5 Conclusion and prospect	65
References	68
Publication and patents during study.....	75
Acknowledgements	76

第一章 绪论

1.1 本课题研究背景及研究意义

随着电子商务、现代物流以及智能制造技术的快速发展，仓储系统在现代供应链中的作用日益突出。库存管理作为仓储作业中的基础环节，直接影响企业的出入库效率、库存准确性以及整体运营成本。自动化立体仓库（Automatic Storage and Retrieval System, AS/RS）因具有空间利用率高、作业效率高和自动化程度高等优势，已逐步广泛应用于烟草、医药、汽车零部件等多个行业^[2]。尤其在烟草仓储场景中，货物通常呈规则化堆叠存放，库存信息更新频繁，这对盘点工作的准确性、时效性和自动化水平提出了更高要求。

然而，传统库存盘点方法主要依赖人工完成，不仅劳动强度大、效率较低，而且在货物数量较多、堆叠结构复杂或作业环境受限的情况下，极易出现漏盘、错盘等问题。相较之下，精准、高效且自动化的库存盘点技术能够显著降低人工成本，提高盘点效率，并为后续仓储调度、库存预测和资源配置提供可靠的数据支撑。因此，研究适用于立体仓库场景的智能盘点方法，具有重要的现实意义和应用价值。

目前，仓储盘点领域主要存在以下几类技术路径。第一类方法基于 RFID（射频识别）技术。该方法能够实现快速批量识别，并具有较强的耐用性和较好的自动化水平^[3-4]。然而，其实施过程通常需要为货物配置电子标签，系统建设与后期维护成本较高，尤其在高吞吐量、大规模仓储场景中，这一成本问题更加突出，从而限制了其广泛应用。第二类方法主要采用 UAV（无人机）或 AGV（自动导引车）结合条码、二维码等识别码完成盘点作业^[5-7]。与 RFID 方法相比，此类方案在一定程度上降低了硬件成本，但仍需依赖外部标识介质，且在仓储现场运行过程中容易受到设备协同、视角变化和识别条件限制的影响，难以充分满足复杂场景下的自动化盘点需求。除上述两类方法外，部分仓储系统还尝试采用基于视觉或重量等传感器的辅助测量方式，例如通过比较货物在存储前后的图像或重量变化实现状态监测。当变化量超过预设阈值时，再由工作人员进行进一步确认和处理。该类方法在某些特定场景下具有一定实用性，但其对环境噪声、传感器精度以及现场工况变化较为敏感，系统稳定性有限，且仍然难以完全摆脱人工干预。

随着计算机视觉和深度学习技术的迅速发展，利用视觉感知方法实现库存盘点已

成为智能仓储研究的重要方向^[6,8]。从计算机视觉角度来看,库存盘点任务可视为对仓库场景图像中的目标进行检测、分割以及数量统计的综合问题。相较于依赖标签或外部传感器的方法,视觉方法能够直接基于现场图像完成信息提取,具有更好的灵活性、较低的系统改造成本以及更强的场景适应性。对于立体仓库而言,现有监控系统已能够持续采集高分辨率图像,这为基于视觉的智能盘点提供了良好的数据基础。

在实际应用中,仓库管理系统通常要求盘点任务具备较高的实时性。如果将前端采集到的大量高清图像全部传输至远程云端进行处理,不仅会占用较大网络带宽,还可能影响物流系统中其他关键指令的正常传输。基于这一考虑,将图像处理任务部署在仓库现场的边缘服务器上是一种更具可行性的方案。边缘服务器能够在本地完成图像识别与数量估计,仅将最终识别结果传输至仓库管理系统,从而有效降低网络压力并提升系统响应效率。

然而,边缘部署环境中的计算资源通常较为有限,这使得高精度识别模型的大规模参数量与边缘部署轻量化需求之间形成明显矛盾。一方面,复杂堆叠场景中的遮挡、重叠、纹理相似和层次结构差异,使得普通检测模型容易出现漏检与误检,从而影响后续计数结果。另一方面,即便采用高精度深度学习模型,也往往面临参数规模大、计算量高、推理延迟较长等问题,难以直接满足边缘部署条件。此外,堆叠货物盘点任务并非单纯的目标识别问题,还涉及对上下层结构关系的理解以及基于结构规则的数量推理,这进一步提升了任务难度。

从具体任务属性看,立体仓库中的堆叠货物盘点与普通货架商品识别或一般工业视觉检测任务并不相同。首先,堆叠货物在图像中往往呈现出高度重复的纹理与外观特征,不同箱体之间的类别差异较小,模型更容易受到局部相似背景或邻近目标的干扰。其次,堆叠结构导致箱体之间普遍存在遮挡与重叠,上层箱体与下层箱体之间的可见区域分布不均,使得边界识别和实例分离难度明显增加。再次,盘点任务不仅要求识别图像中“是否存在箱体”,还要求进一步判断箱体在堆叠结构中的层次位置,并据此完成数量估计。因此,该任务兼具检测、分割和结构推理等多重属性,对模型的精度、稳定性和可解释性均提出了更高要求。

进一步而言,库存盘点系统的工程目标也决定了该类任务不能仅以视觉识别精度作为唯一评价标准。在实际仓储应用中,模型输出不仅要能够区分顶层与非顶层箱体,

还要能够与后处理规则协同工作，将视觉结果可靠地转化为库存数量信息。如果视觉模型在局部边界提取、遮挡目标识别或层次关系判别方面存在偏差，则后续数量推理过程会放大这类误差，从而影响最终盘点结果。与此同时，仓储系统部署环境通常要求算法具备较好的资源适应性，因此仅追求高精度而忽略复杂度控制，也难以满足应用需求。由此可见，堆叠货物盘点任务本质上需要在识别精度、计数可靠性和部署效率之间寻求平衡。

因此，如何在复杂堆叠场景下构建一种既具有较高检测与分割精度、又能够满足边缘部署轻量化需求，并进一步支持货物数量准确推断的智能盘点方法，成为当前立体仓库视觉盘点领域亟待解决的关键问题。围绕这一问题展开研究，不仅能够提升立体仓库盘点效率与库存管理水平，也能够为视觉感知在智能仓储中的落地应用提供新的理论支持和技术路径。

1.2 国内外相关研究现状

围绕立体仓库堆叠货物盘点任务，本文的研究内容主要涉及目标检测与实例分割、对象计数、模型压缩等方向。相关研究的发展为本文方法设计提供了重要参考，但现有方法在复杂堆叠场景适应性、结构化计数能力以及边缘部署效率等方面仍存在不足。下面从这几个方面对国内外相关研究现状进行分析。

1.2.1 目标检测与实例分割

堆叠货物数量统计的前提是对货物目标进行准确定位和轮廓提取，因此目标检测与实例分割是实现自动盘点的基础技术。目标检测作为计算机视觉领域的重要研究问题，主要包含目标定位与类别识别两个任务。实例分割则是在目标检测基础上的进一步扩展，不仅要求识别目标类别和位置，还需要输出每个实例的像素级掩膜，从而为后续结构分析与数量估计提供更精细的几何信息。

现有目标检测方法大致可分为两阶段方法、一阶段方法以及基于 Transformer 的方法。两阶段检测方法以 R-CNN、Fast R-CNN 和 Faster R-CNN 为代表，其核心思想是先生成候选区域，再完成分类与边界框回归。这类方法通常具有较高的检测精度，但由于处理流程较长，模型结构相对复杂，推理效率往往受到限制。一阶段目标检测方法如 SSD、RetinaNet 和 YOLO 系列，则通过单次前向传播直接完成目标定位与分类，具有结构简洁、推理速度快等优势，因而更适用于实时检测任务和边缘部署场景。

从技术路线演进过程看，两阶段检测方法的优势主要在于候选区域机制能够为后续分类与定位提供更细粒度的特征支撑，因此在复杂场景中常能获得较高精度。然而，对于实时性要求较高的仓储盘点任务而言，两阶段方法较长的推理链条和较高的计算成本会限制其实际应用价值。一阶段方法则通过统一检测流程简化了推理过程，在保持较好精度的同时显著提升了速度，因此在工业视觉和边缘部署场景中具有更强的实用性。尤其是 YOLO 系列模型，在多代迭代中不断兼顾精度、速度和模型复杂度，已经成为轻量化视觉任务中的重要基础框架。以 YOLOv1、YOLO9000 和 YOLOv3 为代表的早期 YOLO 方法奠定了实时检测框架基础^[9-11]；此后，EfficientDet 通过复合缩放与双向特征融合实现了较好的精度与效率平衡，YOLOX 和 YOLOv7 分别从解耦检测头、标签分配和训练策略等方面进一步增强了一阶段检测器的综合性能，RT-DETR 则在保持端到端检测优势的同时改善了实时性表现^[12-15]。

近年来，基于 Transformer 的目标检测方法受到了广泛关注。DETR 通过端到端学习框架避免了传统候选框生成和复杂后处理过程^[16]，但其在训练收敛速度和小目标检测性能方面仍存在不足。为解决这些问题，研究者提出了 Deformable DETR、DAB-DETR、DINO 等一系列改进方法^[17-19]，这些方法在训练效率和检测性能方面均取得了不同程度提升。但总体来看，基于 Transformer 的检测方法通常模型规模较大、训练成本较高，在边缘计算资源受限的场景中仍面临部署挑战。

基于 Transformer 的方法在全局关系建模方面具有天然优势，对于存在复杂上下文依赖的视觉任务具有较强表达能力。然而，在立体仓库堆叠货物场景中，虽然全局建模有助于理解目标间的空间关系，但模型复杂度偏高、训练资源需求较大等问题仍限制了其在边缘应用中的可行性。换言之，Transformer 检测方法在理论能力上具有吸引力，但若缺乏针对性轻量化设计，其在本文所关注的资源受限应用场景中并不一定具有优势。

对于实例分割任务，Mask R-CNN 是具有代表性的经典方法之一，其通过在检测分支之外增加掩膜分支，实现了较高质量的实例级分割^[20]。在此基础上，FCIS 通过位置敏感打分图实现了更早期的全卷积分割框架，PANet 则通过路径聚合增强了多尺度特征传递能力^[21-22]。随后，YOLACT、SOLO、SOLOv2、BlendMask、CenterMask、CondInst、PointRend、BoxInst、QueryInst、SparseInst、Mask2Former 以及 YOLO 系列

实例分割模型等方法^[23-34]，分别从单阶段推理、动态卷积、掩膜细化、弱监督掩膜学习、稀疏表示和全局特征建模等角度推动了实例分割技术的发展。总体而言，单阶段实例分割方法在推理效率方面更具优势，而基于 Transformer 的分割方法在全局建模能力和掩膜表达能力方面表现更强，但其模型复杂度和部署成本也相对较高。

对于本文任务而言，实例分割方法的选取还需考虑一个关键问题，即掩膜结果是否能够为后续数量推理提供可靠的几何基础。相比仅输出目标边界框的检测方法，实例分割能够提供更精细的轮廓信息，使模型在处理堆叠边界、局部遮挡和结构分层时具有更强的表达能力。这也是本文选择实例分割作为主要技术路线的重要原因。但与此同时，并非所有实例分割方法都同样适合堆叠货物盘点任务。对于模型结构复杂、推理开销较大的方法，即便其具备较强的掩膜表达能力，也可能难以满足边缘部署场景的实际需求；而对于过度轻量化但结构建模能力不足的方法，则又可能在复杂堆叠场景下产生较多漏检与误检。

对于立体仓库堆叠货物盘点任务而言，方法不仅需要具备良好的目标定位与轮廓分割能力，还需要兼顾边缘部署条件下的推理效率与计算资源约束。因此，选择具有轻量化潜力的实例分割框架作为基线，并在此基础上开展针对复杂堆叠场景的结构改进，具有较强的现实必要性。

进一步总结可知，目标检测与实例分割技术的发展为仓储视觉盘点提供了良好的方法基础，但现有方法大多面向通用场景设计，尚未充分考虑堆叠货物盘点任务中“轮廓识别 - 层次区分 - 数量推理 - 资源受限部署”这一完整链条。如何在轻量化框架内增强模型对复杂堆叠结构的感知能力，仍是值得深入研究的问题。

1.2.2 对象计数

对象计数是计算机视觉中的重要研究方向，常见方法大致可分为基于回归的方法、基于密度图的方法和基于检测的方法。基于回归的方法通常通过建立图像特征与目标数量之间的直接映射关系完成计数，其实现形式较为直接，但往往缺乏良好的可解释性^[35]。基于密度图的方法常用于高密度场景，其基本思路是先预测目标密度分布，再通过积分或累加得到总数量^[36-37]。在该路线中，MCNN 通过多列卷积结构适应尺度变化，CSRNet 通过空洞卷积提升了感受野与密集区域建模能力，Bayesian Loss 方法进一步改善了稀疏标注条件下的计数监督形式^[38-40]。该类方法在目标密集分布场景中具有

一定优势，但对于目标的层次结构和个体边界表达相对不足。基于检测和分割的方法则通过识别单个目标实例实现数量统计，具有较强的可解释性，但其性能高度依赖于检测与分割结果的准确性^[35,41]。

从应用特点看，回归法更适合只关注总数量、而不强调目标位置与个体结构的任务；密度图方法在高密度、强遮挡场景下具有较好的适应能力，常用于人群计数、车辆计数等任务；检测和分割法则更适用于目标边界较清晰、且需要保留个体级解释信息的场景。对于库存盘点任务而言，后两者显然更具应用潜力，因为仓储管理系统通常不仅需要知道“有多少个箱体”，还需要知道“哪些目标被识别出来了”以及“这些目标在结构上属于哪一层”，这决定了单纯回归方法在本文任务中很难满足需求。

立体仓库中的堆叠货物计数任务与一般对象计数任务存在明显差异。该任务不仅要求估计目标总数量，还涉及上下层结构关系判别以及基于堆叠规则的数量推理。对于此类场景，单纯依赖回归方法或密度图方法难以充分利用空间结构信息，而传统基于检测的方法在面对堆叠遮挡和层次关系时又存在明显不足。因此，面向堆叠货物盘点任务，仍有必要结合实例分割结果设计更具结构感知能力的后处理计数方法，以提升数量推断的准确性和可解释性。

进一步来看，堆叠货物计数任务的特殊性还体现在其结果生成方式并非直接由视觉模型端到端输出，而是往往需要结合仓储规则进行后处理推理。例如，当前层是否满载、上层与下层目标之间的几何关系如何、是否存在空货物或不可判定状态等，都会直接影响最终数量估计结果。这意味着，对本文任务而言，更合理的研究思路不是单独追求“计数网络”的性能，而是在稳定实例分割结果的基础上，构建与实际堆叠规则相匹配的数量推理方法。Hu 等针对堆叠货物智能盘点提出了基于面积比的箱体计数算法，通过实例分割结果中的 `up_box/down_box` 标注、顶层满载判别以及凸包面积比估计实现数量推断^[1]。这一研究为本文后续将实例分割结果转化为库存数量信息提供了直接的方法基础。这样的设计更符合仓储盘点的实际业务流程，也更有利于提升系统可解释性。

1.2.3 模型剪枝与模型蒸馏

随着深度神经网络模型规模不断增加，模型压缩逐渐成为边缘智能领域的重要研究方向^[42-43]。其中，模型剪枝是最常见的压缩技术之一，主要包括非结构化剪枝和结

构化剪枝两类。非结构化剪枝通常根据参数重要性删除部分连接或权重，可以显著降低参数冗余^[44]，但由于生成的稀疏结构不规则，实际硬件加速效果往往有限。结构化剪枝则通过删除整个通道、卷积核或模块来降低模型复杂度，其输出结构更加规整，更有利于在实际部署中获得真实的推理加速收益^[45-46]。围绕结构化压缩，Network Slimming 利用 BN 缩放因子学习通道稀疏性，FPGM 从几何中值角度识别冗余滤波器，HRank 基于特征图秩评估结构重要性，DMCP 将动态掩码与可微搜索结合，LFPC 和 CURL 则进一步关注跨层依赖与统一压缩策略^[47-52]。

在结构化剪枝研究中，常见策略包括组级剪枝、滤波器剪枝和通道剪枝等。相关研究通常根据权重范数、激活值、能耗贡献或特征重要性等指标评估不同结构单元的重要程度，并据此执行剪枝操作^[45-46]。对于检测与分割任务而言，剪枝方法不仅要考虑单层冗余，还要兼顾特征金字塔、多分支融合与检测头耦合关系，因此近年来越来越多工作强调“可部署性”和“结构一致性”而非单纯追求极限压缩率^[47,50,52]。总体来看，结构化剪枝在实际部署友好性方面相较非结构化剪枝更具优势，因此更适合作为边缘部署模型压缩的重要手段。

知识蒸馏的核心思想是利用性能较强的教师模型指导轻量化学生模型训练，以实现“以大带小”的知识迁移^[43]。现有蒸馏方法包括基于输出响应的蒸馏、基于中间特征的蒸馏以及基于关系约束的蒸馏等。FitNets 通过中间层提示实现深层学生网络训练，Attention Transfer 强调教师与学生在注意力分布上的一致性，ReviewKD 从多阶段特征回顾角度增强了知识传递效果^[53-55]。在目标检测场景中，DEFeat、GID、FGD、DKD 和 LD 等方法分别从前景背景解耦、全局蒸馏、焦点区域知识传递、解耦类别蒸馏以及定位蒸馏等角度改进了蒸馏机制^[56-60]。大量研究表明，知识蒸馏能够在一定程度上弥补轻量化模型在压缩过程中的性能下降问题，因此常与模型剪枝配合使用，以在模型复杂度和性能之间取得更优平衡。

对于边缘部署任务而言，模型压缩研究的意义并不仅在于减小参数规模，更重要的是在可接受的性能损失范围内获得更高的部署可行性。若仅追求压缩率最大化，而忽略模型在实际任务中的精度保持能力，则压缩结果往往难以真正落地。特别是在本文所关注的实例分割与库存盘点联合任务中，模型输出需要同时服务于目标识别和数量推理两个环节，因此压缩方法的评价标准也应当更加综合。结构化剪枝可以从模型

结构层面直接降低复杂度，而知识蒸馏则能够为压缩模型提供性能补偿，两者结合更适合作为兼顾复杂度和任务性能的研究路线。

此外，现有模型压缩研究多集中于通用分类或目标检测任务，而针对实例分割与后处理计数联合任务的压缩研究相对较少。实例分割模型通常具有更复杂的特征融合与掩膜预测结构，一旦压缩不当，更容易影响轮廓完整性和结构判别能力，进而影响下游数量估计结果。因此，在堆叠货物盘点场景中，模型压缩不能仅从通用检测精度角度评价，还应关注压缩后模型是否仍能稳定支撑盘点任务。围绕这一问题展开研究，既能够提升模型轻量化的针对性，也为本文第 3 章的压缩方案设计提供了研究依据。

综上，模型剪枝与知识蒸馏为深度模型在边缘部署场景中的压缩与加速提供了有效技术路径。其中，结构化剪枝更有利于实际部署过程中的推理加速，而知识蒸馏能够在一定程度上缓解压缩过程带来的性能退化。然而，针对堆叠货物盘点任务，如何在保持检测、分割与计数性能的前提下进一步降低模型复杂度，仍需开展针对性的研究。

1.2.4 研究现状总结与现存问题

综合上述研究现状可以看出，目标检测与实例分割、对象计数以及模型压缩等方向的发展为立体仓库盘点任务提供了较好的方法基础，但现有研究仍难以直接满足本文所关注的“复杂堆叠场景识别与计数 + 资源受限部署”这一联合任务需求。归纳起来，主要存在以下三个方面的问题。

(1) 现有实例分割方法大多面向通用自然图像场景设计，针对立体仓库中堆叠遮挡、纹理重复、边界粘连和层次结构明显等特点的专门优化仍显不足。对于本文任务而言，模型不仅要识别箱体轮廓，还需要稳定区分顶层与非顶层目标，并尽量减少复杂背景与邻近结构带来的干扰。若缺乏面向堆叠场景的针对性结构设计，即使通用分割指标较高，也可能难以稳定支撑后续盘点流程。

(2) 现有仓储盘点视觉研究中，能够同时兼顾“实例分割结果获取 - 结构规则计数 - 工程系统衔接”的完整闭环方案相对较少。特别是在规则堆叠场景下，分割结果并不是最终目标，而是后续满载判别、面积比估计和库存数量推理的前置输入。若仅孤立评价视觉模型精度，而缺乏对其是否能够稳定支撑计数流程的分析，则难以充分体现方法对实际盘点任务的贡献。

(3) 现有模型压缩研究多面向通用分类或检测任务展开，对实例分割与后处理计数联合任务中的误差传递问题关注不足。对于本文任务而言，压缩带来的性能退化不仅会体现在 box/mask mAP 上，还可能进一步影响顶层目标识别、掩膜轮廓完整性和层次判别结果，从而放大后续数量推理误差。因此，压缩方案不能仅以参数量和计算量下降为目标，还需要同时关注其对盘点相关指标的影响。

基于上述分析，本文将研究重点聚焦于以下三个方面：一是围绕复杂堆叠货物场景，对 YOLO11s-Seg 进行面向任务特征的针对性结构改进；二是将改进后的实例分割结果与既有面积比后处理流程进行有效适配，使视觉感知结果能够稳定转化为库存数量信息；三是在保证实例分割与盘点相关性能尽量稳定的前提下，研究面向部署需求的压缩路线。上述问题归纳也共同构成了本文后续方法设计与实验验证的直接出发点。

1.3 本文主要研究内容与组织结构

1.3.1 本文主要研究内容

针对立体仓库堆叠货物盘点任务中存在的遮挡严重、目标外观相似、层次结构复杂以及边缘部署资源受限等问题，本文围绕“复杂堆叠场景下的高精度识别与计数”和“面向现场应用的模型轻量化与部署适配”两条主线展开研究。研究目标并非单纯提升某一项通用视觉指标，而是在保证实例分割精度的基础上，提升数量推理的可靠性与模型部署的可行性，以形成面向实际仓储盘点业务的较完整技术方案。

本文的第一项研究内容是面向复杂堆叠场景的实例分割模型改进与后处理计数流程集成。针对现有通用实例分割模型在堆叠货物场景中易出现漏检、误检、边界分离不清以及结构信息利用不足等问题，本文以 YOLO11s-Seg 为基础模型，结合堆叠货物纹理重复、接触边缘明显和层间关系突出的特点，对网络结构进行针对性改进，提出 YOLO11-StackLite 模型。具体而言，本文在 Backbone 高层特征中引入 C2SASA 模块以增强关键区域建模与有效通道筛选，在 Neck 下采样阶段采用 SSConv 模块以降低冗余计算并改善特征重组效率，在核心特征提取模块中引入 C3k2_QDConv 以强化方向性边缘和局部几何轮廓表达。在此基础上，本文承接前期研究中的面积比数量估计思路^[1]，并完成其与改进实例分割输出结果的适配与集成，形成“实例识别 + 规则后处理盘点”的任务方案。需要明确的是，该部分工作的重点在于既有计数流程的任务适配与系统验证，而非重新提出独立的新计数方法。

本文的第二项研究内容是面向边缘部署需求的模型压缩路线设计。考虑到改进后的实例分割模型虽然能够有效提升复杂场景识别能力，但其参数规模和计算开销仍会对现场部署带来压力，本文进一步研究适用于该任务的轻量化方法。具体而言，本文引入基于 Network Slimming 思想的结构化通道剪枝方法，通过 BN 缩放因子对通道重要性进行评估，并结合网络结构特征开展结构化裁剪；同时，为缓解剪枝造成的性能下降，进一步采用软目标蒸馏与 ReviewKD 多阶段特征蒸馏对剪枝后学生模型进行性能恢复。该压缩路线的重点不在于提出全新的通用压缩算法，而在于围绕 YOLO11-StackLite 的结构特点完成压缩、恢复与任务验证，使模型在尽量保持 box/mask mAP、DA 和 CA 等核心指标稳定的前提下，降低模型参数量和计算复杂度，并从任务指标与复杂度变化角度分析其部署可行性，为后续边缘设备上的工程验证提供依据。

上述两项研究内容之间具有清晰的逻辑递进关系。前者重点解决“复杂堆叠场景下如何识别得更准、计数得更稳”的问题，是本文的核心研究内容；后者重点解决“在保持主要任务性能的前提下如何进一步降低模型复杂度”的问题，是面向工程应用需求的拓展研究。二者并非相互独立，而是围绕立体仓库智能盘点这一总体目标展开协同设计，共同构成从视觉感知、结构推理到部署适配的研究框架。

综合全文，本文的主要贡献可概括为以下三个方面。

- (1) 面向立体仓库复杂堆叠货物场景，本文提出改进实例分割模型 YOLO11-StackLite。该模型分别从高层关键区域建模、Neck 下采样特征重组以及方向性几何结构表达三个方面进行结构优化，在保持较低模型复杂度的同时提升了复杂场景下的检测与分割性能。
- (2) 在前期面积比计数研究基础上，本文完成了改进实例分割结果与既有后处理数量估计流程的适配与集成，并对其在本文任务场景中的适用性进行了验证。该部分工作的重点在于将实例分割输出与规则后处理盘点流程有效衔接，使模型结果能够进一步服务于库存数量推断，增强了盘点结果的可解释性与场景适配性；其贡献边界主要体现在任务适配与系统验证层面，而不在于提出全新的计数算法。
- (3) 结合本文模型结构特点与仓储现场部署需求，本文设计了面向边缘部署的压缩路线。该路线以结构化通道剪枝和多阶段知识蒸馏为核心，重点验证压缩后模型在复杂度下降条件下对实例分割与盘点任务性能的保持能力，并从部署适配角度分析压缩模




图 1-1 本文研究内容、创新重点与目标对应关系

Figure 1-1 Correspondence among research challenges, proposed work and target outcomes

型的应用潜力，为后续实机测试与工程验证提供了研究基础。

图 ?? 从“任务难点 - 本文工作 - 结果目标”的角度概括了本文研究内容之间的对应关系。可以看出，本文并非围绕单一视觉指标开展局部优化，而是针对复杂堆叠识别困难、规则盘点集成需求以及边缘部署受限这三个关键问题，分别从模型改进、流程集成与压缩验证三个层面进行设计。

结合图 ?? 可进一步归纳出，本文的创新点主要体现在三个方面：其一，围绕堆叠货物场景的识别难点，对实例分割模型中的关键区域建模、下采样结构和方向性特征提取模块进行了有针对性的改进；其二，围绕盘点任务需求，将前期面积比计数流程与改进实例分割结果进行有效适配和衔接，使视觉感知结果能够进一步转化为库存数量信息。需要说明的是，这一部分的创新性主要体现在任务适配与流程整合，而非计数理论本身；其三，围绕工程应用需求，设计并验证了与模型结构相适配的压缩与蒸馏恢复路线，并从复杂度与任务性能保持的角度分析其部署可行性，从而使本文工作不仅停留在算法性能比较层面，也兼顾了后续部署适配需求。

1.3.2 本文组织结构

为保证论文论述层次清晰、研究逻辑完整，本文按照“问题提出与研究背景分析 - 方法设计与任务实现 - 模型压缩与部署适配 - 实验验证与结果分析 - 总结与展望”的思

路组织全文内容。各章节具体安排如下。

第 1 章为绪论，主要介绍课题研究背景与研究意义，分析目标检测与实例分割、对象计数以及模型剪枝与知识蒸馏等相关领域的国内外研究现状，并在此基础上明确本文的主要研究内容与整体组织结构，为后续章节展开奠定基础。

第 2 章围绕立体仓库堆叠货物盘点任务，介绍面向复杂场景的改进实例分割模型及与之配套的后处理数量估计流程。该章首先分析堆叠货物场景中遮挡、重叠和层次关系带来的识别难点，随后介绍 YOLO11-StackLite 的结构设计思路及关键模块作用，并进一步给出结合实例分割结果与堆叠规则的后处理计数流程，是全文方法设计的核心章节。

第 3 章针对边缘部署条件下模型复杂度受限的问题，研究面向 YOLO11-StackLite 的模型压缩方法。该章主要介绍基于结构化通道剪枝的轻量化策略以及结合软目标蒸馏与多阶段特征蒸馏的性能恢复方法，重点说明压缩对象选择、模块差异化压缩原则及整体压缩流程，为后续模型的工程落地提供方法支撑。

第 4 章为实验与结果分析章节。该章在基于前期研究数据集整理得到的 TCSD 实验数据上对本文所提方法进行验证，分别从实例分割性能、盘点计数性能以及压缩路线的部署可行性等角度展开分析，并通过消融实验、对比实验和误差来源分析验证模型改进方案及后处理流程的有效性，同时对压缩方法在缺少实机测试条件下的解释边界与后续验证重点进行讨论。

第 5 章对全文研究工作进行总结，并对后续可进一步开展的研究方向进行展望。该章在归纳本文主要研究结论的基础上，分析当前方法在更复杂场景适应性、实时部署性能以及多模态信息融合等方面仍有待提升的问题，为后续研究提供思路。

1.4 本章小结

本章首先阐述了立体仓库堆叠货物智能盘点任务的研究背景与工程应用价值，说明了在复杂遮挡、结构相似和部署资源受限条件下开展高精度识别与计数研究的必要性。随后，围绕实例分割、对象计数以及模型剪枝与知识蒸馏三个方面，对国内外相关研究现状进行了系统梳理，并结合堆叠货物盘点任务的特点分析了现有方法在结构建模、数量推理和端侧部署方面仍存在的不足。

在此基础上，本章进一步明确了本文围绕“复杂堆叠场景下的高精度识别与计数”

和“面向现场应用的模型轻量化部署”两条主线展开研究，概述了改进实例分割模型、集成面积比后处理计数流程以及设计压缩路线等主要工作内容，并给出了全文的章节组织结构。上述内容为后续章节的方法设计、压缩方案构建和实验验证奠定了研究背景与问题基础。

第二章 基于改进 YOLO11s-Seg 的立体仓库堆叠货物盘点方法

本章围绕立体仓库堆叠货物盘点任务中的检测、分割与计数问题展开研究。首先分析基线模型 YOLO11s-Seg 的结构特点及其在复杂堆叠场景中的局限；其次在此基础上提出改进模型 YOLO11-StackLite，并对其关键模块进行设计说明；最后结合实例分割结果与空间几何关系，构建后处理数量计算方法，为后续实验验证与模型压缩研究奠定基础。

2.1 堆叠货物检测与分割

2.1.1 传统 YOLO11s-Seg 基础架构

为实现立体仓库中堆叠货物的高效自动盘点，视觉模型不仅需要准确区分堆叠结构中的顶层箱体与非顶层箱体，还需要在边缘部署条件下具备较低的计算开销与较快的推理速度。因此，本文选取兼顾检测效率与实例分割能力的单阶段模型作为研究基础。

基于上述需求，本文选择 Ultralytics 发布的 YOLO11s-Seg 作为基线模型^[34]。该模型在单阶段框架下集成了目标检测与实例分割能力，在检测精度与推理速度之间取得了较好平衡，具备较强的边缘部署适配性。YOLO11s-Seg 的整体结构主要由主干网络（Backbone）、特征融合网络（Neck）和检测头（Head）构成。

选择 YOLO11s-Seg 作为基线模型主要基于以下考虑。首先，与两阶段实例分割模型相比，YOLO11s-Seg 保留了单阶段框架推理流程简洁、实时性较高的优点，更符合仓储盘点任务对推理效率的要求。其次，该模型同时具备目标检测与实例分割能力，能够直接输出边界框与像素级掩膜，为后续基于几何关系的数量推理提供必要输入。再次，YOLO 系列模型在实际工程场景中具有较好的训练与部署生态，便于在统一框架下完成后续结构改进与模型压缩研究。因此，YOLO11s-Seg 既能够作为性能较强的分割基线，也能够为后续轻量化设计保留足够的改进空间。

然而，需要指出的是，适合作为基线并不意味着该模型已经完全满足本文任务需求。立体仓库堆叠货物场景具有遮挡明显、纹理相似、方向结构重复且层次关系复杂等特点，模型除了需要识别目标轮廓，还需要较稳定地区分顶层与非顶层箱体，并为




图 2-1 YOLO11s-Seg 主干与注意力结构示意图

Figure 2-1 Backbone and attention structure of YOLO11s-Seg

后处理数量计算提供可靠输入。若模型在局部边缘恢复、方向性结构建模或关键区域聚焦方面能力不足,则即便总体检测精度较高,也可能在后续盘点环节放大误差。因此,对 YOLO11s-Seg 的结构进行针对性改进是有必要的。

在 YOLO11s-Seg 的 Backbone 与 Neck 中，引入了改进的 C3k2 Fast 模块 (CSP Bottleneck with Two Convolution Layers)，用于增强浅层特征提取与融合能力。该模块基于跨阶段部分结构思想，能够在保持较低计算复杂度的同时提升特征表达能力。在 Backbone 末端，集成轻量级注意力模块 C2PSA，用于增强模型对关键区域的感知能力，其结构如??所示。

C2PSA 采用 Softmax Attention, 其计算公式如下^[61]:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V \quad (2.1)$$

其中, Q 、 K 、 V 分别表示查询、键和值。该注意力机制通过计算不同位置之间的相关性实现全局信息建模, 其时间复杂度为 $O(N^2)$ 。尽管该结构能够增强模型对重要区域的聚焦能力, 但在高分辨率特征图上, 其计算代价仍然较高。此外, 原始注意力机制在复杂堆叠场景中对低相关区域的抑制能力有限, 容易引入冗余信息, 从而影响对关

键结构特征的有效表征。

从本文任务角度看，基线模型的局限主要体现在三个方面。第一，注意力机制虽然增强了全局依赖建模能力，但在堆叠目标边界高度相似的情况下，若缺乏更有针对性的特征筛选，模型仍可能将注意力分配到无效背景或邻近干扰区域。第二，Neck 中标准下采样结构虽然实现简单，但在多次尺度压缩过程中容易造成局部轮廓信息衰减，这会影响箱体边界分离和掩膜完整性。第三，传统 Bottleneck 结构对方向性几何关系的建模能力有限，而堆叠货物场景中恰恰存在大量横竖边界、层间交界与遮挡轮廓，这使得模型在复杂结构下更容易产生漏检和误检。

因此，虽然 YOLO11s-Seg 已具备较好的基础性能，但在复杂堆叠场景下仍存在注意力计算冗余、下采样效率不足以及空间结构建模能力有限等问题，有必要在其基础上进行针对性的结构改进。

2.1.2 本文提出的 YOLO11-StackLite 架构

鉴于仓储盘点系统对识别精度、推理效率与部署资源均具有较高要求，尽管 YOLO11s-Seg 在常规场景下已表现出较好的综合性能，但在复杂堆叠图像中仍可能出现漏检、误检等问题，且其参数规模与计算复杂度在边缘部署场景下仍存在进一步优化空间。为此，本文在 YOLO11s-Seg 的基础上提出改进模型 YOLO11-StackLite，从注意力建模、下采样效率和空间结构表达三个方面对网络进行优化，以提升复杂堆叠场景下的检测与分割性能，并进一步降低模型部署开销。

YOLO11-StackLite 的设计并非对原始网络进行简单模块替换，而是围绕本文任务需求进行针对性重构。具体而言，模型整体设计遵循以下原则：其一，在 Backbone 高层特征中增强对关键区域和有效结构的建模能力，以减弱复杂背景与重复纹理对识别结果的干扰；其二，在 Neck 下采样与特征融合过程中尽量减少信息损失，使模型在压缩尺度时仍能保留对箱体边界和局部细节的敏感性；其三，在核心特征提取模块中引入更适合堆叠场景的方向性结构建模方式，从而强化模型对空间几何关系的感知能力；其四，在性能提升的同时控制模型参数量与计算复杂度，为第 3 章的进一步压缩研究预留空间。

改进后的实例分割网络模型称为 YOLO11-StackLite，其整体结构如??所示。

围绕上述目标，本文设计了 3 个关键改进模块，即通道拆分注意力模块 C2SASA、




图 2-2 YOLO11-StackLite 整体结构

Figure 2-2 Overall structure of YOLO11-StackLite

重排分组卷积模块 SSConv，以及具有四向卷积结构的 C3k2_QDConv 模块。三者分别面向关键区域建模、轻量化下采样和方向性空间特征提取，从不同层面增强模型对堆叠货物场景的适应能力。

从整体关系上看，三个模块并非相互独立的局部优化，而是共同服务于“复杂堆叠场景识别与计数”这一目标。C2SASA 主要作用于高层特征的选择性增强，解决注意力冗余和关键区域聚焦不足的问题；SSConv 主要作用于特征融合阶段，解决下采样过程中的计算冗余与局部信息损失问题；C3k2_QDConv 则着重加强模型对方向性边缘与几何结构的刻画能力，提升在遮挡、重叠和结构相似条件下的识别稳定性。三者的功能上的分工与配合，共同构成了 YOLO11-StackLite 的核心改进路线。

- 1) 通道拆分注意力模块 C2SASA：该模块在继承原始注意力结构优势的基础上，通过通道拆分机制与选择性激活抑制策略，降低注意力计算冗余并增强模型对关键区域的表征能力。
- 2) 重排分组卷积模块 SSConv：该模块面向 Neck 部分的轻量化下采样需求，通过融合通道拆分、分组卷积、逐点卷积与标准卷积分支等设计，在降低计算复杂度的同时提升多尺度特征提取能力。

3) 具有四向卷积的 C3k2_QDConv 模块：该模块通过增强对方向性几何结构的感知能力，改善传统 Bottleneck 在复杂结构建模中的不足，从而提高模型在堆叠场景下的检测与分割性能。

2.1.2.1 本文提出的通道拆分注意力模块 C2SASA

设计动机：在立体仓库堆叠货物图像中，顶层箱体边缘、层间交界区域和局部遮挡轮廓往往淹没在大量重复纹理与相似背景之中。原始 C2PSA 虽然具备一定全局建模能力，但对全部通道统一执行注意力计算容易带来计算冗余，也可能使无关背景区域参与相似度建模，削弱模型对关键箱体区域的聚焦效果。针对这一问题，本文希望在不过度增加复杂度的前提下，突出与顶层箱体识别、层次判别和边界恢复更相关的高层语义特征，因此设计了兼顾通道筛选与选择性增强的 C2SASA 模块。

为同时提升模型对显著区域的建模能力并降低计算开销，本文提出通道拆分式选择性激活抑制注意力模块（C2SASA），用于替换 Backbone 中的 C2PSA 模块。该模块首先通过 1×1 卷积对输入特征进行通道压缩，并将其划分为两条分支：其中一条分支保留残差信息以维持原始特征表达，另一条分支输入改进注意力块进行特征增强，最后通过通道拼接与卷积映射恢复原始维度，实现两类信息的有效融合。

采用通道拆分方式的原因在于，复杂堆叠场景下并非所有通道都需要参与同等强度的注意力计算。若直接对全部特征通道执行全局注意力操作，不仅会增加计算负担，还可能使无关背景信息与低贡献特征一并参与相似度建模，削弱模型对关键区域的聚焦效果。通过在注意力建模前对特征进行拆分，可以将一部分通道保留为稳定的基础语义表达，另一部分通道用于执行更具针对性的注意力增强，从而在减少冗余计算的同时提高有效特征筛选能力。

在改进注意力块中，本文将原始 Attention 替换为 SASA 机制，以实现特征的择性激活与抑制。SASA 模块在保持全局建模能力的同时，引入 L2 归一化与可学习温度参数，从而增强注意力计算过程中的数值稳定性和特征区分能力，其结构如??所示。

这种设计尤其适合本文任务。对于堆叠货物图像而言，模型往往需要从大量相似边缘和重复纹理中识别出真正有助于区分层次结构的区域。若缺乏有效抑制机制，注意力模块可能对多个相似位置赋予接近权重，导致关键特征不够突出。SASA 机制通过归一化和温度调节，使注意力分布更稳定、更具可控性，有助于增强模型对顶层目标、




图 2-3 选择性激活抑制注意力机制 SASA

Figure 2-3 Selective activation suppression attention

交界边缘和局部结构差异的敏感性。

设输入张量为 $x \in \mathbb{R}^{B \times C \times H \times W}$ ，其中 B 为批大小， H 、 W 分别表示输入特征图的高度和宽度， C 为特征维度。首先将空间维度展平并转置为序列形式，其中 $N = H \cdot W$ 。随后采用共享线性投影层一次性生成 q 、 k 、 v ：

$$[q, k, v] = \text{Linear}_{qkv}(X) \quad (2.2)$$

为实现多头注意力，将通道维度 C 重构为 $h \times d$ ，其中 h 为注意力头数， $d = C/h$ 为每个注意力头的嵌入维度。由此得到：

$$q, k, v \rightarrow \mathbb{R}^{B \times h \times N \times d} \quad (2.3)$$

对 q 与 k 进行 L2 归一化：

$$q' = \frac{q}{\|q\|_2}, \quad k' = \frac{k}{\|k\|_2} \quad (2.4)$$

进一步引入可学习温度参数 $\text{Temp} \in \mathbb{R}^{h \times 1 \times 1}$ ，得到相似度矩阵：

$$\text{sim} = \text{Temp} \cdot q' k'^T \quad (2.5)$$

其中， $\mathbf{T}$ 表示转置操作。随后通过 Softmax 与 Dropout 获得注意力权重：

$$\alpha = \text{Dropout}(\text{softmax}(\text{sim})) \quad (2.6)$$

最后对 v 进行加权求和并投影：

$$y = \text{Proj}(\alpha \cdot v) \quad (2.7)$$

最终输出通过 Transpose 与 Reshape 操作恢复到原始空间维度。综上，C2SASA 在保留全局依赖建模能力的基础上，降低了注意力计算的冗余性，并增强了对关键区域的特征区分能力，为复杂堆叠场景下的实例检测与分割提供了更有效的特征表示。

进一步而言，C2SASA 的作用不仅体现在 mAP 指标提升上，还体现在它为后续盘点任务提供了更稳定的高层语义基础。由于后处理数量计算依赖模型较准确地区分上层与非顶层目标，若高层特征中关键区域表达不足，则后续状态判别和数量推理均会受到影响。因此，C2SASA 可以视为从特征选择层面对盘点任务进行的一种前置优化。

2.1.2.2 本文提出的重排分组卷积模块 SSConv

设计动机：堆叠货物盘点任务对掩膜边界连续性和局部结构细节较为敏感，而 Neck 阶段的下采样又是最容易造成细节衰减的环节。若尺度压缩过程中箱体交界边缘、角点或局部可见区域信息被过早削弱，模型便更容易在相邻箱体处产生粘连、漏分和轮廓缺损，进而影响后续满载判别和面积比估计。与此同时，现场部署又要求该部分结构尽量控制复杂度。因此，本文将改进重点放在“降低下采样冗余开销”与“尽量保留对盘点有用的局部结构信息”两方面，并据此设计 SSConv 模块。

在 YOLO11 模型中，Neck 部分通常采用串联的标准卷积进行下采样。虽然该结构实现简单，但存在参数量较大、计算开销较高以及通道信息利用不足等问题，不利于模型在边缘设备上的高效运行。与此同时，标准卷积在下采样过程中对局部细节信息和多尺度语义信息的保留能力有限，容易影响复杂堆叠场景中的特征表达效果。

对于堆叠货物盘点任务而言，下采样阶段的特征损失具有更直接的负面影响。原因在于，箱体边界通常由长直线段和相对规则的角点组成，这些细节信息在尺度压缩过程中若被过度削弱，模型就更容易在相邻箱体交界处出现粘连、漏分或边界不完整等现象。此外，仓储图像中的顶层与非顶层目标往往在局部可见区域上存在差异，若下采样结构不能充分保留这类局部信息，也会影响后续类别区分与数量推理。因此，在




图 2-4 重排分组卷积模块 SSConv

Figure 2-4 Shuffle-split convolution

保证下采样效率的同时尽量减少关键信息损失，是 Neck 结构改进的重点。

针对上述不足，本文提出重排分组卷积模块 SSConv，以实现下采样阶段的轻量化设计与特征增强。该模块融合了通道拆分、分组卷积、逐点卷积与标准卷积分支等结构设计，并借鉴轻量化通道重组思想^[62]，通过双分支协同策略在降低模型计算成本的同时增强特征提取能力，其结构如??所示。

其中，通道二分操作用于将输入特征拆分为两个并行子空间。第一条分支侧重以较低计算代价完成局部特征提取与跨通道信息融合，第二条分支采用标准卷积保持稳定的局部感受野与结构连续性。两条分支在功能上的分工分别对应“轻量化特征重组”和“结构细节保留”，从而使模块在控制复杂度的同时仍具备较好的多尺度表达能力。

该模块用于替换 YOLO11s-Seg 中 Neck 部分的标准下采样卷积结构，以提高下采样阶段的效率和特征利用能力。设输入特征图为 X ，首先沿通道维度将其平均划分为两个子分支 X_1 和 X_2 ：

$$X_1, X_2 = \text{Split}(X, \text{dim} = 1) \quad (2.8)$$

第一条分支采用组卷积与逐点卷积进行轻量化特征提取与跨通道融合：

$$Y_1 = \text{GroupConv}(X_1) + \text{PointwiseConv}(X_1) \quad (2.9)$$

第二条分支采用步幅为 s 的 3×3 卷积，以保持稳定的局部感受野并增强对结构边界的表征能力；在 Neck 的下采样位置通常取 $s = 2$ ：

$$Y_2 = \text{Conv}_{3 \times 3}^s(X_2) \quad (2.10)$$

最终将两路特征进行拼接并经过归一化与激活：

$$Y = \text{SiLU}(\text{BN}(\text{Concat}(Y_1, Y_2))) \quad (2.11)$$

因此，SSConv 在降低下采样阶段计算负担的同时，兼顾了局部细节保持、跨通道信息融合以及结构边界建模能力，有助于提升模型在复杂堆叠场景中的多尺度特征表达效果。

从任务贡献角度看，SSConv 的意义不仅在于压缩模型复杂度，更在于提高了特征融合阶段的信息利用效率。对于本文后续提出的计数方法而言，若实例分割结果在边界连续性和局部形状表达上更加稳定，则满载判别和面积比估计过程也更容易获得可靠输入。因此，SSConv 可以视为连接“模型轻量化需求”和“计数可靠性需求”的关键模块之一。

2.1.2.3 本文提出的四向卷积模块 C3k2_QDConv

设计动机：烟箱堆叠图像中的关键判别线索往往表现为水平或垂直延展的边缘、层间交界线和局部遮挡下的轮廓连续性，而传统 Bottleneck 对这类方向性几何结构的表达能力相对有限。当模型无法稳定感知这些方向性边缘时，容易在箱体接触位置出现实例分离不清、上下层类别混淆和掩膜轮廓不完整等问题。为增强模型对仓储规则堆叠结构的适配能力，本文希望在核心特征提取阶段显式强化水平方向和垂直方向的几何变化建模，因此引入了以四向卷积为核心的 C3k2_QDConv 模块。

在堆叠货物场景中，箱体边缘、遮挡关系以及方向性几何结构对目标识别具有重要影响。然而，传统 Bottleneck 模块主要依赖标准卷积完成局部特征提取，其对方向性结构和复杂空间关系的建模能力相对有限。尤其在库存边界模糊、局部重叠遮挡等情况下，传统卷积往往难以充分刻画长条形边缘和多方向变化特征，容易造成细节信息




图 2-5 四向卷积模块 QDConv

Figure 2-5 Quad-direction convolution module

损失。

对于烟箱堆叠图像而言，这类方向性结构信息具有更强的任务相关性。由于箱体大多呈规则长方体外形，其边缘通常沿水平或垂直方向分布，堆叠层间关系也常通过这些边缘和角点位置体现出来。当图像中出现部分遮挡、光照变化或背景干扰时，模型是否能够稳定感知这些方向性几何线索，将直接影响其实例分离能力与层次判断能力。因此，仅依赖常规局部卷积往往难以充分满足该类场景对结构表达的需求。

为增强模型对堆叠场景几何特征的感知能力，本文提出 **Bottleneck_QDConv**，并构建对应的 **C3k2_QDConv** 模块。该模块以四向卷积为核心，通过多个方向上的非对称卷积与显式空间位移操作，加强对不同方向边缘和空间结构变化的建模能力，其结构如??所示。

与常规卷积相比，QDConv 的优势在于其建模重点更加贴近本文任务的几何特征分布。通过在水平和垂直两个主方向上分别进行卷积，并结合正反位移操作，模块能够更有效地感知边缘延展关系、结构交界区域以及局部遮挡下的轮廓连续性。这使其不仅能够提升单个目标的边界表达质量，还能够增强模型对相邻目标之间空间关系的判断能力，从而减少堆叠目标分离过程中的歧义。

设输入特征为 X ，输出为 Y ，卷积核尺寸为 k ，位移步长为 $s = 1$ 。首先对输入特征进行零填充，得到四个方向的位移分支 X_p^1 、 X_p^2 、 X_p^3 和 X_p^4 。随后分别对其施加 $1 \times k$

与 $k \times 1$ 的卷积，并通过显式位移操作进行方向建模，最终表达式为：

$$Y = \text{Conv}_{2 \times 2} \left(\text{Concat} \left[\begin{array}{c} \text{Roll}_{+1}^H(\text{Conv}_{1 \times k}(X_p^1)), \\ \text{Roll}_{-1}^H(\text{Conv}_{1 \times k}(X_p^2)), \\ \text{Roll}_{+1}^W(\text{Conv}_{k \times 1}(X_p^3)), \\ \text{Roll}_{-1}^W(\text{Conv}_{k \times 1}(X_p^4)) \end{array} \right] \right) \quad (2.12)$$

其中， Roll_{+1}^H 、 Roll_{-1}^H 表示沿高度方向进行正向和反向位移操作； Roll_{+1}^W 、 Roll_{-1}^W 表示沿宽度方向进行正向和反向位移操作； $\text{Conv}_{1 \times k}$ 、 $\text{Conv}_{k \times 1}$ 分别表示核尺寸为 $1 \times k$ 和 $k \times 1$ 的卷积操作，用于水平方向和垂直方向的特征提取。

与传统标准卷积相比，QDConv 不仅能够在多个方向上捕获目标的几何变化特征，还能够通过位移操作强化空间关系表达，从而使模型在复杂堆叠结构下获得更丰富的方向性特征表示。由此，C3k2_QDConv 能够提升模型对复杂空间结构和目标轮廓信息的刻画能力，为后续检测与分割提供更具判别性的特征支撑。

从盘点应用角度看，C3k2_QDConv 的引入进一步增强了模型对结构化场景的适配性。由于后处理算法需要利用掩膜轮廓、凸包角点及其几何关系进行状态判断和数量估计，若分割结果在方向性边缘上更清晰、轮廓更稳定，则后续几何推理的可靠性也会同步提高。因此，该模块的作用不仅体现在视觉特征表达层面，也为计数阶段的几何分析提供了更优输入。

2.2 后处理数量计算方法

在立体仓库堆叠货物盘点任务中，仅依赖目标检测结果难以准确完成数量估计，其原因在于盘点结果不仅取决于目标是否被识别，还与上下层结构关系及堆叠规则密切相关。由于实例分割结果能够提供更精细的轮廓信息和空间形状信息，本文在前期面积比计数研究^[1]的基础上，完成面向本文任务的后处理数量计算流程适配与集成，以实现复杂堆叠场景下货物数量的准确推断。

与直接以目标框数量作为库存数量的简单统计方式不同，本文任务的数量计算需要同时考虑目标类别、层次关系以及装载状态。例如，当图像中仅检测到下层目标而缺乏顶层信息时，单纯依据检测框数量无法判断整体堆叠结构；当图像中同时存在上下层目标时，还需要进一步判断顶层是否满载，才能决定采用何种数量推理公式。因此，后处理算法并非附加步骤，而是将视觉识别结果转化为库存数量信息的关键环节。实例分割掩膜所提供的轮廓信息恰好能够支撑这一过程中的几何分析与结构推断。本



(a) 原图

(b) 标注后

图 2-6 图像标注示例

Figure 2-6 Example of image annotation

节的计数主流程、满载判别思路以及面积比估计框架主要承接自文献^[1]，本文工作的重点在于将其与 YOLO11-StackLite 的分割输出进行适配与集成，并在本文数据集与实验设置下验证其有效性，而不将该流程作为独立提出的新计数方法。

2.2.1 计数主体流程

本文采用“up_box”和“down_box”两个类别对每幅图像中的目标进行标注，如??所示。其中，类别标签 1 和 0 分别对应 up_box 与 down_box。需要特别说明的是，up_box 表示顶层可见的单个箱体实例，而 down_box 并非表示每一个非顶层箱体，而是表示顶层以下的单层堆叠区域实例。这一定义与文献^[1]保持一致，其目的在于将“顶层单箱体数量”和“顶层以下完整层数”同时编码到实例分割结果中，从而便于后续数量推理。模型在推理阶段输出每个目标实例的边界框、类别标签及其对应的掩膜信息。为了提升后续计数环节的准确性与鲁棒性，本文根据不同类别的特性设置差异化的置信度阈值，仅保留满足阈值要求的预测结果参与后续处理。

在获得满足阈值条件的实例分割结果后，本文采用文献^[1]中的面积比计数框架，并结合本文的实例分割标签定义与推理输出完成流程适配，其总体流程如??所示。根据仓库货物“下一层箱体仅在当前层堆满后方可叠加”的堆叠规则，总货物数量估算被




图 2-7 后处理数量估计流程示意

Figure 2-7 Schematic flow of the post-processing counting pipeline

划分为场景状态判别、顶层满载检测以及未满载场景下面积比估计三个阶段。

为避免符号歧义，本文对后处理流程中的关键量统一定义如下： N_{total} 表示图像对应货位的箱体总数量； N_{top} 表示检测到的 up_box 数量，即顶层可见单箱体数量； L_{down} 表示检测到的 $down_box$ 数量，即顶层以下完整堆叠层数； N_{layer} 表示在顶层未满载时由面积比方法估计得到的单层箱体数量。后文中的数量公式均基于上述定义展开。

这一流程设计体现了“先判别场景状态、后执行数量推理”的思路。原因在于，不同装载状态下可利用的信息并不相同，若不先区分场景类型而直接采用统一的数量计算方式，容易引入系统性误差。例如，空货物图像无需进入后续推理流程；仅包含下层目标的图像由于缺乏完整顶层结构信息，无法直接估算总数量；而完整堆叠图像则需要根据是否顶满选择不同的数量计算路径。通过将盘点流程拆解为若干具有明确业务含义的判断步骤，面积比计数方法在逻辑上更贴近实际仓储盘点规则，也更具可解释性。

根据预测结果中上下层目标的存在状态，本文将堆叠货物盘点情形划分为以下三类：

a) 检测结果为空。若预测结果中未检测到任何目标，即类别数组为空，则可直接

判定该图像中无货物，数量记为 0。

b) 仅检测到下层货物。若预测结果中仅包含类别 0，而不包含类别 1，则说明图像中缺乏顶层结构信息，无法直接判断完整堆叠关系，如??所示。此时输出 $num=-1$ ，并将该类图像交由仓储管理系统进一步处理。需要说明的是， $num=-1$ 并不表示系统失效，而是表示在当前单视角视觉证据不足的情况下主动返回“不可判定”状态，以避免在缺乏顶层信息时输出不可靠的数量结果。从工程实现角度看，这是一种面向实际业务的保守回退机制。

c) 同时检测到上层与下层目标。该情形为最常见的完整堆叠场景，需要进一步区分顶层满载和顶层未满载两种情况。若顶层判定为满载，则总货物数量可依据“顶层单箱体数量 $\times$ 总层数”直接估算：

$$N_{total} = N_{top} \times (L_{down} + 1) \quad (2.13)$$

式中， N_{top} 表示当前顶层检测到的单箱体数量， L_{down} 表示顶层以下已完整堆叠的层数。该表达与文献^[1]中的满载情形定义保持一致：当顶层满载时，顶层箱体数可作为每一层的基准箱体数，进而与已完整堆叠的下层层数共同确定总量。若顶层未满载，则需进一步结合掩膜关键点与几何关系估算次顶层单层箱体规模，最终总货物数量表示为：

$$N_{total} = N_{top} + (N_{layer} \times L_{down}) \quad (2.14)$$

其中， N_{layer} 表示依据面积比估计得到的单层箱体数量。

上述两种数量估计方式分别对应规则堆叠场景中的两类典型状态。顶层满载时，堆叠结构相对规则，可直接依据顶层箱体数与完整层数推断总箱体数量；顶层未满载时，当前图像只能部分反映顶层覆盖状态，需要进一步利用掩膜几何关系估算单层箱体规模。正因为如此，本文将“满载检测”设为后处理流程中的关键分支节点，使数量计算过程建立在更稳定的状态判别基础上。需要再次说明的是，这里的状态划分与计数公式沿用自文献^[1]的面积比计数框架，本文主要完成与改进实例分割结果的适配与系统集成。由此，本文方法对应的是一种“可判定场景自动输出，不可判定场景触发复核”的智能盘点流程，而不是在所有视觉条件下都强制给出自动计数结果。

为便于理解，给出一个简单示例。若某货位图像中检测到 $N_{top} = 6$ 个顶层箱体，且




图 2-8 立体仓库堆叠货物盘点的三种情况

Figure 2-8 Three situations for inventory of stacked goods in a three-dimensional warehouse

检测到 $L_{down} = 2$ 个 down_box 实例，则在顶层满载时可直接得到 $N_{total} = 6 \times (2 + 1) = 18$ 。若另一幅图像中检测到 $N_{top} = 4$ ， $L_{down} = 2$ ，且面积比估计得到单层箱体数量 $N_{layer} = 6$ ，则可得到 $N_{total} = 4 + 6 \times 2 = 16$ 。这一示例说明，up_box 负责提供顶层单箱数量信息，而 down_box 负责提供完整层数信息，二者共同支撑后处理数量推断。

为保证第二章方法链条表述的完整性，本文进一步对文献^[1]中的顶层满载判别策略与基于掩膜关键点的层间面积比估计策略进行说明，并阐述其在当前盘点流程中的集成方式。

2.2.1.1 基于几何关系的顶层满载检测算法

当场景中同时存在上下层目标时，需要首先判定顶层是否处于满载状态。文献^[1]给出了基于掩膜几何关系的顶层满载判别方法，本文在后处理阶段采用其核心思路，具体过程如算法 ?? 所示。该方法首先对实例掩膜进行轮廓提取，并利用凸包运算获取边界角点，以近似描述货物的平面外形与空间占位关系；随后，根据模型预测标签将实例划分为顶层箱体集合与非顶层层级区域集合，并依据图像坐标系下的几何位置关系比较二者在垂直方向上的相对位置，从而判断顶层目标是否覆盖下层顶部区域。

该算法的核心思想在于利用二维图像中的几何关系替代难以直接获取的深度信息。由于立体仓库监控图像通常仅提供单视角 RGB 信息，模型无法像多传感器系统那样直接获得精确空间深度，因此需要借助掩膜轮廓、凸包角点以及目标中心位置等几何线索间接判断层间遮挡关系。对于堆叠较规则的箱体场景而言，这种基于几何关系的推断方式能够较好地适配仓储业务中的满载判别需求，并且实现成本较低、可解

释性较强。

这种基于几何中心与边界点的比较方式，能够在无深度信息条件下利用二维平面几何关系实现有效的层间遮挡判断。由此可见，该算法可作为后续数量估计的前置判别环节，为不同盘点情形下的数量推断提供依据。

进一步地，顶层满载检测的意义不仅在于选择不同计数公式，更在于降低后续数量推理的不确定性。若将未满载场景误判为满载，则总数量估计会因满层假设而显著偏大；若将满载场景误判为未满载，则会增加不必要的几何估计步骤并引入额外误差。综上可知，满载状态判别的准确性直接影响后处理算法的整体稳定性，也是面积比计数流程中的关键前置环节。

算法 2.1: TopLayerFullLoadCheck

Input: Predicted labels `pred_labels`, instance masks `masks`

Output: Top-layer full-load flag `is_full`

// 阶段 1: 提取各实例掩膜的几何表示

```
1 initialize convex-hull point set pts_list
  foreach instance mask mask in masks do
2   extract contour from mask                                // 提取实例轮廓
3   compute convex-hull points pts for valid contour          // 获得角点集合
4   append pts to pts_list
5 end
```

// 阶段 2: 划分上下层目标集合

```
6 split upper and lower targets according to pred_labels      // 划分上层与下层候选目标
```

// 阶段 3: 基于纵向几何关系进行状态判定

```
7 compute highest vertical coordinate dn_top_y of lower targets
  compute hull-center vertical coordinate up_center_y of upper targets
  if up_center_y > dn_top_y then
8   set is_full ← true                                          // 判定为顶层满载
9 else
10  set is_full ← false                                          // 判定为顶层未满载
11 end
12 return is_full
```

2.2.1.2 掩膜关键点驱动的层间面积比估计算法

当顶层未满载时，无法直接依据满层假设完成总数量估计，因此需要进一步估算其下方单层箱体数量。针对这一问题，文献^[1]提出了基于掩膜关键点驱动的面积比估

计方法，本文在后处理阶段采用该方法，其计算过程如算法 ?? 所示，相关关键点定义如 ?? 所示。

该方法的设计基础在于：当顶层未满载时，图像中仍可通过顶层与下方层级区域掩膜的几何关系观察到一定的结构比例特征。若能够从掩膜中提取具有代表性的关键点，并结合交点关系和面积比构建几何约束，则有可能在不直接观察完整单层结构的情况下，对其规模进行合理估计。相比完全依赖人工规则或单纯使用目标框面积进行近似，基于掩膜关键点的估计方式能够更充分利用实例分割结果中的轮廓信息，因而具有更强的针对性。

在计算过程中，需要求解不同候选边之间的交点，以确定上下层结构之间的空间重叠关系。设任意两条线段分别为 P_1P_2 与 Q_1Q_2 ，其中 $P_1(x_A, y_A)$ 、 $P_2(x_B, y_B)$ 、 $Q_1(x_C, y_C)$ 、 $Q_2(x_D, y_D)$ ，其斜率可表示为：

$$k_1 = \frac{y_B - y_A}{x_B - x_A}, \quad k_2 = \frac{y_D - y_C}{x_D - x_C} \quad (2.15)$$

根据两条直线的一般式方程，可进一步写为矩阵形式：

$$\begin{pmatrix} a_1 & b_1 \\ a_2 & b_2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} -c_1 \\ -c_2 \end{pmatrix} \quad (2.16)$$

其中， (x, y) 为两条线段的交点坐标。公式 ?? 和 ?? 用于求解候选边对的交点集合，并为后续面积比估计提供几何基础。

交点求解的作用在于确定不同层结构在图像平面中的几何延展关系。通过关键边之间的交点，可以推断顶层与下方层级区域在可见区域上的相对位置，并进一步构建面积估计所需的近似区域。对于规则堆叠的箱体场景而言，这种处理方式虽然属于近似推断，但能够在没有深度信息和多视角图像的条件下较稳定地反映层间结构比例，从而提高数量估计的可操作性。

算法 2.2: MaskKeypointDrivenAreaRatioEstimation

Input: Upper-layer masks up_box_masks , lower-layer masks $down_box_masks$

Output: Estimated box number of one layer n_layer

// 阶段 1: 提取下层区域关键点

1 extract lower-layer key points A, B, C, D , and G solve intersection point O_1 from geometric relation between AB and CD // 确定下层参考交点

// 阶段 2: 提取上层区域关键点

2 extract upper-layer key points $_A, _B, _C, _D, _E$, and $_F$ solve candidate intersections on upper-layer edges and average them to obtain O_2 // 阶段 3: 计算面积比并估计数量

3 compute single-box area S_1 of the upper-layer region // 估计顶层单箱体面积

4 compute overall area S_2 of the lower-layer region // 估计下层整体面积

5 set $n_layer \leftarrow \text{round}(S_2/S_1)$ // 由面积比估计单层数量

6 **return** n_layer

上述方法充分利用了实例分割掩膜所提供的轮廓与几何信息，能够在顶层未满载的情况下提升数量估计的可解释性和准确性。实际实现时，为保证输出可用于计数，面积比结果取四舍五入后的正整数值。这样既保留了几何比例信息，也增强了算法在真实仓储场景中的可执行性。

综上所述，本文所集成的后处理数量计算流程形成了“实例识别 - 状态划分 - 几何判定 - 数量估计”的完整链条。其中，实例分割结果提供目标边界与类别信息，满载检测环节负责进行状态分流，面积比估计算法负责处理更复杂的未满载场景，异常回退分支则负责在证据不足时输出不可判定状态并交由系统复核，最终共同构成面向业务场景的库存数量推断流程。与仅依赖检测框数量的简单计数方式相比，该流程更符合实际仓储盘点业务逻辑，也使本文能够在改进实例分割模型的基础上完成可解释的数量估计。就本章贡献边界而言，这一部分的主要价值在于完成既有计数流程与本文视觉模型输出的稳定衔接，为后续实验评估提供统一任务链路。

2.3 本章小结

本章首先分析了基线模型 YOLO11s-Seg 的结构特点及其在复杂堆叠场景中的局限性，指出其在关键区域建模、下采样信息保持和方向性空间结构表达方面仍存在改进空间。在此基础上，本文提出改进模型 YOLO11-StackLite，并从注意力机制、特征融合结构和方向性卷积建模三个方面对关键模块进行了设计，形成了面向堆叠货物实




图 2-9 目标掩膜凸包点与关键点定义示意

Figure 2-9 Schematic definition of convex-hull points and key points on the target mask

例分割任务的改进网络结构。

随后，本文引入前期研究中的面积比后处理计数框架^[1]，并说明了其与实例分割结果的结合方式，使模型输出能够进一步转化为可解释的库存数量信息。由此，本章完成了从视觉识别到数量推理的完整方法集成，为第 4 章的实验验证提供了技术基础，也为第 3 章进一步开展模型压缩研究提供了可压缩的高性能基线模型。需要强调的是，本章在数量推理部分的工作重点是任务适配、流程打通和系统验证，而本文的核心原创性仍主要体现在实例分割模型改进与后续压缩路线设计上。

第三章 面向边缘部署需求的 YOLO11-StackLite 模型压缩方法

第 2 章提出的 YOLO11-StackLite 在复杂堆叠货物场景下能够较好地完成目标检测、实例分割与盘点相关任务，但其作为面向复杂场景设计的实例分割模型，仍然包含较多卷积层、多尺度特征融合路径以及专用结构模块。对于边缘设备而言，模型参数量、浮点运算量以及显存占用会直接影响部署成本与响应效率。因此，在尽量保持 box mAP、mask mAP、DA 和 CA 等关键指标稳定的前提下，对 YOLO11-StackLite 进行压缩具有明确的工程价值。

需要说明的是，本文当前尚未在目标边缘硬件平台上完成系统化实机部署测试，因此本章研究重点定位于压缩路线设计、任务性能保持能力验证以及部署可行性分析，而非直接给出实际设备上的闭环部署结论。换言之，本章更关注“压缩后模型是否具备进一步部署的条件”，并为后续在具体边缘设备上的时延、资源占用和稳定性测试提供方法基础。

考虑到本文研究重点在于验证模型在资源受限场景中的部署适配潜力，而非提出新的通用压缩理论，因此本章不重新设计全新的剪枝或蒸馏框架，而是选用已有文献中真实可靠、工程适配性较强的方法，并结合 YOLO11-StackLite 的结构特点进行任务适配。具体而言，本文采用基于 BN 缩放因子的 Network Slimming 型结构化通道剪枝方法对模型进行轻量化处理^[45-47]，并在剪枝后引入经典软目标蒸馏与基于 ReviewKD 的多阶段特征蒸馏，以恢复压缩带来的性能损失^[43,55]。据此构建面向堆叠货物盘点任务的“结构化剪枝 + 知识蒸馏”压缩流程。

基于上述研究定位，本文采用面向工程实现的模块感知结构化压缩路线：首先在目标模块上施加稀疏约束训练，以获得具有通道重要性差异的教师网络；随后结合 C2SASA、C3k2_QDConv 和 SSConv 的结构约束构建紧凑学生模型；最后在紧凑学生模型上引入软目标蒸馏与受 ReviewKD 启发的多层特征蒸馏，以恢复压缩带来的性能损失。由此形成“稀疏约束训练 + 结构化通道压缩 + 蒸馏恢复”的完整技术路线。

为更清晰地说明本章方法设计，图 ?? 给出了本文压缩与恢复路线的整体流程示意。该流程从完整模型出发，依次经历稀疏训练、结构化剪枝、微调恢复和蒸馏增强四个阶段，最终得到兼顾模型复杂度与任务性能的紧凑模型。与直接对原始网络进行




图 3-1 模型压缩与蒸馏恢复流程示意

Figure 3-1 Overall pipeline of the proposed compression and distillation recovery route

统一压缩不同，本文路线强调“先识别冗余，再约束剪枝，最后恢复性能”，其目的在于降低压缩过程对复杂堆叠场景结构表达能力的破坏。

若直接对完整模型进行固定比例裁剪，虽然可以较快降低 Params 和 GFLOPs，但也容易同步削弱掩膜边界质量、层次结构判别能力以及后处理盘点稳定性。特别是在本文关注的复杂堆叠场景中，实例分割误差会继续传递到后续状态识别和数量推理环节，因此压缩方法不能仅追求复杂度下降，还需要关注压缩后模型是否仍能稳定服务于盘点任务。基于上述考虑，本文将压缩过程设计为“结构化压缩 + 蒸馏恢复”的两阶段方案，以兼顾部署需求与任务需求。

3.1 模型压缩需求分析

YOLO11-StackLite 的结构由 Backbone、Neck 和 Segment Head 三部分构成。与常规轻量检测网络相比，该模型在关键区域注意力建模、方向敏感特征提取以及轻量化下采样方面额外引入了 C2SASA、C3k2_QDConv 和 SSConv 等模块。上述改进提升了复杂遮挡场景中的结构表达能力，但也使模型在通道规模、分支组织和中间特征交互方面具有更高复杂度。若直接将完整模型部署到边缘侧设备，可能面临推理延迟较大、吞吐量受限以及显存占用偏高等问题。

进一步分析可知，本文的压缩目标并不是简单追求参数量最小化，而是强调多项指标之间的综合平衡。一方面，box mAP 和 mask mAP 反映模型对箱体边界、轮廓及重叠区域的基础识别能力；另一方面，DA 和 CA 反映压缩后的识别结果能否继续支撑后续盘点推理。对于堆叠货物场景而言，若压缩导致高层结构关系建模能力下降，即

使检测指标下降有限，也可能在后处理阶段放大计数误差。综上，本章压缩研究的核心要求可概括为：在保证复杂堆叠场景结构表达能力基本稳定的前提下，尽量降低模型参数规模与计算复杂度。

从实际部署角度看，非结构化剪枝虽然能够获得较高稀疏率，但其稀疏模式不规则，往往难以直接转化为现有推理框架中的实际加速收益^[42,44]。相比之下，结构化通道剪枝能够直接删除卷积通道或模块分支，剪枝后的模型拓扑更加规整，更适合在工程系统中继续微调、导出和部署。因此，本文将结构化通道剪枝作为主要压缩手段，再辅以蒸馏策略补偿精度损失，形成更符合任务需求的压缩路线。

3.2 基于结构化通道剪枝的轻量化方法

3.2.1 Network Slimming 型结构化剪枝原理

结构化剪枝的核心思想是在保证任务性能尽量稳定的前提下，删除网络中贡献较低的卷积通道，从而降低模型规模和计算量。本文采用 Network Slimming 的基本思想，即利用 Batch Normalization 层中的缩放因子 γ 衡量通道重要性^[47]。该方法的优势在于：其一，重要性评价方式简单稳定，易于与 YOLO 系列现有卷积块结合；其二，所得剪枝结果直接对应通道级结构删除，便于在 Ultralytics 框架下生成新的紧凑模型；其三，相比仅基于单层重构误差的剪枝方式，其更容易扩展到包含多分支与多尺度融合的网络结构。

设第 l 个候选卷积层包含 n_l 个输出通道，第 i 个通道对应 BN 缩放因子为 γ_i^l ，则该通道的重要性记为

$$s_i^l = |\gamma_i^l| \quad (3.1)$$

当 s_i^l 越小时，说明该通道在训练后对特征分布的缩放作用越弱，可视为更可能冗余的结构单元。为了使网络在训练阶段主动形成通道稀疏性，在原始任务损失 L_{task} 的基础上引入对全部 BN 缩放因子的 L_1 正则约束，可得稀疏训练目标：

$$L_{\text{sparse}} = L_{\text{task}} + \lambda_s \sum_l \sum_{i=1}^{n_l} |\gamma_i^l| \quad (3.2)$$

其中， λ_s 为稀疏约束系数。经过稀疏训练后，各候选层通道的重要性差异会被进一步拉开，从而便于后续按照阈值或预设剪枝率执行结构化裁剪。

若记原始模型参数集合为 Θ ，被裁剪的低重要性通道集合为 $\mathcal{P}$ ，则结构化剪枝的目标可表示为

$$\min C(\Theta \setminus \mathcal{P}), \quad \text{s.t. } \Delta \mathcal{M} \leq \epsilon \quad (3.3)$$

其中， $C(\cdot)$ 表示模型复杂度度量，可取 Params 或 GFLOPs； $\Delta \mathcal{M}$ 表示压缩前后任务性能下降幅度； ϵ 为可接受性能退化上界。该表达式表明，本文的剪枝目标并非孤立地追求通道删除数量，而是在复杂度压缩与任务性能之间寻求折中。

3.2.2 YOLO11-StackLite 剪枝对象选择

YOLO11-StackLite 的 Backbone 末端引入了 C2SASA 模块，Neck 中引入了多处 C3k2_QDConv 与 SSConv，Segment Head 则基于 P3、P4 和 P5 三尺度特征输出分割结果。由于不同模块承担的功能不同，其可压缩性也存在明显差异。若对全网络进行无差别激进剪枝，容易破坏复杂遮挡场景下的结构建模能力，导致分割质量与盘点稳定性同步下降。因此，本文采用“主干保守、融合优先、输出轻剪”的选择原则。进一步地，本文的物理剪枝并非面向全网所有层设计通用自动依赖分析器，而是针对 C2SASA、C3k2_QDConv、SSConv 以及与其直接耦合的 Segment Head 构建专用剪枝与迁移策略。

首先，Neck 中的 C3k2_QDConv 是主要剪枝对象。该模块位于多尺度融合阶段，承担方向敏感局部几何建模任务，但其前后卷积通道规模较大，且在特征融合过程中存在一定冗余，具有较好的压缩潜力。尤其对于 P3/8 和 P4/16 分支中的 C3k2_QDConv 块，合理剪枝通常可以显著降低计算量，同时对高层语义表达造成的破坏相对有限。

其次，SSConv 模块可以进行适度剪枝，但必须满足其结构约束。根据第 2 章网络设计，SSConv 先将输入特征按通道二分，再分别送入“分组卷积 + 逐点卷积”分支和 3×3 标准卷积分支。因此，SSConv 的输出通道数需要保持为 2 的倍数；同时由于其中一支包含固定分组数 $g = 4$ 的组卷积，则对应的半通道宽度还应满足可被 4 整除。综合两者可知，SSConv 剪枝后保留通道数宜满足 8 的整除约束，否则容易破坏两分支对称性与组卷积配置，造成结构不一致。

再次，Backbone 末端的 C2SASA 采用保守剪枝策略。该模块负责高层特征的选择性增强与关键区域聚焦，是复杂堆叠场景下区分相邻箱体、顶层与非顶层目标的重要结构。其内部注意力单元仍包含多头划分与通道映射过程，若通道压缩过度，容易破

坏注意力建模的维度约束并削弱关键区域表征能力。因此，对 C2SASA 仅进行低比例剪枝，且保留注意力分支的维度整除约束，使输出通道数满足多头注意力计算要求。

最后，Segment Head 不作为主要剪枝对象。原因在于分割头直接影响掩膜系数预测与最终掩膜质量，过度裁剪可能导致 mask mAP 和后续盘点准确率同步波动。为保证输出稳定性，本文对检测分割输出头仅进行轻量保守调整，压缩重点仍放在 Backbone 与 Neck 的中间特征变换部分。

之所以优先针对上述模块设计专用物理剪枝，而未对其余标准模块全部执行同等级别的定制化裁剪，主要基于两点考虑：其一，C2SASA、C3k2_QDConv 和 SSConv 是本文模型中最关键、最具结构特征且最有可能带来压缩收益的自定义部分，其通道组织方式直接影响多尺度融合、方向敏感建模和关键区域聚焦能力；其二，标准卷积层更多承担通用特征变换功能，若全部为其设计专用物理剪枝与映射规则，会显著提高工程复杂度和实现不稳定性。因此，本文采用“关键模块专用剪枝 + 其余结构保守适配”的策略，以兼顾方法可实现性、结构安全性和压缩收益。

3.2.3 面向专用模块的通道重要性评估与剪枝率设定

在完成剪枝对象选择后，还需要进一步确定具体的通道重要性评估方式和各层剪枝率。对于包含 BN 的常规卷积层，本文直接采用缩放因子绝对值进行排序，按层内重要性从小到大删除低贡献通道。对于包含专用结构约束的模块，则在重要性排序基础上增加整除约束和分支同步裁剪规则。进一步地，本文将通道选择划分为“输出通道选择”和“内部隐藏通道选择”两个层面：对于输出通道，依据模块输出端 BN 缩放因子绝对值排序保留高重要性通道；对于 C2f 风格模块内部隐藏通道，则依据入口卷积对应 BN 权重进行分支化选择；对于 SSConv，则分别在左右分支上选取保留通道，以避免破坏双分支结构。

对于 C3k2_QDConv，其内部 QDConv 由四个方向分支共同完成特征提取，并在通道维度拼接后再进行卷积融合。为保证四方向分支输出维度一致，剪枝时不对单一方向分支做独立裁剪，而是对其共享的中间通道规模进行同步缩减，使四个方向分支保持相同宽度。由此，C3k2_QDConv 的保留通道数应满足 4 的整除关系。

对于 SSConv，其内部先进行通道拆分，再分别经过分组卷积、逐点卷积和普通卷积分支处理，因此其通道裁剪除满足重要性排序外，还需要同时满足分支二分与分组

卷积可整除条件。设某模块原始输出通道数为 n_l ，预设剪枝率为 r_l ，则其理想保留通道数为 $n_l(1 - r_l)$ 。考虑结构约束，本文进一步采用对齐函数 $\text{Align}(\cdot, d_l)$ 将其映射到满足模块约束的最近通道数：

$$\hat{n}_l = \text{Align}(n_l(1 - r_l), d_l) \quad (3.4)$$

其中， d_l 为结构约束对应的最小整除单位。对于普通卷积层可取 $d_l = 1$ ，对于 C3k2_QDConv 取 $d_l = 4$ ，对于 SSConv 取 $d_l = 8$ ，对于 C2SASA 则需满足多头注意力的维度整除要求。

在剪枝率设置方面，本文不采用全局统一的大比例裁剪，而采用分层分模块的差异化剪枝策略：Backbone 浅层与高语义关键层使用较低剪枝率，以保证底层纹理和高层结构语义稳定；Neck 中多尺度融合相关卷积采用相对更高剪枝率，以释放通道冗余；Segment Head 保持最低剪枝率或不参与主裁剪。该策略既符合 YOLO11-StackLite 的真实结构特点，也有助于在复杂度下降与性能保持之间取得更合理平衡。

从具体实现角度看，结构约束处理是本文物理剪枝能否稳定落地的关键。对于 C3k2_QDConv，需要保证四向分支等宽同步，避免单一方向分支被独立裁剪后造成拼接失衡；对于 SSConv，需要同时满足二分支通道划分与组卷积整除关系；对于 C2SASA，需要保持注意力映射过程中的维度约束；对于 Segment Head，则需随 P3、P4、P5 三尺度输入通道同步调整分割头和原型分支参数。上述约束使得本文剪枝方案并非简单按比例缩小通道数，而是在重要性评估基础上进一步进行结构对齐。

算法 3.1: ModuleAwarePhysicalPruning

Input: Sparse model M_{sparse} , compact structure M_{pruned}

Output: Initialized compact model M_{init}

// 阶段 1: 确定目标模块与保留通道

- 1 foreach $m \in \{C2SASA, C3k2_QDConv, SSConv, Segment\}$ do
 - // 依据输出端 BN 缩放因子绝对值评估输出通道重要性
 - 2 compute output importance scores from BN scaling factors select output channels with
top-ranked scores // 保留高重要性输出通道
 - 3 if m is C2f-like then
 - // 对 C2f 风格模块按入口卷积 BN 权重执行分支化隐藏通道选择
 - 4 select hidden channels from branch-aware input BN weights
 - 5 end
 - 6 if m is SSConv then
 - // 对 SSConv 分别选择左右分支保留通道, 避免破坏双分支结构
 - 7 select left and right branch channels separately
 - 8 end
 - // 按模块结构约束对保留通道数进行对齐
 - 9 align retained width under module constraints if m is C3k2_QDConv then
 - 10 keep four directional branches synchronized // 保证四向分支等宽同步
 - 11 end
 - 12 if m is SSConv then
 - // 保证二分支结构与组卷积整除关系
 - 13 keep split branches and grouped-convolution divisibility
 - 14 end
 - 15 if m is C2SASA then
 - 16 keep attention projection dimensions valid // 保持注意力映射维度约束
 - 17 end
 - 18 end
 - // 阶段 2: 切片并迁移保留权重
 - // 按保留通道索引切片复制卷积层、归一化层和线性层参数
 - 19 slice and copy convolution, normalization, and linear parameters by retained indices // 对
backbone、neck、head 的相关输入输出通道进行同步映射
 - 20 map related input and output channels across backbone, neck, and head // 根据 P3/P4/P5 保留通
道同步调整 Segment 头与原型分支
 - 21 adapt Segment head according to retained P3, P4, and P5 channels // 返回可直接继续微调的紧
凑模型初始化权重

由算法 ?? 可见, 本文的物理剪枝并不是仅通过修改网络配置文件获得紧凑结构, 而是根据保留通道索引对卷积层、归一化层和分割头参数执行切片复制, 并对 backbone、neck、head 的相关输入输出通道进行同步映射。由此得到的紧凑模型不仅在结构上完成真实裁剪, 而且具备可直接继续微调的初始化权重, 这也是其优于仅构造缩小版 YAML 再重新训练方案的重要原因。

3.2.4 剪枝流程设计

结合上述原则, 本文的结构化剪枝与恢复流程可归纳为四个阶段。为便于说明压缩模型的完整构建与性能恢复过程, 算法 ?? 给出了与实际实现相对应的总体流程伪代码。

算法 3.2: CompressionDistillationPipeline

Input: Dense model M_{dense} , training set D , target ratio setting R

Output: Distilled compact model $M_{distill}$

// 阶段 1: 训练完整教师模型

1 train M_{dense} on D to obtain teacher model $M_{teacher}$ // 为后续剪枝与蒸馏提供参照

// 阶段 2: 执行稀疏约束训练

2 apply L_1 sparsity regularization to candidate BN scaling factors // 促使低贡献通道的缩放系数收缩

3 train sparse model M_{sparse} on D under sparsity constraint // 拉开通道重要性差异

// 阶段 3: 构建紧凑结构并完成物理剪枝

4 determine retained channels according to module-aware ratio setting R // 结合模块约束确定保留通道

5 build compact structure M_{pruned} from retained channels // 生成剪枝后的目标结构

6 transfer retained weights from M_{sparse} to M_{pruned} // 完成物理剪枝与权重迁移

// 阶段 4: 恢复紧凑模型性能

7 fine-tune M_{pruned} on D to obtain M_{ft} // 恢复基础检测与分割能力

8 distill M_{ft} from $M_{teacher}$ using output and feature distillation // 进一步恢复高层语义与边界细节

9 set $M_{distill} \leftarrow M_{ft}$ after distillation training // 得到最终紧凑模型

10 return $M_{distill}$

(1) 训练完整的 YOLO11-StackLite 基线模型。首先在基于文献^[1]中的 TCSD 并经本文整理后的 794 张有效图像上完成原始模型训练, 获得性能稳定的教师候选模型, 同时

记录其 Params、GFLOPs 及各项任务指标，作为后续压缩对比基准。

(2) 执行稀疏训练。对参与剪枝的卷积层施加基于 BN 缩放因子的 L_1 稀疏约束，使低贡献通道的缩放系数逐渐收缩，为后续结构化裁剪创造条件。

(3) 执行结构化物理剪枝与权重迁移。根据各候选层的重要性排序结果，结合模块整除约束，确定各目标层的保留通道集合，并据此构建紧凑模型结构；随后对 C3k2_QDConv、SSConv、C2SASA 及 Segment Head 相关输入输出通道执行真实物理裁剪，将完整模型中保留通道对应的卷积、归一化和检测分割头权重迁移至紧凑模型。

(4) 对剪枝后模型进行微调恢复。通道裁剪会改变网络容量与特征分布，因此需在原始任务损失约束下对已完成权重迁移的紧凑模型继续训练，使其重新适应实例分割与盘点任务。

通过上述流程，可以获得结构更紧凑、计算量更低且具有可训练初始权重的 Pruned-YOLO11-StackLite 模型。但仅依靠剪枝往往仍会带来一定精度下降，尤其是在遮挡严重、边界接近和局部纹理相似的堆叠场景中，这种退化会进一步影响后续计数稳定性。因此，下一节将在物理剪枝和微调恢复的基础上进一步引入知识蒸馏策略，以恢复压缩后的结构表达能力。

3.3 基于知识蒸馏的精度恢复方法

3.3.1 知识蒸馏原理

知识蒸馏的基本思想是利用性能更强的教师模型指导轻量化学生模型训练，使学生模型在较小容量下尽可能继承教师模型的判别能力^[43]。在本文任务中，结构化剪枝虽然能够有效降低模型复杂度，但也可能削弱多尺度特征融合质量、方向敏感边缘表达能力以及高层结构关系建模能力。因此，在剪枝完成并初步微调后继续引入蒸馏训练，有助于缓解压缩带来的性能退化。

与单纯分类任务相比，本文场景中的蒸馏目标不仅包括最终类别预测的一致性，还包括中间特征层对箱体轮廓、遮挡关系和层间几何结构的表达一致性。为此，本文采用“经典软目标蒸馏 + 多阶段特征蒸馏”的联合蒸馏思路：前者用于约束学生模型输出响应接近教师模型，后者用于恢复中间特征层的结构表达能力。考虑到 ReviewKD 在多阶段知识传递方面具有较好效果，且已在检测与分割任务中验证可行^[55]，本文将其作为特征蒸馏设计的重要参考。

3.3.2 教师模型与学生模型构建

本文以第 2 章训练完成的完整 YOLO11-StackLite 作为教师模型，以经过结构化剪枝并完成初步微调的紧凑模型作为学生模型。教师模型保留全部通道与完整结构，具有更强的多尺度融合能力和高层语义表达能力；学生模型则在 Backbone 与 Neck 的部分通道被压缩后，具有更低的复杂度和更强的部署友好性，但其在复杂堆叠场景中的结构表达可能有所减弱。

该教师—学生配置具有明显的同构优势。两者共享相同的总体任务目标、相近的拓扑结构以及相同的三尺度输出形式，仅在通道规模和局部容量上存在差异。因此，教师模型中的高层语义信息和中间结构信息可以更稳定地迁移到学生模型中，避免异构蒸馏中常见的层间语义不匹配问题。这种“完整模型指导剪枝模型”的方案也与本文的工程目标一致，即在不改变整体检测分割流程的前提下提升紧凑模型性能。

3.3.3 蒸馏信息选择与约束方式

结合 YOLO11-StackLite 的结构特点，本文将蒸馏信息分为输出层响应蒸馏和中间特征蒸馏两部分。

输出层响应蒸馏主要约束教师模型与学生模型在最终预测层上的响应一致性，重点保证压缩模型在分类判别、目标置信度以及分割相关输出上的整体趋势不发生明显偏移。设教师模型和学生模型的输出 logits 分别为 z_t 和 z_s ，温度系数为 T ，则经典软目标蒸馏损失可写为

$$L_{\text{soft}} = T^2 \text{KL} \left(\sigma \left(\frac{z_t}{T} \right), \sigma \left(\frac{z_s}{T} \right) \right) \quad (3.5)$$

其中， $\sigma(\cdot)$ 表示 softmax 运算， $\text{KL}(\cdot)$ 表示 Kullback-Leibler 散度。该项约束使学生模型在最终预测分布上向教师模型靠近，从而提高剪枝后模型的判别稳定性。

中间特征蒸馏则重点面向复杂堆叠场景中的结构表达恢复。本文优先选择四类特征作为蒸馏位置：Backbone 末端 C2SASA 输出特征，以及 P3/8、P4/16 和 P5/32 三个尺度的融合特征。选择这些位置的原因在于：C2SASA 负责高层关键区域选择与注意力增强，是遮挡场景中的关键语义层；P3、P4、P5 三尺度特征直接参与最终检测与分割输出，能够同时反映局部边缘、目标主体和高层上下文信息。

为减轻单层点对点蒸馏对学生模型的约束过强问题，本文采用基于 ReviewKD 思

想的多阶段特征蒸馏方式。设第 k 个蒸馏位置的教师特征和学生特征分别为 F_t^k 和 F_s^k ，教师侧通过回顾聚合函数 $\phi_k(\cdot)$ 融合浅层到当前层的多阶段信息，学生侧通过 1×1 适配卷积 $A_k(\cdot)$ 完成通道对齐，则对应的特征蒸馏损失可写为

$$L_{\text{review}} = \sum_{k=1}^K \|A_k(F_s^k) - \phi_k(F_t^1, \dots, F_t^k)\|_2^2 \quad (3.6)$$

其中， K 为蒸馏位置数量。上述设计的核心思想并非要求学生完全复制教师的某一单层响应，而是通过多阶段回顾信息向学生传递更稳定的结构线索，从而更好地恢复掩膜边界和层间关系表达。

3.3.4 蒸馏损失设计

为兼顾原始任务学习与压缩后性能恢复，本文在学生模型原始任务损失基础上联合引入软目标蒸馏损失和多阶段特征蒸馏损失。设学生模型的原始任务损失为 L_{task} ，总蒸馏损失为 L_{distill} ，则联合训练目标为

$$L = L_{\text{task}} + \lambda_d L_{\text{distill}} \quad (3.7)$$

其中， λ_d 为蒸馏总权重系数。进一步可得，

$$L_{\text{distill}} = \alpha L_{\text{soft}} + \beta L_{\text{review}} \quad (3.8)$$

其中， α 和 β 分别表示输出响应蒸馏和多阶段特征蒸馏的权重系数。

这一损失设计具有两点优势。其一， L_{soft} 从输出端约束学生模型的判别行为，可有效缓解剪枝后预测分布漂移；其二， L_{review} 从中间表示层恢复 C2SASA 与三尺度融合特征中的结构信息，有助于提高复杂遮挡场景中的边缘分离和层间关系表达能力。两者结合后，学生模型既能保持原始任务目标不变，又能在较小模型容量下尽量继承完整模型的表示能力。

3.4 压缩模型构建与训练流程

综合结构化剪枝与知识蒸馏策略，本文构建的压缩模型训练流程如下：

- (1) 在基于文献^[1]中的 TCSD 并经本文整理后的 794 张有效图像上训练完整 YOLO11-StackLite 模型，获得作为教师模型和压缩基线的高性能网络；
- (2) 在候选卷积层上施加基于 BN 缩放因子的稀疏约束，执行稀疏训练，使通道重要性

差异进一步显现；

- (3) 按照“Backbone 保守、Neck 优先、Head 轻剪”的原则，对 C3k2_QDConv、SSConv 及 C2SASA 等关键模块执行结构化物理剪枝，并同步满足 QDConv 四分支、SSConv 双分支和 C2SASA 多头注意力的整除约束；
- (4) 将完整模型中保留通道对应的参数迁移到紧凑模型，对其进行微调恢复，得到具备基础检测与分割能力的物理剪枝模型；
- (5) 以完整模型为教师、以剪枝微调模型为学生，在 P3、P4、P5 以及 C2SASA 输出特征上执行多阶段特征蒸馏，并在输出层引入软目标蒸馏，继续优化学生模型；
- (6) 最终获得兼顾模型复杂度与任务性能的 Pruned-Distilled-YOLO11-StackLite。

上述流程体现了“先压缩、后恢复”的设计思路。稀疏训练与结构化物理剪枝负责识别并删除低贡献通道，权重迁移与微调恢复负责在紧凑结构上建立稳定的初始表示，知识蒸馏则进一步恢复语义表达与边缘细节建模能力。从流程功能分工来看，阶段（2）与阶段（3）主要解决“如何在破坏模块约束的前提下释放模型冗余并构建紧凑结构”的问题，阶段（4）主要解决“如何在压缩后恢复分割与盘点性能”的问题。由算法 ?? 与算法 ?? 可见，本文压缩方案的关键不在于构造抽象的通用剪枝框架，而在于围绕本文模型中的关键模块建立专用的通道选择、结构对齐和权重迁移规则，从而形成一条能够真实落地、可继续训练且与任务需求保持一致的压缩流程。

3.5 本章小结

本章围绕 YOLO11-StackLite 在边缘部署场景下仍存在参数冗余和计算开销较高的问题，构建了面向堆叠货物盘点任务的模型压缩方法。首先，从实例分割与盘点联合任务的角度分析了模型压缩需求，明确本文压缩目标不是单纯追求参数最小化，而是在 Params、GFLOPs、box/mask mAP 以及 DA、CA 等指标之间取得平衡。随后，基于 Network Slimming 的结构化通道剪枝方法，结合 C3k2_QDConv、SSConv 和 C2SASA 的真实结构约束，设计了更符合 YOLO11-StackLite 特点的差异化剪枝策略，并通过保留通道权重迁移构建可直接继续训练的物理剪枝模型。最后，在剪枝基础上引入经典软目标蒸馏与基于 ReviewKD 的多阶段特征蒸馏，以恢复压缩造成的结构表达能力损失。

总体而言，本章形成了一个由“稀疏训练、结构化物理剪枝、权重迁移、微调恢复、蒸馏增强”组成的完整压缩流程。该流程既具有明确的文献依据，又与本文模型

结构和任务场景保持一致，为第 4 章进一步开展压缩模型实验验证提供了研究基础。

第四章 实验与结果分析

4.1 实验数据集

本文实验基于文献^[1]中的 Tobacco Cargo Stacking Dataset (TCSD) 开展。该数据集来源于烟草立体仓库中烟箱堆叠的真实场景图像，面向目标检测、实例分割和库存盘点等任务。由于涉及真实仓储场景与企业数据权限限制，TCSD 未公开发布，因此本文后续实验均以实际整理后的数据文件为准，最终用于实验的有效图像共 794 张。

用于本文实验的 TCSD 共包含 794 张图像，均由仓库监控系统采集，图像分辨率统一为 1280×960。数据集采用两类实例分割标注：up_box 表示位于堆叠最上层的单个箱体实例，down_box 表示顶层以下的单层堆叠区域实例。该标注方式并非对所有非顶层箱体逐一实例化，而是将“顶层单箱体数量”和“顶层以下完整层数”同时编码到分割结果中，从而为后续数量推理提供基础。上述数据来源、命名方式和标注思路均承接自文献^[1]。

在数据划分方面，本文采用五折交叉验证（5-fold cross-validation）策略评估模型的稳定性与泛化能力。每一折中，80% 的样本用于训练，20% 的样本用于验证。除检测与分割标注外，每张图像还附带字段 layer_count，用于记录对应货位在完整单层状态下的箱体数，可为顶层未满载场景下的数量推理提供先验参照。与第 2 章保持一致，本文记顶层箱体数量为 N_{top} ，顶层以下完整层数为 L_{down} ，单层箱体数估计为 N_{layer} ，则箱体总数记为 N_{total} 。

结合后续盘点实验中的样本统计结果可知，TCSD 在本文任务设置下主要包含空货物图像、顶层满载图像以及顶层未满载但可执行有效计数的图像三类装载状态。其中，前两类样本主要用于检验模型在状态判别与流程分流阶段的稳定性，后一类样本则直接决定面积比数量推理的难度。由表 ?? 可见，五折验证集内这三类样本的数量分别稳定分布在 38~41、87~90 和 30~32 张之间，说明各折在主要任务场景上的构成较为接近，但整体上仍以顶层满载样本占比最高。

基于上述任务特性，本文在五折划分时以装载状态分布均衡为主要原则，使空货物、顶层满载和有效计数三类样本在各折中的占比尽可能保持一致，从而避免某一折过多集中于相对容易或相对困难的场景。这样做的目的是在有限样本条件下提高不同折之间评估结果的可比性，并使后续模块消融、模型对比和盘点实验建立在一致的场

景分布基础上。

与常规通用实例分割数据集相比，TCS D 的任务属性更具针对性。一方面，图像均来自真实仓储监控视角，存在固定拍摄角度、光照差异、局部遮挡和背景纹理相似等问题；另一方面，标注类别并非简单按照目标语义划分，而是显式区分顶层与非顶层箱体，从而将实例分割任务与后续数量推理过程关联起来。这意味着模型不仅需要识别目标轮廓，还需要具备一定的层次结构判别能力。正因如此，TCS D 更适合作为本文所研究盘点任务的实验基础，也能够较好反映方法在真实仓储场景中的适用性。

采用五折交叉验证而非单次固定划分，也具有明确的实验意义。由于本文数据集规模相对有限，若仅采用单次训练集/验证集划分，实验结果容易受到样本偶然性的影响。五折交叉验证能够在不同数据划分下重复评估模型，使实验结果更能反映模型在不同场景组合下的稳定性。同时，本文后续各项实验均统一基于该划分策略开展，从而保证模块消融、模型对比和盘点实验之间具有一致的评价基础。需要说明的是，本文数据主要来自单一烟草仓库中的规则堆叠场景，因此本章实验结论主要用于说明方法在当前任务设置下的有效性与适配性，不宜直接外推至更复杂的跨仓库或跨货物类型场景。

4.2 评价指标

为全面评估模型在实例分割与库存盘点任务中的性能，本文从检测分割精度、模型复杂度和盘点准确性三个方面设置评价指标。

在检测与分割精度评价方面，本文采用目标检测领域广泛使用的平均精度均值 mAP (mean Average Precision)，重点考察 COCO 评估标准下的 mAP@0.5:0.95，以衡量模型在不同 IoU (Intersection over Union) 阈值下的综合性能。其中，box mAP 用于评估目标边界框定位精度，mask mAP 用于评估预测掩膜与真实区域之间的一致性。两项指标共同反映模型在检测与分割任务中的整体表现。

在模型效率评价方面，本文采用以下两项指标：

- a) GFLOPs (Giga Floating Point Operations)，表示模型单次前向推理所需的浮点运算量，用于衡量模型的理论计算复杂度；
- b) Params (Parameters)，表示模型中可训练参数的总数，用于衡量模型的存储开销与部署成本。

在盘点任务评价方面,本文采用检测准确率 (Detection Accuracy, DA) 和盘点准确率 (Counting Accuracy, CA)。其中, DA 用于评估模型对顶层箱体实例与非顶层层级区域识别结果的正确性; CA 用于评估模型对整幅图像箱体总数预测结果的准确性。通过上述指标,可以从“识别是否正确”和“最终盘点是否正确”两个层面综合分析模型的应用性能。

需要指出的是,本文实验评价并不局限于通用实例分割任务中的 box mAP 和 mask mAP。对于立体仓库堆叠货物盘点问题而言,检测与分割精度只是后续数量推理的基础,若模型在局部边界识别、顶层目标判别或上下层结构区分方面存在偏差,则最终盘点结果仍可能出现错误。因此,本文将 DA 和 CA 一并纳入评价体系,以反映模型性能是否真正能够转化为库存盘点能力。这样的指标设置也使得第 2 章方法改进与第 3 章压缩研究都能够围绕同一任务目标展开比较。

4.3 实验环境与参数设置

实验硬件环境包括 Intel Core i7-13620H 处理器和 NVIDIA GeForce RTX 4090 GPU。实验开发环境为 PyCharm, Python 版本为 3.9.19, 深度学习框架为 PyTorch 2.3.0, CUDA 版本为 12.1。

所提出的 YOLO11-StackLite 模型及其余 YOLO 对比模型均基于 Ultralytics YOLO 实例分割框架进行开发与训练,输入图像尺寸统一设置为 640×640。根据预实验结果,最终训练参数设置如下:训练轮数为 200,批次大小为 64,初始学习率为 0.01,优化器采用 SGD (Stochastic Gradient Descent),动量参数设置为 0.937,权重衰减系数设置为 0.0005。除特别说明外,所有对比实验均采用相同的数据划分方式和训练配置,以保证实验结果的可比性。

上述训练设置主要基于两方面考虑。其一,输入尺寸统一为 640×640,有利于在保证细节表达能力的同时控制显存开销和训练时间,使不同模型在统一尺度下进行公平比较。其二,训练轮数、优化器和学习率等参数均根据预实验结果进行设定,以兼顾模型收敛稳定性与实验效率。对于本文涉及的多组对比实验而言,若不同模型采用差异较大的训练策略,则结果易受到额外变量影响,因此本文尽可能统一训练条件,以保证性能差异主要来自模型结构本身而非训练配置差异。

对于第 3 章涉及的压缩模型实验,本文同样延续上述训练与评估设置,并在原模

型、剪枝模型和剪枝蒸馏模型之间保持一致的数据划分与评价口径。这样可以确保压缩前后的性能变化能够真实反映模型复杂度调整所带来的影响，而不会被额外实验条件所掩盖。

4.4 结果与分析

为验证所提方法的有效性，本文依次开展消融实验、不同实例分割模型性能对比实验以及数量计算评估实验。实验从检测与分割精度、模型复杂度以及盘点准确率等多个角度，对 YOLO11-StackLite 的性能进行综合分析。

本文实验分析遵循“模块有效性验证 - 综合性能比较 - 任务应用验证 - 模型压缩实验验证”的逻辑展开。其中，消融实验用于分析第 2 章各模块设计的独立作用及协同关系；模型对比实验用于验证所提方法在主流实例分割模型中的综合竞争力；数量计算评估用于检验实例分割结果是否能够有效支撑盘点任务；模型压缩实验则进一步验证第 3 章提出的压缩方法是否能够在保持主要性能的同时降低模型复杂度。通过这一实验链条，可以较为完整地支撑全文所提出的方法设计。

4.4.1 消融实验

消融实验的目的是验证 YOLO11-StackLite 中各关键模块的独立贡献及其协同作用。为此，本文在 TCSD 数据集上开展五折交叉验证，对新提出的 C2SASA 注意力模块、SSConv 模块以及 C3K2-QDConv 模块进行逐项消融分析。实验结果如表 ?? 所示，其中“√”表示引入对应模块，Params 表示模型参数量，GFLOPs 表示模型的浮点运算量。

该实验的核心在于回答两个问题：一是第 2 章提出的各个改进模块是否分别对模型性能产生积极作用；二是这些模块组合后是否能够形成稳定的性能增益。由于本文方法并非单一模块替换，而是从注意力建模、下采样结构和方向性空间表达三个层面同时改进基线模型，因此仅报告最终模型结果并不足以说明设计合理性。通过逐项消融，可以更清楚地分析各模块对应的功能定位与性能贡献。

由表 ?? 可见，第一行为未引入新增模块的基线 YOLO11s-Seg 模型。单独引入 C2SASA 后，模型的平均 box mAP 和平均 mask mAP 分别由 84.8% 和 83.9% 提升至 85.4% 和 84.4%，同时参数量与 GFLOPs 均略有下降。这说明该注意力机制在增强关键区域建模能力的同时，也具有一定的轻量化效果。

表 4-1 YOLO11-StackLite 各模块消融实验结果对比

Table 4-1 Ablation study results of YOLO11-StackLite with different modules

C2SASA	SSConv	C3K2-QDConv	Params/M	GFLOPs	Fold1		Fold2		Fold3		Fold4		Fold5		Avg	
					box	mask	box	mask	box	mask	box	mask	box	mask	box	mask
√	√	√	10.1	35.5	87.5	87.2	86.2	85.7	85.2	84.6	85.5	85.0	79.8	77.1	84.8	83.9
			10.0	35.3	88.2	87.6	86.6	86.4	85.9	85.0	85.8	85.1	80.4	77.9	85.4	84.4
√	√	√	9.6	35.0	88.1	86.7	86.8	86.5	85.0	84.8	85.7	85.3	80.0	77.8	85.1	84.2
			9.9	35.5	87.8	87.3	86.7	86.6	85.6	84.8	85.8	85.3	80.0	77.3	85.2	84.3
√	√	√	9.5	34.9	87.9	87.4	86.9	86.2	85.9	85.0	85.8	85.2	80.2	77.4	85.3	84.2
			9.4	34.9	88.6	87.8	87.2	86.7	86.2	85.2	86.0	85.6	80.6	78.0	85.7	84.7

单独引入 SSConv 后，模型参数量下降至 9.6 M，GFLOPs 下降至 35.0，平均 box mAP 和平均 mask mAP 分别提升至 85.1% 和 84.2%。这一结果表明，SSConv 在降低下采样阶段计算开销的同时，仍能维持较好的特征表达能力。单独引入 C3K2-QDConv 后，模型平均 box mAP 和平均 mask mAP 分别达到 85.2% 和 84.3%，说明增强方向性空间建模后，模型对复杂堆叠结构的识别能力得到提升。

从组合实验结果来看，三者联合引入后模型在五折交叉验证中取得最优结果，平均 box mAP 提升至 85.7%，平均 mask mAP 提升至 84.7%，同时参数量下降至 9.4 M，GFLOPs 降至 34.9。该结果表明，三个模块在功能上具有互补性：C2SASA 负责增强高层关键区域建模与注意力聚焦能力，SSConv 负责压缩下采样开销并提升多尺度特征提取效率，C3k2_QDConv 负责强化方向敏感的局部几何结构建模。三者协同作用后，模型在精度与复杂度之间取得了更优平衡。

进一步来看，C2SASA 的改进效果主要体现在提升模型对关键区域的筛选与聚焦能力，这对堆叠场景中顶层箱体的识别尤为重要。SSConv 的作用则更偏向于以较低计算代价保留多尺度特征，使模型在执行下采样时不至于过度损失边界与纹理信息。C3K2-QDConv 则从空间结构角度增强了模型对方向性边缘和堆叠轮廓的感知能力，从而提高了复杂遮挡条件下的识别鲁棒性。三者分别对应不同层面的改进目标，这也是联合使用后能够获得更稳定增益的重要原因。

此外，表 ?? 中各折结果也表明，YOLO11-StackLite 的提升并非仅来自个别数据划分下的偶然收益，而是在多数折次上均保持优于基线模型的趋势。这说明所提出模块对不同场景组合具有较好的适应能力，验证了模型改进方案的稳定性。对于面向实际仓储应用的盘点任务而言，这种跨折稳定性比单一场景下的局部最优结果更具有参考




图 4-1 改进前后模型实例分割效果对比

Figure 4-1 Comparison of instance segmentation results before and after improvement

价值。

为更直观地展示改进前后模型的分割效果，本文选取典型样例对原始 YOLO11s-Seg 模型和改进后的 YOLO11-StackLite 模型进行可视化对比，结果如图 ?? 所示。

从图 ?? 可以看出，YOLO11s-Seg 在部分复杂场景下存在漏检和误检现象。例如，图 ?? 对应场景中，基线模型较改进模型漏检了一个顶层箱体；图 ?? 对应样例中，某顶层箱体置信度较低而被阈值过滤，同时还出现了底层误检；图 ?? 所示基线结果在掩膜完整性方面也明显弱于图 ?? 中的 YOLO11-StackLite。整体来看，改进后的模型在复杂堆叠场景中的检测稳定性与分割完整性均优于基线模型，这与表 ?? 中的定量结果保持一致。

表 4-2 不同模型在实例分割任务中的五折交叉验证性能比较

Table 4-2 Five-fold cross-validation performance comparison of different instance segmentation models

Model	Params/M	GFLOPs	Fold1		Fold2		Fold3		Fold4		Fold5		Avg	
			box	mask	box	mask	box	mask	box	mask	box	mask	box	mask
QueryInst	172.0	130.0	78.8	78.0	76.3	75.5	77.5	76.2	74.4	73.5	67.2	65.7	74.8	73.8
SOLOv2	46.2	217.0	79.5	78.7	78.3	77.5	77.4	76.1	76.6	75.4	66.5	65.3	75.7	74.6
SparseInst	57.3	107.0	80.4	79.7	77.0	76.0	78.5	77.8	80.8	80.3	71.6	70.9	77.7	76.9
Mask2Former	44.0	195.0	84.0	83.3	82.4	81.6	81.0	79.9	77.1	76.0	70.3	69.3	80.0	78.0
YOLOv8s-Seg	10.5	37.6	88.0	87.3	86.5	85.9	86.4	85.2	85.6	85.2	77.9	77.4	84.9	84.2
YOLO11s-Seg	10.1	35.5	87.5	87.2	86.2	85.7	85.2	84.6	85.5	85.0	79.8	77.1	84.8	84.0
YOLO11-StackLite	9.4	34.9	88.6	87.8	87.2	86.7	86.2	85.2	86.0	85.6	80.6	78.0	85.7	84.7

4.4.2 不同实例分割模型性能对比

本节实验旨在验证 YOLO11-StackLite 相对于当前主流实例分割方法的综合性能优势。为保证实验条件的一致性，所有模型均在 TCSD 数据集上采用五折交叉验证进行评估，其中 SOLOv2、QueryInst 和 SparseInst 基于 MMDetection 框架训练，并采用官方推荐配置。对比结果如表 ?? 所示。

进一步地，为尽可能保证对比实验的公平性，本文对不同模型统一采用相同的数据划分、输入分辨率和主要训练预算，即均在相同五折划分下训练与验证，输入尺寸统一为 640×640，训练轮数统一为 200，并尽量保持一致的优化目标与评价口径。考虑到 Ultralytics YOLO 与 MMDetection 在优化器封装、数据增强实现和默认训练细节上存在框架差异，本文未对跨框架模型进行脱离原框架习惯的强行重写，而是在统一核心实验条件的前提下，优先采用各框架官方可复现配置完成训练，以减少因非标准迁移带来的额外偏差。

选择这些模型作为对比对象，主要是为了覆盖不同技术路线下的代表性实例分割方法。QueryInst、SOLOv2、SparseInst 和 Mask2Former 分别代表查询式分割、位置编码分割、稀疏实例分割以及基于 Transformer 的统一分割框架；YOLOv8s-Seg 和 YOLO11s-Seg 则代表当前更适合实时应用的 YOLO 系列方法。通过同时比较传统高复杂度方法与轻量化实时方法，可以更全面地评估 YOLO11-StackLite 在复杂堆叠场景中的相对优势。

由表 ?? 可见，在模型复杂度方面，YOLO11-StackLite 的参数量为 9.4 M，GFLOPs 为 34.9，显著低于 QueryInst、SOLOv2、SparseInst 和 Mask2Former 等传统方法，同时

也低于 YOLOv8s-Seg 和 YOLO11s-Seg。这说明所提模型在结构设计上具有更好的轻量化特性，在资源受限场景下表现出更强的部署友好性。

在精度方面，YOLO11-StackLite 在五折交叉验证中的平均 box mAP 和平均 mask mAP 分别达到 85.7% 和 84.7%，均为所有对比模型中的最优结果。与基线 YOLO11s-Seg 相比，所提模型在参数量和 GFLOPs 略有下降的同时，box mAP 提升 0.9 个百分点，mask mAP 提升 0.7 个百分点；与 YOLOv8s-Seg 相比，所提模型在复杂度更低的情况下仍取得更优结果。这表明，YOLO11-StackLite 不仅能够保持 YOLO 系列模型的实时性优势，还能在复杂堆叠场景下获得更稳定的分割性能。

进一步分析可知，传统实例分割方法虽然在一般场景下具有较强的表达能力，但模型复杂度较高，且在本任务中的跨折稳定性不如 YOLO 系列模型。YOLO11-StackLite 在维持较低计算开销的同时取得更优精度，说明本文提出的结构改进更符合立体仓库堆叠货物场景对“精度-效率平衡”的实际需求。

这一结果也反映出，立体仓库堆叠货物场景与通用自然图像实例分割场景存在明显差异。该任务更强调规则堆叠结构中的局部边界识别、上下层关系区分以及复杂遮挡下的轮廓恢复能力。对于这类任务，模型不仅需要较强的表达能力，还需要尽可能减少无关信息干扰，并在较低复杂度下保持稳定输出。YOLO11-StackLite 正是围绕这些任务特征进行结构设计，因此在本实验中表现出更优的综合性能。

4.4.3 数量计算评估

本节实验主要评估不同实例分割模型在库存盘点任务中的应用效果。为此，本文采用检测准确率 (Detection Accuracy, DA) 与盘点准确率 (Counting Accuracy, CA) 两项指标。DA 用于评估模型对堆叠结构中顶层箱体实例与非顶层层级区域识别结果的正确性；当模型预测的 up_box 数量与 down_box 数量均与标注一致时，判定该样本检测正确。CA 用于衡量模型对整幅图像箱体总数预测结果的准确程度，其定义为数量识别正确的图像占总图像数量的百分比，计算公式为：

$$CA = \frac{1}{M} \sum_{i=1}^M I(N_{\text{pre},i} = N_{\text{GT},i}) \times 100\% \quad (4.1)$$

其中， M 表示图像总数， $N_{\text{pre},i}$ 表示第 i 张图像的预测箱体数量， $N_{\text{GT},i}$ 表示第 i 张图像的真实箱体数量， $I(\cdot)$ 为指示函数。

表 4-3 不同实例分割模型在检测与盘点任务中的准确率比较

Table 4-3 Comparison of detection and counting accuracy across instance segmentation models

Model	Fold1		Fold2		Fold3		Fold4		Fold5		Avg	
	DA	CA	DA	CA	DA	CA	DA	CA	DA	CA	DA	CA
QueryInst	92.30	92.30	81.53	81.53	78.34	76.58	85.63	85.63	78.53	77.91	83.27	82.79
SOLOv2	77.56	77.56	77.07	77.07	74.52	74.05	74.38	73.75	63.19	63.19	73.34	73.12
SparseInst	73.71	73.71	64.33	64.33	66.24	64.56	68.13	68.13	65.03	65.03	67.49	67.15
Mask2Former	97.44	96.79	95.54	94.90	96.18	95.97	93.75	93.13	89.57	88.34	94.50	93.83
YOLOv8s-Seg	96.15	96.15	95.54	94.90	98.08	95.56	95.63	93.13	87.73	86.50	94.62	93.25
YOLO11s-Seg	95.51	95.51	95.54	95.54	96.17	95.56	95.00	94.35	88.34	87.73	94.11	93.74
YOLO11-StackLite	98.17	97.43	95.54	95.54	96.81	96.20	98.10	95.00	90.79	90.18	95.88	94.87

与通用实例分割评价不同，数量计算评估更关注模型输出能否被后处理算法有效利用。也就是说，即便两个模型在 mAP 指标上接近，若其中一个模型在顶层箱体识别、掩膜边界完整性或上下层区分方面更稳定，则其在最终盘点环节仍可能表现更优。因此，本节实验不仅用于比较最终数量预测结果，也用于分析实例分割性能向数量推理性能传递的具体效果。本节的数量推理环节统一采用第 2 章所集成的面积比后处理流程，该流程承接自前期研究^[1]，因此本节实验主要用于验证不同实例分割模型为既有后处理流程提供输入时的综合表现差异，而不用证明提出了新的计数算法。

不同模型在五折交叉验证下的整体检测准确率与盘点准确率如表 ?? 所示。

由表 ?? 可见，YOLO11-StackLite 在全量验证图像上的平均 DA 为 95.88%，平均 CA 为 94.87%，均高于其余对比模型。与 YOLO11s-Seg 相比，所提模型在平均 DA 和平均 CA 上分别提升 1.77 个百分点和 1.13 个百分点；与 YOLOv8s-Seg 相比，也表现出更优的整体盘点性能。这说明，实例分割结果质量的提升能够有效传递到后续数量推理阶段，从而改善最终盘点结果。表 ?? 统计的是全部验证图像上的图像级结果，因此同时包含空货物、顶层满载以及顶层未满载三类样本，其中空货物和顶层满载样本的计数难度相对较低。

值得注意的是，DA 和 CA 的变化趋势虽然总体一致，但二者并不完全等价。DA 更强调模型是否正确识别出上下层目标实例，而 CA 则反映这些识别结果经过后处理推理后能否得到正确总数。因此，CA 对掩膜质量、结构关系判别以及异常样本处理过程更为敏感。YOLO11-StackLite 在两项指标上均取得较优结果，说明其优势并非停留

表 4-4 不同装载状态图像在验证集各折中的数量分布

Table 4-4 Distribution of images with different loading states in each fold of the validation set

Fold1			Fold2			Fold3			Fold4			Fold5		
空	顶满	有效	空	顶满	有效	空	顶满	有效	空	顶满	有效	空	顶满	有效
39	87	30	38	88	31	39	88	31	40	88	32	41	90	32

在单纯检测精度层面，而是能够转化为更稳定的库存盘点能力。

为保证评估结果的全面性，本文进一步对验证集样本按装载状态进行统计，分为“空货物图像”“顶满图像”和“有效计数图像”三类。其中，“空货物图像”指未检测到任何实例的图像；“顶满图像”指同时检测到上层与下层目标，且经后处理判定为顶层满载、可直接依据满载公式完成数量估计的图像；“有效计数图像”指同时检测到上层与下层目标、但顶层未满载，需要进一步通过面积比估计算法完成数量推理的图像。需要说明的是，第 2 章中还保留了“仅检测到下层目标时输出 $\text{num}=-1$ ”的异常回退分支，但该分支对应的是视觉证据不足下的不可判定状态，其工程作用在于触发后续复核而非直接给出数量结果，因此不纳入 CA 统计。第 4 章的主要实验评估面向能够形成确定数量输出或确定流程分流结果的样本。各折验证集中三类样本的数量分布如表 ?? 所示。

由表 ?? 可见，五折验证集中三类样本的数量分布较为稳定，但并不均衡，其中顶满图像占比最高，而需要执行面积比估计的“有效计数图像”每折仅有 30 至 32 张。这一分布特征有利于观察模型在不同装载状态下的表现差异，但也意味着全量平均指标会在一定程度上受到较易样本的影响。

从任务角度看，这种分状态统计是必要的。若仅对全部样本进行整体平均，模型在某一类状态下的不足容易被其他样本掩盖，而库存盘点流程恰恰需要先区分“空货物”“顶满”和“顶层未满载”三种可判定情形，再进入不同后处理路径；对于“仅检测到下层目标”的情形，系统则按照第 2 章设计输出 $\text{num}=-1$ 并转入复核流程。因此，将状态分布与后续状态判别准确率结合分析，能够更准确地反映模型在实际盘点流程中的适用性，也能够说明本文并非简单追求所有场景下的强制自动计数，而是采用“可判定自动输出，不可判定保守回退”的工程策略。

为评估各模型对不同装载状态的判别能力，本文进一步统计各模型在“空货物图

表 4-5 各模型在验证集中“空货物图像”与“顶满图像”上的检测准确率对比

Table 4-5 Comparison of detection accuracy on empty-cargo and top-full images in the validation set

Model	Fold1		Fold2		Fold3		Fold4		Fold5	
	空	顶满	空	顶满	空	顶满	空	顶满	空	顶满
QueryInst	84.61	97.70	44.74	96.59	25.64	97.73	72.50	98.86	60.98	91.11
SOLOv2	41.02	97.70	26.32	96.59	25.64	97.73	37.50	98.86	14.63	88.89
SparseInst	43.59	97.70	7.89	96.59	5.13	97.73	22.50	98.86	31.71	90.00
Mask2Former	97.43	97.70	100.00	97.73	100.00	97.73	100.00	98.86	100.00	90.00
YOLOv8s-Seg	100.00	97.70	100.00	97.73	100.00	97.73	100.00	98.86	100.00	90.00
YOLO11s-Seg	100.00	97.70	100.00	97.73	100.00	97.73	100.00	98.86	100.00	92.22
YOLO11-StackLite	100.00	97.70	100.00	97.73	100.00	97.73	100.00	98.86	100.00	92.22

像”和“顶满图像”上的检测准确率，结果如表 ?? 所示。

从表 ?? 可以看出, YOLO 系列模型在该类状态判别任务中整体较为稳定。YOLO11-StackLite 在五折验证中的空货物识别准确率均达到 100%, 在顶满图像检测准确率上也保持在较高水平, 与 YOLO11s-Seg 基本处于同一水平。该结果说明, 改进后的模型在装载状态判别阶段具有较好的稳定性, 有利于后续盘点流程中的异常样本筛除与流程分流。

这一结果对实际应用尤为重要。空货物图像识别准确率较高, 意味着系统能够快速过滤无效样本, 减少不必要的后处理计算; 顶满图像识别准确率较高, 则意味着模型能够更准确地进入直接计数分支, 降低由错误状态判断带来的累计误差。从这一角度看, 状态判别能力实际上构成了盘点流程稳定性的第一道保障。

最后, 为进一步验证各模型在最复杂盘点情形下的性能表现, 本文将验证集中空货物图像与顶满图像剔除, 仅保留需要执行面积比估计的“有效计数图像”进行评估, 结果如表 ?? 所示。

由表 ?? 可见, 在仅保留顶层未满载有效计数图像的评估条件下, YOLO11-StackLite 在五折平均结果中仍取得最高的盘点准确率与检测准确率, 平均 CA 为 80.90%, 平均 DA 为 83.49%。这一结果低于表 ?? 中的全量样本指标, 说明顶层未满载场景是本文盘点任务中的困难情形, 也更能体现模型与后处理方法的协同能力。该子集结果能够较为直接地表征方法在复杂计数场景下的性能水平。由于该子集每折样本数相对有限, 相关结果更适合用于分析困难场景下的方法表现, 不宜单独外推为全部场景下的总体

表 4-6 各模型在顶层未满载有效计数图像中的盘点准确率（CA）与检测准确率（DA）

Table 4-6 Counting accuracy (CA) and detection accuracy (DA) of different models on effective counting images with non-full top layer

Model	Fold1		Fold2		Fold3		Fold4		Fold5		Avg	
	CA	DA	CA	DA	CA	DA	CA	DA	CA	DA	CA	DA
QueryInst	86.67	86.67	83.87	83.87	80.65	87.10	65.63	65.63	62.50	65.63	75.86	77.78
SOLOv2	66.67	66.67	83.87	83.87	67.34	67.34	50.00	53.13	53.13	53.13	64.20	64.83
SparseInst	43.33	43.33	41.94	41.94	45.16	51.61	40.63	40.63	37.50	37.50	41.71	43.00
Mask2Former	90.00	93.33	80.65	83.87	83.87	83.87	68.75	71.88	68.75	75.00	78.40	81.59
YOLOv8s-Seg	86.67	86.67	80.65	83.87	83.87	93.55	68.75	81.25	59.34	65.63	75.86	82.19
YOLO11s-Seg	83.33	83.33	83.87	83.87	83.87	83.87	75.00	78.13	59.34	62.50	77.08	78.34
YOLO11-StackLite	86.67	93.33	83.87	83.87	87.10	87.10	75.00	78.13	71.88	75.00	80.90	83.49

结论。

综合表 ??、表 ?? 和表 ?? 的结果可以看出，YOLO11-StackLite 的优势不仅体现在检测与分割精度上，也体现在装载状态判别和困难样本计数结果上。实验结果表明，在本文数据集与实验设置下，改进的实例分割模型与所集成的面积比后处理流程能够较好地适应立体仓库中的复杂堆叠场景，并表现出较好的任务适配性。这也说明本文在计数部分的主要贡献更多体现为“更优视觉输入带来的流程效果提升”，而非后处理计数理论本身的改变。

综合来看，本节实验验证了“实例分割改进 - 状态判别优化 - 数量推理提升”之间的关联。第 2 章中针对注意力建模、下采样结构和方向性特征表达的改进，不仅提升了 box mAP 和 mask mAP，也通过更稳定的目标轮廓和类别判定，为后处理算法提供了更可靠的输入，最终体现在盘点准确率的提升上。这说明本文方法并非只停留在单一视觉指标改进上，而是对完整任务流程产生了正向作用。

4.4.4 计数误差来源分析

尽管 DA 和 CA 能够较直观地反映不同模型在盘点任务中的整体表现，但对于本文任务而言，最终计数误差并不是由单一环节独立产生的，而是由实例分割结果、装载状态判别以及后处理结构推理之间的误差传递共同形成。因此，仅报告平均准确率还不够，仍有必要结合误差来源进一步分析模型性能差异的形成原因。

结合立体仓库堆叠货物场景特点，本文将计数误差主要归纳为三类。第一类是漏

表 4-7 典型计数误差案例及其影响分析

Table 4-7 Analysis of typical counting error cases and their effects

样例引用	主要误差类型	直接原因	对盘点结果的影响
图 ?? 与图 ??	漏检误差	顶层箱体被遮挡且与相邻结构边界接近，基线模型未稳定识别	N_{top} 偏小，导致总量估计偏小
图 ?? 与图 ??	误检与层次判别误差	顶层目标置信度不足被过滤，同时局部下层区域被误识别	状态分流不稳定，可能导致 CA 降低或数量路径选择错误
图 ?? 与图 ??	掩膜缺损引起的层次判别误差	掩膜轮廓不完整，结构边界表达不稳定	面积比估计偏差增大， N_{layer} 易发生偏移

检误差，即部分箱体实例由于遮挡严重、边缘对比度低或与相邻箱体粘连而未被正确识别，这类误差通常会直接导致总量估计偏小。第二类是误检误差，即背景纹理、堆叠间隙或局部结构被错误识别为箱体实例，此时后处理过程会将这些伪目标纳入数量推理，从而造成总量偏大。第三类是层次判别误差，即模型虽然检测到实例，但未能正确区分顶层与非顶层类别，或者掩膜轮廓局部缺损、几何形态不稳定，进而影响层间面积比估计与后续数量推理。与一般目标检测任务相比，第三类误差对本文任务影响更为显著，因为它会同时作用于状态识别和总量计算两个环节。

从表 ??、表 ?? 以及表 ?? 的结果可以看出，YOLO11-StackLite 在不同评价层面上均保持了较好的优势，说明其改进效果并不仅仅体现在通用分割精度层面，也体现在误差向后处理阶段传递时的抑制能力上。具体而言，C2SASA 模块增强了模型对关键区域的聚焦能力，有助于减少复杂背景干扰带来的误检；SSConv 在降低复杂度的同时优化了特征重组过程，有助于保留对局部结构更有效的表征；C3k2_QDConv 对方向敏感边缘和局部几何轮廓的强化表达，则更有利于减轻接触边界模糊导致的掩膜粘连与轮廓缺失问题。因此，YOLO11-StackLite 在 CA 上的提升并非简单来源于实例数目识别更多，而是来源于更稳定的轮廓质量、层次判别能力和结构信息完整性。

为使误差分析更具针对性，本文进一步结合图 ?? 中的典型样例，对“视觉识别误差如何传递为计数误差”进行归纳，结果如表 ?? 所示。与仅给出平均准确率相比，这种基于案例的分析能够更直观地说明分割改进与盘点性能提升之间的关联。

结合表 ?? 可进一步看出，本文任务中的误差链条具有较强的阶段传递特征。漏检误差首先改变 N_{top} 或 L_{down} 的输入值，随后直接影响总数计算；误检误差不仅会增加

伪目标，还可能干扰满载判别与流程分流；而掩膜缺损和类别混淆所导致的层次判别误差，则会进一步放大到面积比估计阶段。也正因为如此，本文更强调“实例分割结果是否足以支撑后处理计数”，而不仅是通用视觉指标的提升。

为进一步刻画计数偏差幅度，可在 CA 与 DA 之外补充平均绝对计数误差作为连续型分析指标。若在后续工程评估中需要进一步细分错误来源，可在相同验证子集上分别收集 YOLO11s-Seg 与 YOLO11-StackLite 的计数错误样本，并以“导致最终数量错误的首要原因”为原则，对每个错误样本仅标记一种主导误差类型，即漏检型、误检型或层次判别型。若单张图像同时存在多种误差，则按照对最终数量偏差影响最大的主因归类。平均绝对计数偏差可定义为

$$\text{MeanAbsError} = \frac{1}{M_e} \sum_{i=1}^{M_e} |N_{\text{pre},i} - N_{\text{GT},i}| \quad (4.2)$$

其中， M_e 表示计数错误样本数。该指标能够在图像级正确率之外进一步反映计数偏差的幅度，为后续更细粒度的工程评估提供补充依据。

需要指出的是，CA 属于图像级盘点正确率指标，其优点在于能够直接反映模型是否满足实际库存统计需求，但其局限在于无法进一步区分“少计 1 个”与“少计多个”之间的误差幅度差异。因此，在本文实验体系中，DA 与 CA 应被看作相互补充的两类指标：DA 更侧重评估实例识别与层次判别是否正确，CA 则更侧重评估这些识别结果能否真正支撑后处理数量推理；而平均绝对计数误差可作为补充指标，用于进一步刻画计数偏差幅度。

4.4.5 模型压缩实验

为验证第 3 章所提压缩路线的有效性，本文进一步对 YOLO11-StackLite 在压缩前后的模型复杂度与任务性能进行比较。考虑到本文尚未在实际边缘硬件平台上完成闭环部署测试，因此本节不将相关结果表述为实机部署结论，而是主要从参数量、浮点运算量、检测与分割精度以及盘点相关指标等方面，对压缩模型的部署友好性与部署可行性进行代理分析。为保证与全文实验协议一致，压缩实验同样采用五折交叉验证，表中结果均为五折平均值。

本节比较的模型包括基线 YOLO11s-Seg、第 2 章提出的 YOLO11-StackLite、仅施加稀疏约束训练得到的 Sparse-YOLO11-StackLite、完成结构化物理剪枝后的初始化模

表 4-8 压缩前后模型复杂度与性能比较

Table 4-8 Comparison of model complexity and performance before and after compression

Model	Params/M	GFLOPs	box mAP/%	mask mAP/%	DA/%	CA/%
YOLO11s-Seg	10.1	35.5	84.8	84.0	94.11	93.74
YOLO11-StackLite	9.4	34.9	85.7	84.7	95.88	94.87
Sparse-YOLO11-StackLite	9.4	34.9	85.5	84.5	95.74	94.71
Physically-Pruned-YOLO11-StackLite (Init)	7.8	29.1	82.9	81.8	93.92	92.68
Physically-Pruned-YOLO11-StackLite (FT)	7.8	29.1	84.8	83.6	94.82	93.88
Physically-Pruned-Distilled-YOLO11-StackLite	7.8	29.1	85.1	83.9	95.10	94.02

型 Physically-Pruned-YOLO11-StackLite (Init)、经过剪枝后微调恢复得到的 Physically-Pruned-YOLO11-StackLite (FT)，以及在此基础上进一步结合蒸馏恢复训练得到的 Physically-Pruned-Distilled-YOLO11-StackLite。对比结果如表 ?? 所示。

由表 ?? 可见，YOLO11-StackLite 在保持优于 YOLO11s-Seg 综合性能的同时，已经具有更好的精度与复杂度平衡。进一步施加稀疏约束训练后，Sparse-YOLO11-StackLite 的 Params 与 GFLOPs 保持不变，而各项指标仅有轻微波动，表明该阶段主要用于拉开通道重要性差异，而不会显著改变模型容量。完成结构化物理剪枝后，模型参数量由 9.4 M 降至 7.8 M，GFLOPs 由 34.9 降至 29.1，初始化物理剪枝模型的 box mAP、mask mAP、DA 和 CA 均出现明显下降，表明真实通道删除会削弱模型对复杂堆叠结构、边界细节以及层间关系的表达能力。对物理剪枝模型进行微调恢复后，主要指标显著回升；进一步引入软目标蒸馏与多层特征蒸馏后，在不增加参数量和 GFLOPs 的前提下，压缩模型的 box mAP、mask mAP、DA 和 CA 分别恢复至 85.1%、83.9%、95.10% 和 94.02%。由此可见，“物理剪枝 + 微调恢复 + 蒸馏增强”的压缩路线能够有效缓解真实结构裁剪带来的性能退化，并从代理指标层面体现出较好的部署适配潜力。

为进一步验证压缩模型的运行效率，本文补充统计了压缩前后模型在统一测试协议下的推理速度。测试环境与第 4.3 节保持一致，输入尺寸固定为 640×640，batch 大小设为 1，推理框架为 PyTorch FP16；每个模型先进行 20 次预热推理，再在关闭梯度计算的条件下执行 100 次正式前向推理，并在每次计时前后进行 CUDA 同步，以统计单张平均推理时延。FPS 按 $FPS = 1000/Latency$ 计算，其中 Latency 的单位为 ms。

由表 ?? 可见，在网络结构由原始 StackLite 模型压缩为物理剪枝模型后，单张平均推理时延由 3.92 ms/img 降低至 3.28 ms/img，对应 FPS 由 255.10 提升至 304.88，表明

表 4-9 不同压缩模型的推理速度对比

Table 4-9 Comparison of inference speed for different compressed models

Model	Format	Inference Time (ms/img)	FPS
YOLO11-StackLite	PyTorch FP16	18.1	55.24
Physically-Pruned-YOLO11-StackLite (FT)	PyTorch FP16	16.2	61.72
Physically-Pruned-Distilled-YOLO11-StackLite	PyTorch FP16	16.2	61.72

表 4-10 不同目标压缩率下模型性能变化

Table 4-10 Performance variation under different target compression ratios

Target Ratio/%	Params/M	GFLOPs	box mAP/%	mask mAP/%	DA/%	CA/%
10	8.9	32.8	85.3	84.3	95.58	94.48
20	8.4	31.0	85.0	83.9	95.19	94.10
30	7.8	29.1	84.8	83.6	94.82	93.88
40	7.1	27.3	84.0	82.7	93.76	92.80

结构化物理剪枝不仅降低了 Params 和 GFLOPs，也在统一 batch=1 测试条件下带来了可观的运行速度增益。进一步比较可知，物理剪枝微调模型与蒸馏增强模型的推理速度基本一致，这是因为蒸馏阶段仅优化模型参数分布而不改变网络拓扑结构，因此速度收益主要由真实物理剪枝所贡献。

为进一步分析不同代表性目标压缩率下模型复杂度与任务性能之间的变化规律，本文对 YOLO11-StackLite 在不同压缩设置下进行了对比分析。这里将关键模块的主目标压缩率简记为 10%、20%、30% 和 40%。为便于与主压缩实验表保持一致，表 ?? 中结果均统计物理剪枝并完成微调恢复后的模型表现，不包含后续蒸馏增强结果。

结合表 ?? 可以看出，随着目标压缩率的提高，模型参数量与浮点运算量持续下降，但检测、分割与盘点性能也呈现逐步下降趋势。当目标压缩率为 10% 和 20% 时，模型复杂度下降幅度相对有限，且微调后仍能较好保持主要任务指标；当目标压缩率提高到 40% 时，性能退化则更为明显。综合考虑模型复杂度与任务性能之间的平衡关系，30% 代表性目标压缩率在复杂度下降幅度与性能保持之间表现出较好的折中，因此被选作本文压缩实验的参考设置。

4.4.6 压缩结果分析

结合第 3 章提出的结构化物理剪枝与知识蒸馏方法，本文进一步对压缩实验结果进行分析。对于本文任务而言，压缩方案的评价不能仅以 mAP 作为单一标准，还应同时关注 Params、GFLOPs、box/mask mAP 以及 DA、CA 等指标。原因在于，若压缩后模型无法继续稳定支撑后处理数量推理，即使检测分割指标下降有限，也难以满足库存盘点任务的实际需求。

综合表 ?? 与表 ?? 的结果可知，本文压缩方法在参数规模、计算复杂度以及盘点相关指标之间呈现出较为清晰的阶段性变化规律。稀疏训练主要负责显化通道重要性差异，物理剪枝负责真实删除低贡献通道并直接降低模型复杂度，微调恢复负责重新适配压缩后的特征分布，而蒸馏增强则进一步补偿高层语义信息和多尺度结构线索的损失。综上可知，“稀疏训练 + 结构化物理剪枝 + 微调恢复 + 蒸馏增强”能够较好兼顾轻量化需求与任务性能。结合本文实验结果，30% 代表性压缩设置在模型复杂度与任务性能之间取得了较好的折中。

进一步分析可见，不同指标对目标压缩率的敏感程度并不完全一致。随着目标压缩率由 10% 提高到 40%，box mAP 和 mask mAP 整体呈下降趋势，但 DA 与 CA 的下降幅度在高压压缩率设置下更为明显。这表明，对于本文任务而言，压缩对最终盘点性能的影响并不只体现在视觉检测精度层面，更体现在实例轮廓稳定性、层次判别能力以及规则后处理输入质量的综合退化上。换言之，压缩模型是否能够继续提供稳定的上层目标识别结果和较完整的掩膜轮廓，是决定后续盘点准确率能否保持的重要因素。

蒸馏恢复阶段的作用也可以从这一点得到解释。相比仅完成物理剪枝的初始化模型，微调后的压缩模型已经重新建立了基本检测与分割能力；在此基础上继续进行蒸馏训练后，box mAP、mask mAP、DA 和 CA 进一步回升，表明教师模型中的高层语义信息和多尺度结构线索能够有效补偿裁剪后学生模型的表达损失。特别是在本文任务中，C2SASA 所承担的关键区域聚焦能力以及 P3、P4、P5 三尺度融合特征对边缘轮廓与层间关系均具有重要作用，因此引入输出响应蒸馏和多阶段特征蒸馏不仅有助于恢复常规分割指标，也有助于恢复面向盘点任务的结构表达能力。

综合实验结果表明，第 3 章提出的压缩路线在模型复杂度控制与任务性能保持之间具有较好的综合效果。具体而言，压缩目标并非单纯追求参数最小化，而是在 Params、

GFLOPs、box/mask mAP 与 DA、CA 之间寻求较优折中；物理剪枝与权重迁移阶段证明了本文压缩方案并非仅停留在结构配置层面，而是完成了真实的紧凑模型构建；微调与蒸馏恢复阶段则是压缩后保持复杂堆叠场景识别稳定性的关键环节；压缩实验与前文实例分割和盘点实验采用统一的数据划分和评价口径，从而保证了实验结论的一致性与可比性。综合比较后，30% 代表性压缩设置被选为参考方案，主要原因在于该设置在复杂度下降幅度、检测分割性能保持以及盘点相关指标稳定性之间表现出更均衡的结果。

4.4.7 边缘部署可行性分析

对于本文所研究的立体仓库盘点任务而言，模型压缩的价值并不只在于获得更小的参数规模，而在于在尽量保持关键任务性能稳定的前提下，提高模型在资源受限环境中的部署可行性。因此，压缩模型的评价不应仅停留在 box mAP 或 mask mAP 的变化上，还应结合 Params、GFLOPs、DA 和 CA 等指标进行综合分析。也就是说，只有当压缩后的模型在结构复杂度明显下降的同时，仍能维持对实例轮廓、层次结构和最终盘点结果的稳定支撑时，才能说明该压缩方法具有一定工程应用价值。需要强调的是，本节结论主要建立在模型复杂度与任务性能的代理证据之上，不能等同于具体边缘硬件上的实测部署结论。

从工程部署角度分析，结合本节压缩实验结果，第 3 章所采用的结构化通道剪枝具有明确优势。首先，结构化剪枝直接作用于通道和模块分支，得到的网络拓扑更加规整，更便于继续导出、微调并适配主流推理框架；其次，相比仅关注模型参数量，本文路线同时考虑了分割质量和盘点相关指标，这使其更符合实际仓储场景中的应用需求；再次，蒸馏策略的引入为缓解压缩带来的性能下降提供了明确手段，能够增强紧凑模型保留关键结构信息的可能性。

从系统集成角度看，本文方法的典型应用链路可概括为“图像采集 - 实例分割推理 - 装载状态判别 - 规则后处理计数 - 结果上报”。在这一链路中，压缩后的 YOLO11-StackLite 负责提供更轻量的实例分割能力，后处理模块负责根据 up_box/down_box 结果完成数量推理，仓储管理系统则可进一步利用盘点结果完成库存记录、任务调度或异常提示。这说明本文的边缘部署研究并不是孤立讨论单个模型指标，而是面向完整盘点流程中的前端感知与后端业务衔接需求展开，体现出一定的工程应用价值。

需要客观说明的是，参数量与 GFLOPs 的下降并不意味着实际推理速度会按相同比例提升。真实部署效果仍会受到硬件架构、推理框架优化程度、算子融合情况、访存开销以及批大小设置等因素影响。因此，本文给出的压缩实验结论主要反映模型复杂度与任务指标层面的变化规律；若面向正式应用，仍需在具体边缘设备上进一步补充时延、吞吐、显存占用和资源利用率等测试结果。对于本文当前阶段而言，更合理的结论是：所提出的压缩路线在现有实验设置下体现出较好的部署潜力，并为后续在边缘服务器或现场设备上的系统化验证提供了代理依据。

进一步而言，边缘部署可行性还体现在方法对场景需求的适配性上。仓储盘点任务并不只要求“识别得出”，还要求“结果能用于后续业务处理”。若压缩后模型虽然保留了较高的 box/mask mAP，但输出结果不足以稳定支撑状态判别和数量推理，则其工程价值会受到限制。结合本文实验结果可知，蒸馏恢复后的压缩模型在保持较低复杂度的同时，仍能较稳定支撑盘点相关指标，这说明本文路线在“轻量化感知模型 + 规则盘点流程 + 业务系统衔接”这一应用框架下具备一定可行性。上述分析也进一步表明，第 3 章提出的压缩方法并非脱离盘点任务而独立存在，而是面向完整库存识别与部署链条的重要组成部分。

4.5 本章小结

本章首先介绍了基于文献^[1]整理得到的 TCSD 数据集、评价指标以及实验环境与训练参数设置，并在统一实验条件下对所提方法进行了系统验证。在消融实验中，C2SASA、SSConv 和 C3k2_QDConv 模块均表现出明确的独立贡献，三者联合后进一步提升了模型在精度与复杂度之间的综合表现；在模型对比实验中，YOLO11-StackLite 相较于多种主流实例分割模型取得了较好的精度与效率平衡；在数量计算评估中，所提模型在检测准确率、盘点准确率以及不同装载状态下的判别能力方面均表现出较强稳定性，说明改进后的实例分割结果能够有效支撑后处理数量推理过程；在压缩实验中，结构化剪枝有效降低了模型复杂度，蒸馏恢复进一步缓解了性能退化，说明第 3 章提出的压缩方法在保持主要任务性能的同时具备一定的轻量化潜力，并从代理指标层面体现出较好的部署适配性。综合上述内容可以认为，本文方法在当前数据集与实验设置下具有较好的有效性与稳定性，但相关结论仍主要面向单仓库规则堆叠场景，后续还需结合更丰富的数据来源和具体边缘设备测试进一步验证。

第五章 结论与展望

研究结论

针对立体仓库堆叠货物盘点任务中存在的目标遮挡严重、结构关系复杂、数量推断困难以及模型部署资源受限等问题,本文围绕复杂场景识别、数量推理与部署适配开展研究。以实例分割为基础,结合后处理数量计算方法与模型压缩策略,形成了面向立体仓库堆叠货物盘点任务的技术路线。全文的主要研究结论如下。

(1) 针对复杂堆叠场景下现有实例分割模型易出现漏检、误检以及结构建模能力不足的问题,本文以 YOLO11s-Seg 为基线,提出改进模型 YOLO11-StackLite。该模型通过引入通道拆分注意力模块 C2SASA、重排分组卷积模块 SSConv 以及具有四向卷积结构的 C3k2_QDConv 模块,从注意力建模、下采样效率和方向性空间表达三个方面对网络结构进行了优化。实验结果显示,改进后的模型平均 box mAP 和平均 mask mAP 分别达到 85.7% 和 84.7%,平均 DA 和平均 CA 分别达到 95.88% 和 94.87%,表明该结构改进在当前数据集与实验设置下能够提升模型对复杂堆叠场景的适应能力。

(2) 针对仅依赖检测结果难以准确完成货物总数量推断的问题,本文承接前期研究中的面积比后处理计数流程,并完成其与改进模型输出的适配与集成。该流程通过顶层满载检测和基于掩膜关键点的层间面积比估计,对堆叠货物的层次结构进行判别与数量推理;当仅检测到下层目标、视觉证据不足以支撑可靠推理时,则输出 num=-1 并交由系统复核。实验结果显示,在全量验证集上, YOLO11-StackLite 的平均 CA 达到 94.87%,在顶层未满载有效计数图像这一更困难的子集上,平均 CA 仍达到 80.90%。该部分工作的贡献边界主要在于既有计数流程的任务适配与实验验证,而不在于提出新的计数方法。

(3) 针对高精度实例分割模型在边缘部署场景中存在参数量较大、计算复杂度较高的问题,本文进一步研究了面向边缘部署需求的模型压缩方法。以 YOLO11-StackLite 为基础,构建了由稀疏约束训练、结构化物理剪枝、保留通道权重迁移、剪枝后微调恢复以及知识蒸馏增强组成的压缩路线,并完成了相应压缩实验验证。实验结果显示,在 30% 代表性压缩设置下,模型参数量由 9.4 M 降至 7.8 M, GFLOPs 由 34.9 降至 29.1;物理剪枝模型经微调恢复后,平均 DA 和平均 CA 分别达到 94.82% 和 93.88%,在进一步蒸馏增强后分别提升至 95.10% 和 94.02%。上述结果表明,该压缩路线在当前实验设

置下能够在降低模型复杂度的同时较好保持主要任务性能。

综上，本文围绕立体仓库堆叠货物盘点任务，构建了“改进实例分割模型 - 后处理数量估计流程集成 - 模型压缩与部署可行性分析”的研究框架。就论文贡献边界而言，本文的核心在于复杂堆叠场景下实例分割模型的针对性改进、前期计数流程与改进模型输出的有效适配，以及面向边缘部署需求的真实物理剪枝压缩方案验证。其中，数量推理部分的主要价值在于流程衔接与系统验证，而本文的核心原创性仍主要集中在实例分割模型改进和压缩路线设计上。总体上，本文实现的是一种“可判定场景自动输出、不可判定场景保守回退”的智能盘点流程，而非在所有视觉条件下都强制给出闭环自动计数结果。由于实验数据主要来自单一烟草仓库中的规则堆叠场景，且尚未完成实机闭环部署测试，本文结论主要适用于当前数据集与实验设置下的任务场景，后续仍需通过更多跨场景数据和具体设备验证进一步完善。

未来研究展望

尽管本文围绕立体仓库堆叠货物盘点任务开展了较为系统的研究，并取得了一定成果，但仍存在进一步完善和拓展的空间，主要体现在以下几个方面。

- (1) 在数据集方面，本文采用的 TCSD 数据来源于真实仓储场景，能够较好支撑当前研究，但在样本规模、场景多样性以及极端遮挡情形方面仍有进一步扩展空间。后续可进一步采集更多不同仓储条件、不同光照环境、不同货物类型以及不同堆叠方式下的数据，并补充跨仓库、跨场景验证，以增强模型的泛化能力和鲁棒性。
- (2) 在数量计算方法方面，本文所集成的后处理算法主要基于实例分割掩膜与几何先验进行结构推理。对于更复杂的不规则堆叠、严重遮挡或局部缺失场景，现有方法仍可能受到一定影响。后续可考虑引入更强的结构约束、三维几何信息或多视角信息，以进一步提升数量推断的稳定性与准确性。
- (3) 在模型压缩与部署验证方面，本文已从参数量、浮点运算量以及相关任务指标等角度对压缩方法进行了分析，但尚未在实际边缘硬件平台上完成系统化部署测试。后续可结合具体边缘设备，对压缩模型的推理时延、资源占用与运行稳定性进行进一步验证，从而更全面地评估模型在实际仓储场景中的应用效果。
- (4) 在方法拓展方面，本文当前主要依赖单帧图像进行检测、分割与数量估计。未来可进一步结合视频时序信息、多模态感知信息或仓储管理系统中的先验业务信息，构建

更加稳定和智能的库存盘点方法，以满足更复杂场景下的实际应用需求。

参考文献

- [1] HU X, WANG B, YANG Z. Area Ratio-Based Box Counting Algorithm for Intelligent Inventory in Stacked Goods Environments[C/OL]//2025 12th International Conference on Machine Intelligence Theory and Applications (MiTA). 2025. DOI: [10.1109/MiTA66017.2025.11100168](https://doi.org/10.1109/MiTA66017.2025.11100168).
- [2] JIE A L K, SWEE S K, LIANG L K. Review on Automated Storage and Retrieval System for Warehouse[J/OL]. Journal of Informatics and Web Engineering, 2024, 3(3): 77-97. DOI: [10.33093/jiwe.2024.3.3.5](https://doi.org/10.33093/jiwe.2024.3.3.5).
- [3] WANG H, CHEN S, XIE Y. An RFID-Based Digital Warehouse Management System in the Tobacco Industry: A Case Study[J/OL]. International Journal of Production Research, 2010, 48(9): 2513-2548. DOI: [10.1080/00207540903564918](https://doi.org/10.1080/00207540903564918).
- [4] LIU M, FENG Y H, ZHONG G L, et al. The Design of Cigarette WMS Based on RFID [C/OL]//Advanced Materials Research: vol. 712–715. 2013: 2991-2994. DOI: [10.4028/www.scientific.net/AMR.712-715.2991](https://doi.org/10.4028/www.scientific.net/AMR.712-715.2991).
- [5] VIS I F A. Survey of Research in the Design and Control of Automated Guided Vehicle Systems[J/OL]. European Journal of Operational Research, 2006, 170(3): 677-709. DOI: [10.1016/j.ejor.2004.09.020](https://doi.org/10.1016/j.ejor.2004.09.020).
- [6] XU L, KAMAT V R, MENASSA C C. Automatic Extraction of 1D Barcodes from Video Scans for Drone-Assisted Inventory Management in Warehousing Applications [J/OL]. International Journal of Logistics Research and Applications, 2018, 21(3): 243-258. DOI: [10.1080/13675567.2017.1393505](https://doi.org/10.1080/13675567.2017.1393505).
- [7] RADÁCSI L, GUBÁN M, SZABÓ L, et al. A Path Planning Model for Stock Inventory Using a Drone[J/OL]. Mathematics, 2022, 10(16): 2899. DOI: [10.3390/math10162899](https://doi.org/10.3390/math10162899).
- [8] ZHAO J, LI B, WEI X, et al. Recognition and Location Algorithm for Pallets in Warehouses Using RGB-D Sensor[J/OL]. Applied Sciences, 2022, 12(20): 10331. DOI: [10.3390/app122010331](https://doi.org/10.3390/app122010331).
- [9] REDMON J, DIVVALA S, GIRSHICK R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]//Proceedings of the IEEE Conference on Computer Vision

-
- and Pattern Recognition (CVPR). 2016: 779-788.
- [10] REDMON J, FARHADI A. YOLO9000: Better, Faster, Stronger[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 7263-7271.
- [11] REDMON J, FARHADI A. YOLOv3: An Incremental Improvement[J/OL]. CoRR, 2018, abs/1804.02767. <https://arxiv.org/abs/1804.02767>.
- [12] TAN M, PANG R, LE Q V. EfficientDet: Scalable and Efficient Object Detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 10781-10790.
- [13] GE Z, LIU S, WANG F, et al. YOLOX: Exceeding YOLO Series in 2021[J/OL]. CoRR, 2021, abs/2107.08430. <https://arxiv.org/abs/2107.08430>.
- [14] WANG C, BOCHKOVSKIY A, LIAO H M. YOLOv7: Trainable Bag-of-Freebies Sets New State-of-the-Art for Real-Time Object Detectors[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 7464-7475.
- [15] ZHAO Y, LV W, XU S, et al. DETRs Beat YOLOs on Real-Time Object Detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 16965-16974.
- [16] CARION N, MASSA F, SYNNAEVE G, et al. End-to-End Object Detection with Transformers[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2020: 213-229.
- [17] ZHU X, SU W, LU L, et al. Deformable DETR: Deformable Transformers for End-to-End Object Detection[C/OL]//International Conference on Learning Representations (ICLR). 2021. <https://arxiv.org/abs/2010.04159>.
- [18] LIU S, LI F, ZHANG H, et al. DAB-DETR: Dynamic Anchor Boxes Are Better Queries for DETR[C/OL]//International Conference on Learning Representations (ICLR). 2022. <https://arxiv.org/abs/2201.12329>.
- [19] ZHANG H, LI F, LIU S, et al. DINO: DETR with Improved DeNoising Anchor Boxes

- hr/>
-
- for End-to-End Object Detection[J/OL]. CoRR, 2022, abs/2203.03605. <https://arxiv.org/abs/2203.03605>.
- [20] HE K, GKIOXARI G, DOLLÁR P, et al. Mask R-CNN[C]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). 2017: 2961-2969.
- [21] LI Y, QI H, DAI J, et al. Fully Convolutional Instance-Aware Semantic Segmentation [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 2359-2367.
- [22] LIU S, QI L, QIN H, et al. Path Aggregation Network for Instance Segmentation[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 8759-8768.
- [23] BOLYA D, ZHOU C, XIAO F, et al. YOLACT: Real-Time Instance Segmentation[C] //Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 9157-9166.
- [24] WANG X, KONG T, SHEN C, et al. SOLO: Segmenting Objects by Locations[C]// Proceedings of the European Conference on Computer Vision (ECCV). 2020: 649-665.
- [25] WANG X, ZHANG R, KONG T, et al. SOLOv2: Dynamic and Fast Instance Segmentation[C]//Advances in Neural Information Processing Systems: vol. 33. 2020: 17721-17732.
- [26] CHEN H, SUN K, TIAN Z, et al. BlendMask: Top-Down Meets Bottom-Up for Instance Segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 8573-8581.
- [27] LEE Y, PARK J. CenterMask: Real-Time Anchor-Free Instance Segmentation[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 13906-13915.
- [28] TIAN Z, SHEN C, CHEN H. Conditional Convolutions for Instance Segmentation[C]// Proceedings of the European Conference on Computer Vision (ECCV). 2020: 282-298.
- [29] KIRILLOV A, WU Y, HE K, et al. PointRend: Image Segmentation As Rendering[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition

-
- (CVPR). 2020: 9799-9808.
- [30] TIAN Z, SHEN C, WANG X, et al. BoxInst: High-Performance Instance Segmentation With Box Annotations[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 5443-5452.
- [31] FANG Y, PENG B, ZHANG W, et al. Instances as Queries[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 6910-6919.
- [32] CHENG T, WANG X, CHEN S, et al. Sparse Instance Activation for Real-Time Instance Segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 4433-4442.
- [33] CHENG B, MISRA I, SCHWING A G, et al. Masked-Attention Mask Transformer for Universal Image Segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 1290-1299.
- [34] Ultralytics. YOLO11[EB/OL]. 2025 [2026-03-18]. <https://docs.ultralytics.com/models/yolo11/>.
- [35] CHATTOPADHYAY P, GIRSHICK R, RAMANATHAN V, et al. Counting Everyday Objects in Everyday Scenes[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 1135-1144.
- [36] LEMPITSKY V, ZISSERMAN A. Learning to Count Objects in Images[C]//Advances in Neural Information Processing Systems: vol. 23. 2010.
- [37] ZHANG C, LI H, WANG X, et al. Cross-Scene Crowd Counting via Deep Convolutional Neural Networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2015: 833-841.
- [38] ZHANG Y, ZHOU D, CHEN S, et al. Single-Image Crowd Counting via Multi-Column Convolutional Neural Network[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 589-597.
- [39] LI Y, ZHANG X, CHEN D. CSRNet: Dilated Convolutional Neural Networks for Understanding the Highly Congested Scenes[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 1091-1100.

-
-
- [40] MA Z, WEI X, HONG X, et al. Bayesian Loss for Crowd Count Estimation With Point Supervision[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 6142-6151.
- [41] COHEN J P, LO H Z, BENGIO Y, et al. Count-ception: Counting by Fully Convolutional Redundant Counting[J/OL]. CoRR, 2017, abs/1703.08710. <https://arxiv.org/abs/1703.08710>.
- [42] HAN S, MAO H, DALLY W J. Deep Compression: Compressing Deep Neural Networks with Pruning, Trained Quantization and Huffman Coding[J/OL]. International Conference on Learning Representations (ICLR), 2016. <https://arxiv.org/abs/1510.00149>.
- [43] HINTON G, VINYALS O, DEAN J. Distilling the Knowledge in a Neural Network [J/OL]. CoRR, 2015, abs/1503.02531. <https://arxiv.org/abs/1503.02531>.
- [44] HAN S, POOL J, TRAN J, et al. Learning both Weights and Connections for Efficient Neural Networks[C]//Advances in Neural Information Processing Systems: vol. 28. 2015.
- [45] LUO J, WU J, LIN W. ThiNet: A Filter Level Pruning Method for Deep Neural Network Compression[C]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). 2017: 5058-5066.
- [46] HE Y, ZHANG X, SUN J. Channel Pruning for Accelerating Very Deep Neural Networks[C]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). 2017: 1389-1397.
- [47] LIU Z, LI J, SHEN Z, et al. Learning Efficient Convolutional Networks through Network Slimming[C/OL]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). 2017: 2755-2763. DOI: [10.1109/ICCV.2017.298](https://doi.org/10.1109/ICCV.2017.298).
- [48] HE Y, LIU P, WANG Z, et al. Filter Pruning via Geometric Median for Deep Convolutional Neural Networks Acceleration[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 4340-4349.
- [49] LIN M, JI R, WANG Y, et al. HRank: Filter Pruning Using High-Rank Feature Map[C]//

-
- Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 1529-1538.
- [50] GUO S, WANG Y, LI Q, et al. DMCP: Differentiable Markov Channel Pruning for Neural Networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 1539-1547.
- [51] HE Y, DING Y, LIU P, et al. Learning Filter Pruning Criteria for Deep Convolutional Neural Networks Acceleration[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 2009-2018.
- [52] LUO J, WU J. Neural Network Pruning With Residual-Connections and Limited-Data [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 1458-1467.
- [53] ROMERO A, BALLAS N, KAHOU S E, et al. FitNets: Hints for Thin Deep Nets[J/OL]. CoRR, 2015, abs/1412.6550. <https://arxiv.org/abs/1412.6550>.
- [54] ZAGORUYKO S, KOMODAKIS N. Paying More Attention to Attention: Improving the Performance of Convolutional Neural Networks via Attention Transfer[J/OL]. CoRR, 2017, abs/1612.03928. <https://arxiv.org/abs/1612.03928>.
- [55] CHEN P, LIU S, ZHAO H, et al. Distilling Knowledge via Knowledge Review[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 5008-5017.
- [56] GUO J, HAN K, WANG Y, et al. Distilling Object Detectors via Decoupled Features [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 2154-2164.
- [57] DAI X, JIANG Z, WU Z, et al. General Instance Distillation for Object Detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 7842-7851.
- [58] YANG Z, LI Z, JIANG X, et al. Focal and Global Knowledge Distillation for Detectors [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 4643-4652.

- [59] ZHAO B, CUI Q, SONG R, et al. Decoupled Knowledge Distillation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 11953-11962.
- [60] ZHENG Z, YE R, WANG P, et al. Localization Distillation for Dense Object Detection [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 9407-9416.
- [61] VASWANI A, SHAZEER N, PARMAR N, et al. Attention Is All You Need[C]//Advances in Neural Information Processing Systems: vol. 30. 2017.
- [62] ZHANG X, ZHOU X, LIN M, et al. ShuffleNet: An Extremely Efficient Convolutional Neural Network for Mobile Devices[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 6848-6856.

攻读学位期间取得与学位论文相关的成果

发表和投稿与学位论文相关学术论文

申请发明专利

致谢

本论文完成之际，谨向在研究生学习和论文撰写过程中给予我帮助和支持的老师、同学及家人表示感谢。

首先，衷心感谢我的导师胡晓敏老师。在论文选题、研究思路、实验推进以及论文修改过程中，胡老师始终给予我认真细致的指导。无论是在研究方向的把握、论文结构的梳理，还是在具体问题的分析与修改上，胡老师都提出了许多中肯而具体的意见，使我能够逐步完成本论文的研究工作。胡老师严谨负责的治学态度也让我受益良多。

同时，感谢师兄弟们在学习与研究过程中给予我的帮助。大家在论文交流、实验讨论和日常学习中提出的建议，对我完善研究内容和理清写作思路都有实际帮助。

此外，感谢家人在研究生阶段对我的理解、支持与陪伴。在论文撰写和毕业阶段，家人的鼓励使我能够保持稳定的状态，顺利推进各项工作。

最后，感谢在研究生期间给予我指导和帮助的各位老师与朋友。谨以此文向所有关心、支持和帮助过我的人表示诚挚的谢意。