

中图分类号:

学校代号: 11845

UDC:

密级:

学 号: 2112305180

广东工业大学硕士学位论文

(工程硕士)

面向立体仓库堆叠货物盘点的改进实例分割与 模型压缩方法研究

胡文轩

指导教师姓名、职称:	胡晓敏教授
学科(专业)或领域名称:	计算机技术
学 生 所 属 学 院:	计算机学院
答 辩 委 员 会 主 席:	胡晓敏教授
论 文 答 辩 日 期:	2026 年 5 月 25 日

A Dissertation Submitted to Guangdong University of Technology
in Partial Fulfillment of the Requirement
for the Degree of Master of Engineering Science

Research on Improved Instance Segmentation and
Model Compression for Inventory Counting of Stacked
Goods in Automated Warehouses

Candidate: HU WenXuan

Supervisor: HU XiaoMin

May 25, 2026
School of School of Computer Science
Guangdong University of Technology

Guangzhou 510006, Guangdong, P. R. China

学位论文独创性声明

本人郑重声明：所呈交的学位论文是我个人在导师的指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明，并表示了谢意。本人依法享有和承担由此论文所产生的权利和责任。

论文作者签名：

日期：

学位论文版权使用授权声明

本学位论文作者完全了解学校有关保存、使用学位论文的规定：“研究生在广东工业大学学习和工作期间参与广东工业大学研究项目或承担广东工业大学安排的任务所完成的发明创造及其他技术成果，除另有协议外，归广东工业大学享有或特有”。同意授权广东工业大学保留并向国家有关部门或机构送交该论文的印刷本和电子版本，允许该论文被查阅和借阅。同意授权广东工业大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印、扫描或数字化等其他复制手段保存和汇编本学位论文。保密论文在解密后遵守此规定。

论文作者签名：

日期：

指导教师签名：

日期：

摘要

随着现代物流与智能仓储技术的快速发展，立体仓库库存盘点对自动化、智能化和实时性的要求不断提高。针对传统人工盘点效率低、成本高，且在复杂堆叠场景下易出现漏盘与错盘的问题，本文面向立体仓库堆叠货物盘点任务，围绕复杂场景识别与轻量化应用需求开展研究，主要包括改进实例分割模型、后处理数量计算方法以及模型压缩方法三个方面。

针对立体仓库场景中货物遮挡明显、结构关系复杂、现有实例分割模型易出现漏检与误检的问题，本文以 YOLO11s-Seg 为基线，提出改进模型 YOLO11-StackLite。该模型从注意力建模、下采样效率和空间结构表达三个方面进行优化，设计了通道拆分注意力模块 C2SASA、重排分组卷积模块 SSConv 以及具有四向卷积结构的 C3k2_QDConv 模块，从而增强模型对复杂堆叠货物场景的检测与分割能力。

针对仅依赖检测结果难以准确完成库存数量推断的问题，本文结合实例分割掩膜信息与仓储场景中的堆叠规则，构建了后处理数量计算方法。该方法通过顶层满载检测算法和基于掩膜关键点的层间面积比估计算法，对堆叠货物的层次结构进行判别与推理，实现货物总数量估算，从而提升库存盘点结果的可解释性与准确性。

考虑到仓储现场通常具有边缘侧应用需求，而高精度实例分割模型存在参数量较大、计算复杂度较高的问题，本文进一步研究了面向边缘部署需求的模型压缩方法。针对 YOLO11-StackLite，采用结构化剪枝降低模型参数量与浮点运算量，并结合知识蒸馏缓解压缩带来的性能退化，以提高模型的部署友好性。

在自建 TBD (Tobacco Box Dataset) 数据集上开展的实验结果表明，所提出的 YOLO11-StackLite 在检测精度、分割精度以及库存盘点准确率方面均优于对比模型，并在模型复杂度控制方面取得了较好的平衡。相关结果验证了本文方法在立体仓库堆叠货物盘点任务中的有效性，并为后续面向实际边缘场景的进一步应用提供了方法基础。

关键词：立体仓库；堆叠货物盘点；实例分割；模型压缩

ABSTRACT

With the rapid development of modern logistics and intelligent warehousing, higher requirements are being placed on the automation, intelligence, and real-time performance of inventory counting in automated warehouses. Traditional manual inventory counting suffers from low efficiency, high labor cost, and poor reliability in complex stacked scenes. To address these problems, this thesis focuses on the inventory counting task of stacked goods in automated warehouses and studies methods for complex-scene recognition and lightweight deployment. The main work includes an improved instance segmentation model, a post-processing-based quantity estimation method, and a model compression strategy.

To address severe occlusion, complex structural relationships, and frequent missed or false detections in stacked cargo scenes, an improved instance segmentation model named YOLO11-StackLite is proposed based on YOLO11s-Seg. The proposed model is optimized from three aspects, namely attention modeling, downsampling efficiency, and spatial structure representation. Specifically, a channel-splitting attention module C2SASA, a shuffle-split convolution module SSConv, and a quad-direction convolution based module C3k2_QDConv are designed to enhance the detection and segmentation performance in complex stacked scenes.

Since it is difficult to accurately infer the total quantity of goods only from detection results, a post-processing counting method is further constructed by combining instance segmentation masks with stacking rules in warehouse scenes. The proposed method includes a top-layer full-load detection algorithm and an interlayer area-ratio estimation algorithm driven by mask keypoints, which enable structural reasoning and quantity estimation for stacked goods and improve both the interpretability and accuracy of inventory counting.

Considering the demand for edge-oriented applications in warehouse environments and the relatively high parameter scale and computational complexity of high-accuracy instance segmentation models, a model compression method for YOLO11-StackLite is further studied. Structured pruning is adopted to reduce model parameters and floating-point operations, while knowledge distillation is introduced to alleviate the performance degradation caused by compression, thereby improving the deployment friendliness of the model.

Experiments conducted on the self-built TBD (Tobacco Box Dataset) show that the proposed YOLO11-StackLite outperforms the compared models in detection accuracy, segmentation accuracy, and inventory counting accuracy, while achieving a better balance between performance and model complexity. These results verify the effectiveness of the proposed method for stacked cargo inventory counting in automated warehouses and provide a methodological basis for further application in practical edge scenarios.

Key words: automated warehouse; stacked goods inventory counting; instance segmentation; model compression

目录

摘要	I
ABSTRACT	II
目录	IV
CONTENTS	VI
第一章 绪论	1
1.1 本课题研究背景及研究意义	1
1.2 国内外相关研究现状	3
1.2.1 目标检测与实例分割	3
1.2.2 对象计数	5
1.2.3 模型剪枝与模型蒸馏	6
1.3 本文主要研究内容与论文结构	7
第二章 基于改进 YOLO11-Seg 的立体仓库堆叠货物盘点方法	10
2.1 堆叠货物检测与分割	10
2.1.1 YOLO11s-Seg 基础架构	10
2.1.2 YOLO11-StackLite 架构	12
2.2 后处理数量计算方法	21
2.2.1 计数主体流程	22
第三章 面向边缘部署需求的 YOLO11-StackLite 模型压缩方法	29
3.1 模型压缩需求分析	29
3.2 基于结构化剪枝的轻量化方法	30
3.2.1 结构化剪枝原理	30
3.2.2 YOLO11-StackLite 剪枝对象选择	31
3.2.3 通道重要性评估与剪枝率设定	31
3.2.4 剪枝流程设计	32
3.3 基于知识蒸馏的精度恢复方法	33
3.3.1 知识蒸馏原理	33
3.3.2 教师模型与学生模型构建	33

3.3.3 蒸馏信息选择与约束方式	34
3.3.4 蒸馏损失设计	34
3.4 压缩模型构建与训练流程	35
3.5 本章小结	36
第四章 实验与结果分析	37
4.1 实验数据集	37
4.2 评价指标	37
4.3 实验环境与参数设置	38
4.4 结果与分析	39
4.4.1 消融实验	39
4.4.2 不同实例分割模型性能对比	41
4.4.3 数量计算评估	43
4.4.4 模型压缩实验	47
4.5 本章小结	49
第五章 结论与展望	50
参考文献	52
攻读学位期间取得与学位论文相关的成果	56
致谢	57

CONTENTS

ABSTRACT(IN CHINESE).....	I
ABSTRACT(IN ENGLISH).....	II
CONTENTS(IN CHINESE).....	IV
CONTENTS(IN ENGLISH).....	VI
Chapter 1 Introduction.....	1
1.1 Background and significance of research.....	1
1.2 Analysis of the research status at home and abroad.....	3
1.2.1.....	3
1.2.2.....	5
1.2.3.....	6
1.3 Main research content and thesis structure.....	7
Chapter 2 Method for Stacked Cargo Inventory Based on Improved YOLO11-Seg	10
2.1 Stacked Cargo Detection and Segmentation.....	10
2.1.1.....	10
2.1.2.....	12
2.2 Post-processing Counting Method.....	21
2.2.1.....	22
Chapter 3 Model Compression Method of YOLO11-StackLite for Edge Deployment	29
3.1 Analysis of Model Compression Requirements.....	29
3.2 Lightweight Method Based on Structured Pruning.....	30
3.2.1 Principle of Structured Pruning.....	30
3.2.2 Selection of Pruning Targets in YOLO11-StackLite.....	31
3.2.3 Channel Importance Evaluation and Pruning Ratio Setting.....	31
3.2.4 Pruning Process Design.....	32
3.3 Accuracy Recovery Method Based on Knowledge Distillation.....	33
3.3.1 Principle of Knowledge Distillation.....	33
3.3.2 Construction of Teacher and Student Models.....	33

3.3.3 Selection of Distillation Information and Constraint Strategy.....	34
3.3.4 Design of Distillation Loss	34
3.4 Construction and Training Process of the Compressed Model.....	35
3.5 Summary	36
Chapter 4 Experiments and Results	37
4.1 Dataset	37
4.2 Evaluation Metrics	37
4.3 Experimental Environment and Settings	38
4.4 Results and Discussion	39
4.4.1 Ablation Study	39
4.4.2 Comparison of Different Instance Segmentation Models.....	41
4.4.3 Counting Performance Evaluation	43
4.4.4 Model Compression Experiments.....	47
4.5 Summary	49
Chapter 5 Conclusion and prospect	50
References	52
Publication and patents during study.....	56
Acknowledgements	57

第一章 绪论

1.1 本课题研究背景及研究意义

随着电子商务、现代物流以及智能制造技术的快速发展，仓储系统在现代供应链中的作用日益突出。库存管理作为仓储作业中的基础环节，直接影响企业的出入库效率、库存准确性以及整体运营成本。自动化立体仓库（Automatic Storage and Retrieval System, AS/RS）因具有空间利用率高、作业效率高和自动化程度高等优势，已逐步广泛应用于烟草、医药、汽车零部件等多个行业^[1]。尤其在烟草仓储场景中，货物通常呈规则化堆叠存放，库存信息更新频繁，这对盘点工作的准确性、时效性和自动化水平提出了更高要求。

然而，传统库存盘点方法主要依赖人工完成，不仅劳动强度大、效率较低，而且在货物数量较多、堆叠结构复杂或作业环境受限的情况下，极易出现漏盘、错盘等问题。相较之下，精准、高效且自动化的库存盘点技术能够显著降低人工成本，提高盘点效率，并为后续仓储调度、库存预测和资源配置提供可靠的数据支撑。因此，研究适用于立体仓库场景的智能盘点方法，具有重要的现实意义和应用价值。

目前，仓储盘点领域主要存在以下几类技术路径。第一类方法基于 RFID（射频识别）技术。该方法能够实现快速批量识别，并具有较强的耐用性和较好的自动化水平^[2-3]。然而，其实施过程通常需要为货物配置电子标签，系统建设与后期维护成本较高，尤其在高吞吐量、大规模仓储场景中，这一成本问题更加突出，从而限制了其广泛应用。第二类方法主要采用 UAV（无人机）或 AGV（自动导引车）结合条码、二维码等识别码完成盘点作业^[4-6]。与 RFID 方法相比，此类方案在一定程度上降低了硬件成本，但仍需依赖外部标识介质，且在仓储现场运行过程中容易受到设备协同、视角变化和识别条件限制的影响，难以充分满足复杂场景下的自动化盘点需求。除上述两类方法外，部分仓储系统还尝试采用基于视觉或重量等传感器的辅助测量方式，例如通过比较货物在存储前后的图像或重量变化实现状态监测。当变化量超过预设阈值时，再由工作人员进行进一步确认和处理。该类方法在某些特定场景下具有一定实用性，但其对环境噪声、传感器精度以及现场工况变化较为敏感，系统稳定性有限，且仍然难以完全摆脱人工干预。

随着计算机视觉和深度学习技术的迅速发展，利用视觉感知方法实现库存盘点已

成为智能仓储研究的重要方向^[5,7]。从计算机视觉角度来看,库存盘点任务可视为对仓库场景图像中的目标进行检测、分割以及数量统计的综合问题。相较于依赖标签或外部传感器的方法,视觉方法能够直接基于现场图像完成信息提取,具有更好的灵活性、较低的系统改造成本以及更强的场景适应性。对于立体仓库而言,现有监控系统已能够持续采集高分辨率图像,这为基于视觉的智能盘点提供了良好的数据基础。

在实际应用中,仓库管理系统通常要求盘点任务具备较高的实时性。如果将前端采集到的大量高清图像全部传输至远程云端进行处理,不仅会占用较大网络带宽,还可能影响物流系统中其他关键指令的正常传输。基于这一考虑,将图像处理任务部署在仓库现场的边缘服务器上是一种更具可行性的方案。边缘服务器能够在本地完成图像识别与数量估计,仅将最终识别结果传输至仓库管理系统,从而有效降低网络压力并提升系统响应效率。

然而,边缘部署环境中的计算资源通常较为有限,这使得高精度识别模型的大规模参数量与边缘侧轻量化部署需求之间形成明显矛盾。一方面,复杂堆叠场景中的遮挡、重叠、纹理相似和层次结构差异,使得普通检测模型容易出现漏检与误检,从而影响后续计数结果。另一方面,即便采用高精度深度学习模型,也往往面临参数规模大、计算量高、推理延迟较长等问题,难以直接满足边缘部署条件。此外,堆叠货物盘点任务并非单纯的目标识别问题,还涉及对上下层结构关系的理解以及基于结构规则的数量推理,这进一步提升了任务难度。

从具体任务属性看,立体仓库中的堆叠货物盘点与普通货架商品识别或一般工业视觉检测任务并不相同。首先,堆叠货物在图像中往往呈现出高度重复的纹理与外观特征,不同箱体之间的类别差异较小,模型更容易受到局部相似背景或邻近目标的干扰。其次,堆叠结构导致箱体之间普遍存在遮挡与重叠,上层箱体与下层箱体之间的可见区域分布不均,使得边界识别和实例分离难度明显增加。再次,盘点任务不仅要求识别图像中“是否存在箱体”,还要求进一步判断箱体在堆叠结构中的层次位置,并据此完成数量估计。因此,该任务兼具检测、分割和结构推理等多重属性,对模型的精度、稳定性和可解释性均提出了更高要求。

进一步而言,库存盘点系统的工程目标也决定了该类任务不能仅以视觉识别精度作为唯一评价标准。在实际仓储应用中,模型输出不仅要能够区分顶层与非顶层箱体,

还要能够与后处理规则协同工作，将视觉结果可靠地转化为库存数量信息。如果视觉模型在局部边界提取、遮挡目标识别或层次关系判别方面存在偏差，则后续数量推理过程会放大这类误差，从而影响最终盘点结果。与此同时，仓储系统部署环境通常要求算法具备较好的资源适应性，因此仅追求高精度而忽略复杂度控制，也难以满足应用需求。由此可见，堆叠货物盘点任务本质上需要在识别精度、计数可靠性和部署效率之间寻求平衡。

因此，如何在复杂堆叠场景下构建一种既具有较高检测与分割精度、又能够满足边缘部署轻量化需求，并进一步支持货物数量准确推断的智能盘点方法，成为当前立体仓库视觉盘点领域亟待解决的关键问题。围绕这一问题展开研究，不仅能够提升立体仓库盘点效率与库存管理水平，也能够为视觉感知在智能仓储中的落地应用提供新的理论支持和技术路径。

1.2 国内外相关研究现状

围绕立体仓库堆叠货物盘点任务，本文的研究内容主要涉及目标检测与实例分割、对象计数、模型压缩等方向。相关研究的发展为本文方法设计提供了重要参考，但现有方法在复杂堆叠场景适应性、结构化计数能力以及边缘部署效率等方面仍存在不足。下面从这几个方面对国内外相关研究现状进行分析。

1.2.1 目标检测与实例分割

堆叠货物数量统计的前提是对货物目标进行准确定位和轮廓提取，因此目标检测与实例分割是实现自动盘点的基础技术。目标检测作为计算机视觉领域的重要研究问题，主要包含目标定位与类别识别两个任务。实例分割则是在目标检测基础上的进一步扩展，不仅要求识别目标类别和位置，还需要输出每个实例的像素级掩膜，从而为后续结构分析与数量估计提供更精细的几何信息。

现有目标检测方法大致可分为两阶段方法、一阶段方法以及基于 Transformer 的方法。两阶段检测方法以 R-CNN、Fast R-CNN 和 Faster R-CNN 为代表，其核心思想是先生成候选区域，再完成分类与边界框回归。这类方法通常具有较高的检测精度，但由于处理流程较长，模型结构相对复杂，推理效率往往受到限制。一阶段目标检测方法如 SSD、RetinaNet 和 YOLO 系列，则通过单次前向传播直接完成目标定位与分类，具有结构简洁、推理速度快等优势，因而更适用于实时检测任务和边缘部署场景。

从技术路线演进过程看，两阶段检测方法的优势主要在于候选区域机制能够为后续分类与定位提供更细粒度的特征支撑，因此在复杂场景中常能获得较高精度。然而，对于实时性要求较高的仓储盘点任务而言，两阶段方法较长的推理链条和较高的计算成本会限制其实际应用价值。一阶段方法则通过统一检测流程简化了推理过程，在保持较好精度的同时显著提升了速度，因此在工业视觉和边缘部署场景中具有更强的实用性。尤其是 YOLO 系列模型，在多代迭代中不断兼顾精度、速度和模型复杂度，已经成为轻量化视觉任务中的重要基础框架。

近年来，基于 Transformer 的目标检测方法受到了广泛关注。DETR 通过端到端学习框架避免了传统候选框生成和复杂后处理过程^[8]，但其在训练收敛速度和小目标检测性能方面仍存在不足。为解决这些问题，研究者提出了 Deformable DETR、DAB-DETR、DINO 等一系列改进方法^[9-11]，这些方法在训练效率和检测性能方面均取得了不同程度提升。但总体来看，基于 Transformer 的检测方法通常模型规模较大、训练成本较高，在边缘计算资源受限的场景中仍面临部署挑战。

基于 Transformer 的方法在全局关系建模方面具有天然优势，对于存在复杂上下文依赖的视觉任务具有较强表达能力。然而，在立体仓库堆叠货物场景中，虽然全局建模有助于理解目标间的空间关系，但模型复杂度偏高、训练资源需求较大等问题仍限制了其在边缘应用中的可行性。换言之，Transformer 检测方法在理论能力上具有吸引力，但若缺乏针对性轻量化设计，其在本文所关注的资源受限应用场景中并不一定具有优势。

对于实例分割任务，Mask R-CNN 是具有代表性的经典方法之一，其通过在检测分支之外增加掩膜分支，实现了较高质量的实例级分割^[12]。随后，YOLACT、SOLO、SOLOv2、QueryInst、SparseInst、Mask2Former 以及 YOLO 系列实例分割模型等方法^[13-19]，分别从单阶段推理、动态掩膜生成、稀疏表示和全局特征建模等角度推动了实例分割技术的发展。总体而言，单阶段实例分割方法在推理效率方面更具优势，而基于 Transformer 的分割方法在全局建模能力和掩膜表达能力方面表现更强，但其模型复杂度和部署成本也相对较高。

对于本文任务而言，实例分割方法的选取还需考虑一个关键问题，即掩膜结果是否能够为后续数量推理提供可靠的几何基础。相比仅输出目标边界框的检测方法，实

例分割能够提供更精细的轮廓信息，使模型在处理堆叠边界、局部遮挡和结构分层时具有更强的表达能力。这也是本文选择实例分割作为主要技术路线的重要原因。但与此同时，并非所有实例分割方法都同样适合堆叠货物盘点任务。对于模型结构复杂、推理开销较大的方法，即便其具备较强的掩膜表达能力，也可能难以满足边缘侧应用的实际需求；而对于过度轻量化但结构建模能力不足的方法，则又可能在复杂堆叠场景下产生较多漏检与误检。

对于立体仓库堆叠货物盘点任务而言，方法不仅需要具备良好的目标定位与轮廓分割能力，还需要兼顾边缘部署条件下的推理效率与计算资源约束。因此，选择具有轻量化潜力的实例分割框架作为基线，并在此基础上开展针对复杂堆叠场景的结构改进，具有较强的现实必要性。

进一步总结可知，目标检测与实例分割技术的发展为仓储视觉盘点提供了良好的方法基础，但现有方法大多面向通用场景设计，尚未充分考虑堆叠货物盘点任务中“轮廓识别 - 层次区分 - 数量推理 - 资源受限部署”这一完整链条。如何在轻量化框架内增强模型对复杂堆叠结构的感知能力，仍是值得深入研究的问题。

1.2.2 对象计数

对象计数是计算机视觉中的重要研究方向，常见方法大致可分为基于回归的方法、基于密度图的方法和基于检测的方法。基于回归的方法通常通过建立图像特征与目标数量之间的直接映射关系完成计数，其实现形式较为直接，但往往缺乏良好的可解释性^[20]。基于密度图的方法常用于高密度场景，其基本思路是先预测目标密度分布，再通过积分或累加得到总数量^[21-22]。该类方法在目标密集分布场景中具有一定优势，但对于目标的层次结构和个体边界表达相对不足。基于检测和分割的方法则通过识别单个目标实例实现数量统计，具有较强的可解释性，但其性能高度依赖于检测与分割结果的准确性^[20,23]。

从应用特点看，回归法更适合只关注总数量、而不强调目标位置与个体结构的任务；密度图方法在高密度、强遮挡场景下具有较好的适应能力，常用于人群计数、车辆计数等任务；检测和分割法则更适用于目标边界较清晰、且需要保留个体级解释信息的场景。对于库存盘点任务而言，后两者显然更具应用潜力，因为仓储管理系统通常不仅需要知道“有多少个箱体”，还需要知道“哪些目标被识别出来了”以及“这些

目标在结构上属于哪一层”，这决定了单纯回归方法在本文任务中很难满足需求。

立体仓库中的堆叠货物计数任务与一般对象计数任务存在明显差异。该任务不仅要求估计目标总数量，还涉及上下层结构关系判别以及基于堆叠规则的数量推理。对于此类场景，单纯依赖回归方法或密度图方法难以充分利用空间结构信息，而传统基于检测的方法在面对堆叠遮挡和层次关系时又存在明显不足。因此，面向堆叠货物盘点任务，仍有必要结合实例分割结果设计更具结构感知能力的后处理计数方法，以提升数量推断的准确性和可解释性。

进一步来看，堆叠货物计数任务的特殊性还体现在其结果生成方式并非直接由视觉模型端到端输出，而是往往需要结合仓储规则进行后处理推理。例如，当前层是否满载、上层与下层目标之间的几何关系如何、是否存在空货物或不可判定状态等，都会直接影响最终数量估计结果。这意味着，对本文任务而言，更合理的研究思路不是单独追求“计数网络”的性能，而是在稳定实例分割结果的基础上，构建与实际堆叠规则相匹配的数量推理方法。这样的设计更符合仓储盘点的实际业务流程，也更有利于提升系统可解释性。

1.2.3 模型剪枝与模型蒸馏

随着深度神经网络模型规模不断增加，模型压缩逐渐成为边缘智能领域的重要研究方向^[24-25]。其中，模型剪枝是最常见的压缩技术之一，主要包括非结构化剪枝和结构化剪枝两类。非结构化剪枝通常根据参数重要性删除部分连接或权重，可以显著降低参数冗余^[26]，但由于生成的稀疏结构不规则，实际硬件加速效果往往有限。结构化剪枝则通过删除整个通道、卷积核或模块来降低模型复杂度，其输出结构更加规整，更有利于在实际部署中获得真实的推理加速收益^[27-28]。

在结构化剪枝研究中，常见策略包括组级剪枝、滤波器剪枝和通道剪枝等。相关研究通常根据权重范数、激活值、能耗贡献或特征重要性等指标评估不同结构单元的重要程度，并据此执行剪枝操作^[27-28]。总体来看，结构化剪枝在实际部署友好性方面相较非结构化剪枝更具优势，因此更适合作为边缘侧模型压缩的重要手段。

知识蒸馏的核心思想是利用性能较强的教师模型指导轻量化学生模型训练，以实现“以大带小”的知识迁移^[25]。现有蒸馏方法包括基于输出响应的蒸馏、基于中间特征的蒸馏以及基于关系约束的蒸馏等。大量研究表明，知识蒸馏能够在一定程度上弥

补轻量化模型在压缩过程中的性能下降问题，因此常与模型剪枝配合使用，以在模型复杂度和性能之间取得更优平衡。

对于边缘部署任务而言，模型压缩研究的意义并不仅在于减小参数规模，更重要的是在可接受的性能损失范围内获得更高的部署可行性。若仅追求压缩率最大化，而忽略模型在实际任务中的精度保持能力，则压缩结果往往难以真正落地。特别是在本文所关注的实例分割与库存盘点联合任务中，模型输出需要同时服务于目标识别和数量推理两个环节，因此压缩方法的评价标准也应当更加综合。结构化剪枝可以从模型结构层面直接降低复杂度，而知识蒸馏则能够为压缩模型提供性能补偿，两者结合更适合作为兼顾复杂度和任务性能的研究路线。

此外，现有模型压缩研究多集中于通用分类或目标检测任务，而针对实例分割与后处理计数联合任务的压缩研究相对较少。实例分割模型通常具有更复杂的特征融合与掩膜预测结构，一旦压缩不当，更容易影响轮廓完整性和结构判别能力，进而影响下游数量估计结果。因此，在堆叠货物盘点场景中，模型压缩不能仅从通用检测精度角度评价，还应关注压缩后模型是否仍能稳定支撑盘点任务。围绕这一问题展开研究，既能够提升模型轻量化的针对性，也为本文第3章的压缩方案设计提供了研究依据。

综上，模型剪枝与知识蒸馏为深度模型在边缘部署场景中的压缩与加速提供了有效技术路径。其中，结构化剪枝更有利于实际部署过程中的推理加速，而知识蒸馏能够在一定程度上缓解压缩过程带来的性能退化。然而，针对堆叠货物盘点任务，如何在保持检测、分割与计数性能的前提下进一步降低模型复杂度，仍需开展针对性的研究。

1.3 本文主要研究内容与论文结构

针对立体仓库堆叠货物盘点任务中存在的识别精度不足、复杂场景计数困难以及边缘部署受限等问题，本文围绕“复杂堆叠场景下的高精度盘点”和“面向边缘部署的模型轻量化”两条主线开展研究。本文的主要研究内容如下：

(1) 面向复杂堆叠场景的实例分割模型改进与后处理计数方法研究。针对现有模型在堆叠货物识别过程中易出现漏检、误检以及对结构信息建模不足的问题，本文以 YOLO11-Seg 为基线，设计适用于堆叠货物场景的改进实例分割模型，并结合实例分割掩膜与空间几何关系构建后处理计数方法，以提升库存盘点的准确性与鲁棒性。




图 1-1 研究内容逻辑关系

Figure 1-1 Logical relationship of the research contents

(2) 面向边缘部署的模型压缩方法研究。针对高精度识别模型参数量较大、计算开销较高而难以直接部署于边缘侧的问题，本文进一步研究模型压缩方法，通过结构化剪枝降低模型复杂度，并结合知识蒸馏缓解压缩过程中的性能损失，从而提升模型在实际仓储场景中的部署可行性。

上述两部分研究内容之间具有明确的递进关系。第一部分重点解决“复杂堆叠场景下如何识别得更准、计数得更稳”的问题，是全文的核心任务；第二部分进一步解决“在保持主要任务性能的前提下如何降低模型复杂度”的问题，是面向实际应用需求的延伸研究。通过将模型改进与模型压缩结合起来，本文形成了从视觉感知到应用可行性分析的较完整研究链条。

研究内容之间的逻辑关系如图 1-1 所示。

本文的章节安排如下：第 1 章为绪论，主要介绍研究背景、国内外研究现状、研

究内容与论文结构；第 2 章围绕堆叠货物检测、分割与计数任务，提出改进的实例分割模型及后处理计数方法；第 3 章针对边缘部署需求，研究模型压缩方法，包括结构化剪枝与知识蒸馏；第 4 章通过实验对所提方法的有效性进行验证，并从精度、复杂度与计数性能等方面进行分析；第 5 章对全文工作进行总结，并对后续研究方向进行展望。

其中，第 1 章和第 2 章共同构成问题提出与方法设计部分，第 3 章和第 4 章分别对应模型轻量化方法与实验验证部分，第 5 章则对全文研究工作进行总结归纳。整体结构由“问题分析 - 方法构建 - 压缩扩展 - 实验验证 - 总结展望”组成，旨在逐步回答本文围绕立体仓库堆叠货物盘点任务提出的关键问题。

第二章 基于改进 YOLO11-Seg 的立体仓库堆叠货物盘点方法

本章围绕立体仓库堆叠货物盘点任务中的检测、分割与计数问题展开研究。首先分析基线模型 YOLO11s-Seg 的结构特点及其在复杂堆叠场景中的局限；其次在此基础上提出改进模型 YOLO11-StackLite，并对其关键模块进行设计说明；最后结合实例分割结果与空间几何关系，构建后处理数量计算方法，为后续实验验证与模型压缩研究奠定基础。

2.1 堆叠货物检测与分割

2.1.1 YOLO11s-Seg 基础架构

为实现立体仓库中堆叠货物的高效自动盘点，视觉模型不仅需要准确区分堆叠结构中的顶层箱体与非顶层箱体，还需要在边缘部署条件下具备较低的计算开销与较快的推理速度。因此，本文选取兼顾检测效率与实例分割能力的单阶段模型作为研究基础。

基于上述需求，本文选择 Ultralytics 发布的 YOLO11s-Seg 作为基线模型^[19]。该模型在单阶段框架下集成了目标检测与实例分割能力，在检测精度与推理速度之间取得了较好平衡，具备较强的边缘部署适配性。YOLO11s-Seg 的整体结构主要由主干网络（Backbone）、特征融合网络（Neck）和检测头（Head）构成。

选择 YOLO11s-Seg 作为基线模型主要基于以下考虑。首先，与两阶段实例分割模型相比，YOLO11s-Seg 保留了单阶段框架推理流程简洁、实时性较高的优点，更符合仓储盘点任务对推理效率的要求。其次，该模型同时具备目标检测与实例分割能力，能够直接输出边界框与像素级掩膜，为后续基于几何关系的数量推理提供必要输入。再次，YOLO 系列模型在实际工程场景中具有较好的训练与部署生态，便于在统一框架下完成后续结构改进与模型压缩研究。因此，YOLO11s-Seg 既能够作为性能较强的分割基线，也能够为后续轻量化设计保留足够的改进空间。

然而，需要指出的是，适合作为基线并不意味着该模型已经完全满足本文任务需求。立体仓库堆叠货物场景具有遮挡明显、纹理相似、方向结构重复且层次关系复杂等特点，模型除了需要识别目标轮廓，还需要较稳定地区分顶层与非顶层箱体，并为




图 2-1 YOLO11s-Seg 主干与注意力结构示意图

Figure 2-1 Backbone and attention structure of YOLO11s-Seg

后处理数量计算提供可靠输入。若模型在局部边缘恢复、方向性结构建模或关键区域聚焦方面能力不足，则即便总体检测精度较高，也可能在后续盘点环节放大误差。因此，对 YOLO11s-Seg 的结构进行针对性改进是有必要的。

在 YOLO11s-Seg 的 Backbone 与 Neck 中，引入了改进的 C3k2 Fast 模块 (CSP Bottleneck with Two Convolution Layers)，用于增强浅层特征提取与融合能力。该模块基于跨阶段部分结构思想，能够在保持较低计算复杂度的同时提升特征表达能力。在 Backbone 末端，集成轻量级注意力模块 C2PSA，用于增强模型对关键区域的感知能力，其结构如图 2-1 所示。

C2PSA 采用 Softmax Attention，其计算公式如下^[29]：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2.1)$$

其中， Q 、 K 、 V 分别表示查询、键和值。该注意力机制通过计算不同位置之间的相关性实现全局信息建模，其时间复杂度为 $O(N^2)$ 。尽管该结构能够增强模型对重要区域的关注能力，但在高分辨率特征图上，其计算代价仍然较高。此外，原始注意力机制

在复杂堆叠场景中对低相关区域的抑制能力有限，容易引入冗余信息，从而影响对关键结构特征的有效表征。

从本文任务角度看，基线模型的局限主要体现在三个方面。第一，注意力机制虽然增强了全局依赖建模能力，但在堆叠目标边界高度相似的情况下，若缺乏更有针对性的特征筛选，模型仍可能将注意力分配到无效背景或邻近干扰区域。第二，Neck 中标准下采样结构虽然实现简单，但在多次尺度压缩过程中容易造成局部轮廓信息衰减，这会影响箱体边界分离和掩膜完整性。第三，传统 Bottleneck 结构对方向性几何关系的建模能力有限，而堆叠货物场景中恰恰存在大量横竖边界、层间交界与遮挡轮廓，这使得模型在复杂结构下更容易产生漏检和误检。

因此，虽然 YOLO11s-Seg 已具备较好的基础性能，但在复杂堆叠场景下仍存在注意力计算冗余、下采样效率不足以及空间结构建模能力有限等问题，有必要在其基础上进行针对性的结构改进。

2.1.2 YOLO11-StackLite 架构

鉴于仓储盘点系统对识别精度、推理效率与部署资源均具有较高要求，尽管 YOLO11s-Seg 在常规场景下已表现出较好的综合性能，但在复杂堆叠图像中仍可能出现漏检、误检等问题，且其参数规模与计算复杂度在边缘部署场景下仍存在进一步优化空间。为此，本文在 YOLO11s-Seg 的基础上提出改进模型 YOLO11-StackLite，从注意力建模、下采样效率和空间结构表达三个方面对网络进行优化，以提升复杂堆叠场景下的检测与分割性能，并进一步降低模型部署开销。

YOLO11-StackLite 的设计并非对原始网络进行简单模块替换，而是围绕本文任务需求进行针对性重构。具体而言，模型整体设计遵循以下原则：其一，在 Backbone 高层特征中增强对关键区域和有效结构的建模能力，以减弱复杂背景与重复纹理对识别结果的干扰；其二，在 Neck 下采样与特征融合过程中尽量减少信息损失，使模型在压缩尺度时仍能保留对箱体边界和局部细节的敏感性；其三，在核心特征提取模块中引入更适合堆叠场景的方向性结构建模方式，从而强化模型对空间几何关系的感知能力；其四，在性能提升的同时控制模型参数量与计算复杂度，为第 3 章的进一步压缩研究预留空间。

改进后的实例分割网络模型称为 YOLO11-StackLite，其整体结构如图 2-2 所示。




图 2-2 YOLO11-StackLite 整体结构

Figure 2-2 Overall structure of YOLO11-StackLite

围绕上述目标，本文设计了 3 个关键改进模块，即通道拆分注意力模块 C2SASA、重排分组卷积模块 SSConv，以及具有四向卷积结构的 C3k2_QDConv 模块。三者分别面向关键区域建模、轻量化下采样和方向性空间特征提取，从不同层面增强模型对堆叠货物场景的适应能力。

从整体关系上看，三个模块并非相互独立的局部优化，而是共同服务于“复杂堆叠场景识别与计数”这一目标。C2SASA 主要作用于高层特征的选择性增强，解决注意力冗余和关键区域聚焦不足的问题；SSConv 主要作用于特征融合阶段，解决下采样过程中的计算冗余与局部信息损失问题；C3k2_QDConv 则着重加强模型对方向性边缘与几何结构的刻画能力，提升在遮挡、重叠和结构相似条件下的识别稳定性。三者在功能上的分工与配合，共同构成了 YOLO11-StackLite 的核心改进路线。

1) 通道拆分注意力模块 C2SASA：该模块在继承原始注意力结构优势的基础上，通过通道拆分机制与选择性激活抑制策略，降低注意力计算冗余并增强模型对关键区域的表征能力。

2) 重排分组卷积模块 SSConv：该模块面向 Neck 部分的轻量化下采样需求，通过融合

像素重排、分支卷积与组卷积等设计，在降低计算复杂度的同时提升多尺度特征提取能力。

3) 具有四向卷积的 C3k2_QDConv 模块：该模块通过增强对方向性几何结构的感知能力，改善传统 Bottleneck 在复杂结构建模中的不足，从而提高模型在堆叠场景下的检测与分割性能。

2.1.2.1 通道拆分注意力模块 C2SASA 为同时提升模型对显著区域的建模能力并降低计算开销，本文提出通道拆分式选择性激活抑制注意力模块 (C2SASA)，用于替换 Backbone 中的 C2PSA 模块。该模块首先通过 1×1 卷积对输入特征进行通道压缩，并将其划分为两条分支：其中一条分支保留残差信息以维持原始特征表达，另一条分支输入改进注意力块进行特征增强，最后通过通道拼接与卷积映射恢复原始维度，实现两类信息的有效融合。

之所以采用通道拆分方式，是因为在复杂堆叠场景中，并非所有通道都需要参与同等强度的注意力计算。若直接对全部特征通道执行全局注意力操作，不仅会增加计算负担，还可能使无关背景信息与低贡献特征一并参与相似度建模，削弱模型对关键区域的聚焦效果。通过在注意力建模前对特征进行拆分，可以将一部分通道保留为稳定的基础语义表达，另一部分通道用于执行更具针对性的注意力增强，从而在减少冗余计算的同时提高有效特征筛选能力。

在改进注意力块中，本文将原始 Attention 替换为 SASA 机制，以实现特征的择性激活与抑制。SASA 模块在保持全局建模能力的同时，引入 L2 归一化与可学习温度参数，从而增强注意力计算过程中的数值稳定性和特征区分能力，其结构如图 2-3 所示。

这种设计尤其适合本文任务。对于堆叠货物图像而言，模型往往需要从大量相似边缘和重复纹理中识别出真正有助于区分层次结构的区域。若缺乏有效抑制机制，注意力模块可能对多个相似位置赋予接近权重，导致关键特征不够突出。SASA 机制通过归一化和温度调节，使注意力分布更稳定、更具可控性，有助于增强模型对顶层目标、交界边缘和局部结构差异的敏感性。

设输入张量为 $x \in R^{B \times C \times H \times W}$ ，其中 B 为批大小， H 、 W 分别表示输入特征图的高度和宽度， C 为特征维度。首先将空间维度展平并转置为序列形式，其中 $N = H \cdot W$ 。




图 2-3 选择性激活抑制注意力机制 SASA

Figure 2-3 Selective activation suppression attention

随后采用共享线性投影层一次性生成 q 、 k 、 v ：

$$[q, k, v] = \text{Linear}_{qkv}(X) \quad (2.2)$$

为实现多头注意力，将通道维度 C 重构为 $h \times d$ ，其中 h 为注意力头数， $d = C/h$ 为每个注意力头的嵌入维度。由此得到：

$$q, k, v \rightarrow \mathbb{R}^{B \times h \times N \times d}$$

对 q 与 k 进行 L2 归一化：

$$q' = \frac{q}{\|q\|_2}, \quad k' = \frac{k}{\|k\|_2}$$

进一步引入可学习温度参数 $\text{Temp} \in \mathbb{R}^{h \times 1 \times 1}$ ，得到相似度矩阵：

$$\text{sim} = \text{Temp} \cdot q' k'^T \quad (2.3)$$

其中， T 表示转置操作。随后通过 Softmax 与 Dropout 获得注意力权重：

$$\alpha = \text{Dropout}(\text{softmax}(\text{sim}))$$

最后对 v 进行加权求和并投影：

$$y = \text{Proj}(\alpha \cdot v)$$

最终输出通过 Transpose 与 Reshape 操作恢复到原始空间维度。综上，C2SASA 在保留全局依赖建模能力的基础上，降低了注意力计算的冗余性，并增强了对关键区域的特征区分能力，为复杂堆叠场景下的实例检测与分割提供了更有效的特征表示。

进一步而言，C2SASA 的作用不仅体现在 mAP 指标提升上，还体现在它为后续盘点任务提供了更稳定的高层语义基础。由于后处理数量计算依赖模型较准确地区分上层与非顶层目标，若高层特征中关键区域表达不足，则后续状态判别和数量推理均会受到影响。因此，C2SASA 可以视为从特征选择层面对盘点任务进行的一种前置优化。

2.1.2.2 重排分组卷积模块 SSConv 在 YOLO11 模型中，Neck 部分通常采用串联的标准卷积进行下采样。虽然该结构实现简单，但存在参数量较大、计算开销较高以及通道信息利用不足等问题，不利于模型在边缘设备上的高效运行。与此同时，标准卷积在下采样过程中对局部细节信息和多尺度语义信息的保留能力有限，容易影响复杂

堆叠场景中的特征表达效果。

对于堆叠货物盘点任务而言，下采样阶段的特征损失具有更直接的负面影响。原因在于，箱体边界通常由长直线段和相对规则的角点组成，这些细节信息在尺度压缩过程中若被过度削弱，模型就更容易在相邻箱体交界处出现粘连、漏分或边界不完整等现象。此外，仓储图像中的顶层与非顶层目标往往在局部可见区域上存在差异，若下采样结构不能充分保留这类局部信息，也会影响后续类别区分与数量推理。因此，在保证下采样效率的同时尽量减少关键信息损失，是 Neck 结构改进的重点。

针对上述不足，本文提出重排分组卷积模块 SSConv，以实现下采样阶段的轻量化设计与特征增强。该模块融合了像素重排、分支卷积、组卷积与逐点卷积等结构思想^[30-31]，通过通道重组和双分支处理策略，在降低模型计算成本的同时增强特征提取能力，其结构如图 2-4 所示。

其中，像素重排操作有助于在不增加过多计算开销的情况下增强通道间信息交互，使原本分散在空间维度中的局部信息重新组合到通道维度中，便于后续卷积操作更有效地提取结构特征。双分支设计则体现了“局部细节保持”与“整体感受野扩展”的兼顾思想：一条分支侧重轻量化特征提取与通道融合，另一条分支侧重保留较大的感受野，以捕获更稳定的整体堆叠结构信息。这种分工使模块在轻量化条件下仍能保有较好的多尺度表达能力。

该模块用于替换 YOLO11-Seg 中 Neck 部分的标准下采样卷积结构，以提高下采样阶段的效率和特征利用能力。设输入特征图为 X ，首先通过 PixelShuffle 操作增强通道间信息交互，再沿通道维度将特征划分为两个子分支 X_1 和 X_2 ：

$$X_1, X_2 = \text{Split}(\text{PixelShuffle}(X), \text{dim} = 1)$$

第一条分支采用组卷积与逐点卷积进行轻量化特征提取与跨通道融合：

$$Y_1 = \text{GroupConv}(X_1) + \text{PointwiseConv}(X_1)$$

第二条分支采用步幅为 2 的 3×3 卷积，以保持较大的感受野并增强对整体结构的感知能力：

$$Y_2 = \text{Conv2d}_{3 \times 3}(X_2)$$




图 2-4 重排分组卷积模块 SSConv

Figure 2-4 Shuffle-split convolution

最终将两路特征进行拼接并经过归一化与激活：

$$Y = \text{SiLU}(\text{BN}(\text{Concat}(Y_1, Y_2)))$$

因此，SSConv 在降低下采样阶段计算负担的同时，兼顾了局部细节保持与跨通道信息融合能力，有助于提升模型在复杂堆叠场景中的多尺度特征表达效果。

从任务贡献角度看，SSConv 的意义不仅在于压缩模型复杂度，更在于提高了特征融合阶段的信息利用效率。对于本文后续提出的计数方法而言，若实例分割结果在边界连续性和局部形状表达上更加稳定，则满载判别和面积比估计过程也更容易获得可靠输入。因此，SSConv 可以视为连接“模型轻量化需求”和“计数可靠性需求”的关键模块之一。

2.1.2.3 具有四向卷积的 C3k2_QDConv 模块 在堆叠货物场景中，箱体边缘、遮挡关系以及方向性几何结构对目标识别具有重要影响。然而，传统 Bottleneck 模块主要依赖标准卷积完成局部特征提取，其对方向性结构和复杂空间关系的建模能力相对有限。尤其在库存边界模糊、局部重叠遮挡等情况下，传统卷积往往难以充分刻画长条形边缘和多方向变化特征，容易造成细节信息损失。

对于烟箱堆叠图像而言，这类方向性结构信息具有更强的任务相关性。由于箱体大多呈规则长方体外形，其边缘通常沿水平或垂直方向分布，堆叠层间关系也常通过这些边缘和角点位置体现出来。当图像中出现部分遮挡、光照变化或背景干扰时，模型是否能够稳定感知这些方向性几何线索，将直接影响其实例分离能力与层次判断能力。因此，仅依赖常规局部卷积往往难以充分满足该类场景对结构表达的需求。

为增强模型对堆叠场景几何特征的感知能力，本文提出 Bottleneck_QDConv，并构建对应的 C3k2_QDConv 模块。该模块以四向卷积为核心，通过多个方向上的非对称卷积与显式空间位移操作，加强对不同方向边缘和空间结构变化的建模能力，其结构如图 2-5 所示。

与常规卷积相比，QDConv 的优势在于其建模重点更加贴近本文任务的几何特征分布。通过在水平和垂直两个主方向上分别进行卷积，并结合正反位移操作，模块能够更有效地感知边缘延展关系、结构交界区域以及局部遮挡下的轮廓连续性。这使其不仅能够提升单个目标的边界表达质量，还能够增强模型对相邻目标之间空间关系的判断能力，从而减少堆叠目标分离过程中的歧义。




图 2-5 四向卷积模块 QDConv

Figure 2-5 Quad-direction convolution module

设输入特征为 X ，输出为 Y ，卷积核尺寸为 k ，位移步长为 $s = 1$ 。首先对输入特征进行零填充，得到四个方向的位移分支 X_p^1 、 X_p^2 、 X_p^3 和 X_p^4 。随后分别对其施加 $1 \times k$ 与 $k \times 1$ 的卷积，并通过显式位移操作进行方向建模，最终表达式为：

$$Y = \text{Conv}_{2 \times 2} \left(\text{Concat} \left[\begin{array}{c} \text{Roll}_{+1}^H(\text{Conv}_{1 \times k}(X_p^1)), \\ \text{Roll}_{-1}^H(\text{Conv}_{1 \times k}(X_p^2)), \\ \text{Roll}_{+1}^W(\text{Conv}_{k \times 1}(X_p^3)), \\ \text{Roll}_{-1}^W(\text{Conv}_{k \times 1}(X_p^4)) \end{array} \right] \right)$$

其中， Roll_{+1}^H 、 Roll_{-1}^H 表示沿高度方向进行正向和反向位移操作； Roll_{+1}^W 、 Roll_{-1}^W 表示沿宽度方向进行正向和反向位移操作； $\text{Conv}_{1 \times k}$ 、 $\text{Conv}_{k \times 1}$ 分别表示核尺寸为 $1 \times k$ 和 $k \times 1$ 的卷积操作，用于水平方向和垂直方向的特征提取。

与传统标准卷积相比，QDConv 不仅能够在多个方向上捕获目标的几何变化特征，还能够通过位移操作强化空间关系表达，从而使模型在复杂堆叠结构下获得更丰富的方向性特征表示。由此，C3k2_QDConv 能够提升模型对复杂空间结构和目标轮廓信息的刻画能力，为后续检测与分割提供更具判别性的特征支撑。

从盘点应用角度看，C3k2_QDConv 的引入进一步增强了模型对结构化场景的适配性。由于后处理算法需要利用掩膜轮廓、凸包角点及其几何关系进行状态判断和数量估计，若分割结果在方向性边缘上更清晰、轮廓更稳定，则后续几何推理的可靠性也会同步提高。因此，该模块的作用不仅体现在视觉特征表达层面，也为计数阶段的几何分析提供了更优输入。

2.2 后处理数量计算方法

在立体仓库堆叠货物盘点任务中，仅依赖目标检测结果难以准确完成数量估计，其原因在于盘点结果不仅取决于目标是否被识别，还与上下层结构关系及堆叠规则密切相关。由于实例分割结果能够提供更精细的轮廓信息和空间形状信息，本文进一步结合实例分割掩膜设计后处理数量计算方法，以实现复杂堆叠场景下货物数量的准确推断。

与直接以目标框数量作为库存数量的简单统计方式不同，本文任务的数量计算需要同时考虑目标类别、层次关系以及装载状态。例如，当图像中仅检测到下层目标而缺乏顶层信息时，单纯依据检测框数量无法判断整体堆叠结构；当图像中同时存在上下层目标时，还需要进一步判断顶层是否满载，才能决定采用何种数量推理公式。因




图 2-6 图像标注示例

Figure 2-6 Example of image annotation

此，后处理算法并非附加步骤，而是将视觉识别结果转化为库存数量信息的关键环节。实例分割掩膜所提供的轮廓信息恰好能够支撑这一过程中的几何分析与结构推断。

2.2.1 计数主体流程

本文采用“up_box”和“down_box”两个类别对每幅图像中的目标进行标注，如图 2-6 所示。其中，类别标签 1 和 0 分别对应上层货物与下层货物。模型在推理阶段输出每个目标实例的边界框、类别标签及其对应的掩膜信息。为了提升后续计数环节的准确性与鲁棒性，本文根据不同类别的特性设置差异化的置信度阈值，仅保留满足阈值要求的预测结果参与后续处理。

在获得满足阈值条件的实例分割结果后，本文设计了一种基于实例分割结果的启发式后处理计数方法，其总体流程如图 2-7 所示。根据仓库货物“下一层箱体仅在当前层堆满后方可叠加”的堆叠规则，本文将总货物数量估算划分为下层箱体数量估算与顶层箱体数量推断两个阶段。

这一流程设计体现了“先判别场景状态、后执行数量推理”的思路。原因在于，不同装载状态下可利用的信息并不相同，若不先区分场景类型而直接采用统一的数量计算方式，容易引入系统性误差。例如，空货物图像无需进入后续推理流程；仅包含下




图 2-7 后计数算法流程图

Figure 2-7 Flow chart of post counting algorithm

层目标的图像由于缺乏完整顶层结构信息，无法直接估算总数量；而完整堆叠图像则需要根据是否顶满选择不同的数量计算路径。通过将盘点流程拆解为若干具有明确业务含义的判断步骤，本文方法在逻辑上更贴近实际仓储盘点规则，也更具可解释性。

根据预测结果中上下层目标的存在状态，本文将堆叠货物盘点情形划分为以下三类：

a) 检测结果为空。若预测结果中未检测到任何目标，即类别数组为空，则可直接判定该图像中无货物，数量记为 0。

b) 仅检测到下层货物。若预测结果中仅包含类别 0，而不包含类别 1，则说明图像中缺乏顶层结构信息，无法直接判断完整堆叠关系，如图 2-8(a)所示。此时输出 $num=-1$ ，并将该类图像交由仓储管理系统进一步处理。

c) 同时检测到上层与下层目标。该情形为最常见的完整堆叠场景，需要进一步区分顶层满载和顶层未满载两种情况。若顶层判定为满载，则总货物数量可依据上下层




图 2-8 立体仓库堆叠货物盘点的三种情况

Figure 2-8 Three situations for inventory of stacked goods in a three-dimensional warehouse

目标数量关系直接估算：

$$N_{total} = N_{up_box} \times (N_{down_box} + 1) \quad (2.4)$$

式中， N_{total} 为货物总数量， N_{up_box} 与 N_{down_box} 分别为上层和下层目标数量。若顶层未满载，则需进一步结合掩膜关键点与几何关系推理完整堆叠结构，并估算每层下层箱体数量 N_{layer} ，最终总货物数量表示为：

$$N_{total} = N_{up_box} + (N_{layer} \times N_{down_box}) \quad (2.5)$$

上述两种数量估计方式分别对应规则堆叠场景中的两类典型状态。顶层满载时，堆叠结构相对规则，可直接依据上下层数量关系推断总箱体数量；顶层未满载时，当前图像只能部分反映顶层覆盖状态，需要进一步利用掩膜几何关系估算次顶层箱体规模。正因为如此，本文将“满载检测”设为后处理流程中的关键分支节点，使数量计算过程建立在更稳定的状态判别基础上。

下面将分别对顶层满载检测算法以及基于掩膜关键点的层间面积比估计算法进行介绍，以说明本文后处理数量计算方法的具体实现过程。

2.2.1.1 基于几何关系的顶层满载检测算法 当场景中同时存在上下层目标时，首先需要判断顶层是否处于满载状态。为此，本文提出一种基于掩膜几何关系的顶层满载检测算法，其流程见表 2-1。该算法首先对实例掩膜进行轮廓提取，并利用凸包运算获取边界角点，以近似描述货物的平面外形与空间占位关系。随后，根据模型预测标签将

表 2-1 基于几何关系的顶层满载检测算法

Table 2-1 Top-layer full-load detection algorithm based on geometric relationships

步骤	具体内容
输入	预测标签列表 <code>pred_labels</code> , 掩模列表 <code>masks</code>
输出	是否满载 (布尔值)
1	初始化角点集合 <code>pts_list</code>
2	遍历所有实例掩模并提取轮廓
3	对有效轮廓计算凸包角点 <code>pts</code>
4	根据预测标签划分上层与下层目标集合
5	计算下层目标最高点的纵坐标 <code>dn_top_y</code>
6	计算上层目标凸包中心的纵坐标 <code>up_center_y</code>
7	若 <code>up_center_y > dn_top_y</code> , 则判定为满载
8	否则判定为未满载

实例划分为上层货物集合与下层货物集合, 并依据图像坐标系下的几何位置关系比较二者在垂直方向上的相对位置, 从而判断上层目标是否覆盖下层顶部区域。

该算法的核心思想在于利用二维图像中的几何关系替代难以直接获取的深度信息。由于立体仓库监控图像通常仅提供单视角 RGB 信息, 模型无法像多传感器系统那样直接获得精确空间深度, 因此需要借助掩膜轮廓、凸包角点以及目标中心位置等几何线索间接判断层间遮挡关系。对于堆叠较规则的箱体场景而言, 这种基于几何关系的推断方式能够较好地适配仓储业务中的满载判别需求, 并且实现成本较低、可解释性较强。

这种基于几何中心与边界点的比较方式, 能够在无深度信息的条件下利用二维平面几何关系实现有效的层间遮挡判断。因此, 该算法能够作为后续数量估计的前置判别步骤, 为不同盘点情形下的数量推断提供依据。

进一步来看, 顶层满载检测的意义不仅在于选择不同计数公式, 更在于降低后续数量推理的不确定性。若将未满载场景误判为满载, 则总数量估计会因满层假设而显著偏大; 若将满载场景误判为未满载, 则又会增加不必要的几何估计步骤并引入额外误差。因此, 满载状态判别的准确性直接影响后处理算法整体稳定性, 也是本文将其独立设计为一个子算法的重要原因。

2.2.1.2 掩膜关键点驱动(layer间面积比)估计算法 当顶层未满载时,无法直接依据满层假设完成总数量估计,因此需要进一步估算其下方次顶层箱体数量。针对这一问题,本文提出一种基于掩膜关键点驱动(layer间面积比)估计方法,其流程见表 2-2,关键点示意见图 2-9。

该方法的设计基础在于:当顶层未满载时,图像中仍可通过顶层与次顶层掩膜的几何关系观察到一定的结构比例特征。若能够从掩膜中提取具有代表性的关键点,并结合交点关系和面积比构建几何约束,则有可能在不直接观察完整次顶层结构的情况下,对其规模进行合理估计。相比完全依赖人工规则或单纯使用目标框面积进行近似,基于掩膜关键点的估计方式能够更充分利用实例分割结果中的轮廓信息,因而具有更强的针对性。

在计算过程中,需要求解不同候选边之间的交点,以确定上下层结构之间的空间重叠关系。设任意两条线段分别为 P_1P_2 与 Q_1Q_2 , 其中 $P_1(x_A, y_A)$ 、 $P_2(x_B, y_B)$ 、 $Q_1(x_C, y_C)$ 、 $Q_2(x_D, y_D)$, 其斜率可表示为:

$$k_1 = \frac{y_B - y_A}{x_B - x_A}, \quad k_2 = \frac{y_D - y_C}{x_D - x_C} \quad (2.6)$$

根据两条直线的一般式方程,可进一步写为矩阵形式:

$$\begin{pmatrix} a_1 & b_1 \\ a_2 & b_2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} -c_1 \\ -c_2 \end{pmatrix} \quad (2.7)$$

其中, (x, y) 为两条线段的交点坐标。公式(2.6)和公式(2.7)用于求解候选边对的交点集合,并为后续面积比估计提供几何基础。

交点求解的作用在于确定不同层结构在图像平面中的几何延展关系。通过关键边之间的交点,可以推断顶层与次顶层在可见区域上的相对位置,并进一步构建面积估计所需的近似区域。对于规则堆叠的箱体场景而言,这种处理方式虽然属于近似推断,但能够在没有深度信息和多视角图像的条件下较稳定地反映层间结构比例,从而提高数量估计的可操作性。

上述方法充分利用了实例分割掩膜所提供的轮廓与几何信息,能够在顶层未满载的情况下提升数量估计的可解释性和准确性,从而增强盘点算法对复杂堆叠场景的适应能力。

总体来看,本文后处理数量计算方法形成了“实例识别 - 状态划分 - 几何判定 - 数

表 2-2 掩膜关键点驱动(layer)面积比算法

Table 2-2 Interlayer area-ratio algorithm driven by mask keypoints

步骤	具体内容
输入	上层掩膜集合 <code>up_box_masks</code> ，下层掩膜集合 <code>down_box_masks</code>
输出	估算的次顶层箱体数量 <code>N_{layer}</code>
1	提取次顶层关键点 A 、 B 、 C 、 D 、 G
2	根据 AB 与 CD 的几何关系求解交点 O_1
3	提取顶层关键点 $_A$ 、 $_B$ 、 $_C$ 、 $_D$ 、 $_E$ 、 $_F$
4	对候选边对求交，得到顶层交点集合，并取平均位置作为 O_2
5	计算顶层单箱体区域面积 S_1
6	计算次顶层整体区域面积 S_2
7	由面积比得到 $N_{layer} = S_2/S_1$
8	返回估计结果 <code>N_{layer}</code>

量估计”的完整流程。其中，实例分割结果提供目标边界与类别信息，满载检测算法负责进行状态分流，面积比估计算法负责处理更复杂的未满载场景，最终共同完成库存数量推断。与仅依赖检测框数量的简单计数方式相比，该方法更符合实际仓储盘点业务逻辑，也更能体现本文研究在任务层面的完整性。

本章首先分析了基线模型 YOLO11s-Seg 的结构特点及其在复杂堆叠场景中的局限性，指出其在关键区域建模、下采样信息保持和方向性空间结构表达方面仍存在改进空间。在此基础上，本文提出改进模型 YOLO11-StackLite，并从注意力机制、特征融合结构和方向性卷积建模三个方面对关键模块进行了设计。随后，结合实例分割结果与空间几何关系，构建了面向堆叠货物场景的后处理数量计算方法，使模型输出能够进一步转化为可解释的库存数量信息。由此，第 2 章完成了从视觉识别到数量推理的完整方法构建，为第 4 章的实验验证提供了技术基础，也为第 3 章进一步开展模型压缩研究提供了可压缩的高性能基线模型。




图 2-9 目标掩膜凸包点和关键点示意图

Figure 2-9 Schematic diagram of convex hull points and key points on the target mask

第三章 面向边缘部署需求的 YOLO11-StackLite 模型压缩方法

第 2 章提出的 YOLO11-StackLite 模型在复杂堆叠货物场景下取得了较好的检测、分割与盘点效果。然而，随着模型识别能力的增强，网络结构中仍然存在一定程度的参数冗余与计算冗余，这在资源充足的训练环境中并不构成明显限制，但在算力和存储资源均较为有限的应用场景中，会直接影响模型的实际应用效率。对于立体仓库库存盘点任务而言，系统不仅要求模型具备较高的识别精度，还要求其能够在较低存储开销和较小计算负担下稳定运行。因此，在保持检测、分割与盘点性能尽量稳定的前提下，对模型进行压缩具有明确的工程价值和研究意义。

模型压缩的核心目标是在有限资源约束下提升模型的部署友好性。考虑到本文当前研究重点在于验证模型在边缘场景中的应用可行性，而非针对具体硬件平台进行系统级部署优化，因此本章主要从模型参数量、浮点运算量以及检测、分割与盘点相关指标等角度，对压缩效果进行间接评估。基于此，本文针对第 2 章构建的 YOLO11-StackLite，采用结构化剪枝降低模型复杂度^[27-28]，并结合知识蒸馏缓解压缩带来的性能退化^[25]，构建适用于堆叠货物盘点任务的轻量化模型。

3.1 模型压缩需求分析

YOLO11-StackLite 在第 2 章实验中已表现出较优的检测与分割性能，但其作为实例分割模型，仍包含较多卷积层、特征融合操作以及多分支结构。在复杂堆叠货物场景中，模型不仅需要提取目标轮廓信息，还需要保留层间结构信息以支持后续数量推理，因此网络结构通常比普通目标检测模型更加复杂。虽然这种结构设计能够提升识别精度，但也会带来更高的参数开销与理论计算开销。

在实际仓储盘点任务中，边缘侧设备往往具有算力有限、显存容量受限以及实时处理要求较高等特点。若模型参数规模过大、推理计算量过高，则可能增加部署成本，并影响系统响应效率。尤其对于本文的实例分割与数量推断联合任务而言，若仅关注检测精度而忽略模型复杂度，则难以满足实际应用对稳定性和时效性的要求。因此，有必要在尽量保持检测、分割和盘点性能的前提下，对模型进行轻量化处理。

进一步分析可知，本文任务中的模型压缩并非简单追求参数量最小化，而是强调

多项指标之间的综合平衡。一方面，box mAP 与 mask mAP 反映模型在目标定位和实例轮廓提取上的基础能力；另一方面，DA 与 CA 则进一步反映识别结果能否有效支撑库存盘点任务。因此，本文在压缩模型时不仅关注 Params 和 GFLOPs 的变化，还需要关注压缩后模型对后续盘点流程的影响。换言之，只有当压缩模型在复杂堆叠场景下仍保持较好的结构识别能力时，模型压缩才具有实际意义。

基于上述需求，本章从结构化剪枝和知识蒸馏两个方面开展研究：前者用于降低模型结构复杂度，后者用于弥补压缩过程中可能出现的性能损失。二者结合能够形成“降低复杂度 - 恢复性能”的压缩路径，更符合本文任务对精度与效率平衡的要求。

3.2 基于结构化剪枝的轻量化方法

3.2.1 结构化剪枝原理

模型剪枝是深度模型压缩中的常见方法之一，其基本思想是通过删除网络中的冗余结构单元，降低模型规模与计算复杂度^[24,26]。根据剪枝对象的不同，模型剪枝通常可分为非结构化剪枝与结构化剪枝两类。非结构化剪枝主要对单个权重连接进行剔除，虽然能够获得较高的稀疏率，但由于其稀疏结构不规则，实际部署时难以直接转化为显著的硬件加速收益。相比之下，结构化剪枝通常以卷积核、通道或模块为基本单位进行裁剪，压缩后的网络结构更加规则，更有利于后续模型部署与推理优化^[27-28]。

从任务适配性角度看，结构化剪枝更适合本文所研究的实例分割与盘点任务。原因在于，本文模型需要同时处理多尺度特征、掩膜预测以及结构信息推理，若采用不规则的非结构化稀疏方式，虽然在参数层面上可能具有较高压缩率，但在工程实现中难以稳定继承原模型的多分支结构优势。结构化剪枝通过保留网络拓扑的整体可解释性，使压缩后的模型更便于继续微调与蒸馏训练，也更适合作为后续部署基础。

考虑到本文研究目标是提升模型在边缘场景中的部署可行性，故选择结构化剪枝作为主要压缩手段。该方法不仅能够有效降低模型参数量和浮点运算量，而且在工程实现上更便于直接应用于现有推理框架。因此，本文采用基于通道重要性评估的结构化剪枝策略，对 YOLO11-StackLite 中的冗余结构进行压缩。

若记第 l 层卷积输出通道集合为 $\{c_i^l\}_{i=1}^{n_l}$ ，其重要性记为 s_i^l ，则结构化剪枝的基本目标可表示为在保持任务性能约束的前提下，删除低重要性通道集合 $\mathcal{P}$ ，从而最小化

模型复杂度：

$$\min C(\Theta \setminus \mathcal{P}) \quad (3.1)$$

其中， Θ 表示原模型参数集合， $C(\cdot)$ 表示模型复杂度度量，如参数量或浮点运算量。对应地，需满足压缩后模型在检测、分割与盘点任务上的性能下降控制在可接受范围内。

3.2.2 YOLO11-StackLite 剪枝对象选择

在对 YOLO11-StackLite 进行剪枝时，若对整个网络进行无差别压缩，容易导致关键特征表达能力显著下降，进而影响实例分割和后续盘点性能。因此，剪枝对象的选择需要兼顾压缩率与任务性能稳定性。

结合第 2 章模型结构特点，本文优先将 Neck 中的特征融合层以及部分卷积层作为主要剪枝对象。其原因在于：Neck 负责多尺度特征融合，内部存在一定程度的通道冗余，通过合理剪枝可在不显著破坏基础特征表达能力的前提下降低模型复杂度。对于 Backbone 中承担基础表征任务的关键层，则采用相对保守的剪枝策略，以避免因过度压缩导致底层纹理信息和结构特征损失。此外，对于检测头相关结构，也仅进行适度压缩，以保证输出层的稳定性。

从具体结构上看，YOLO11-StackLite 中新增的 C2SASA、SSConv 和 C3k2_QDConv 模块分别承担关键区域建模、轻量化下采样和方向性空间结构提取等任务。对于其中与基础结构表达密切相关的部分，本文采用保守处理策略；而对于特征融合过程中存在明显冗余的卷积通道，则优先纳入剪枝范围。这样的处理方式有利于在不破坏模型核心结构优势的条件下释放冗余参数。

通过上述剪枝对象选择方式，可以在保持模型核心表达能力的同时，尽量释放结构冗余，从而为后续蒸馏精度恢复阶段提供更稳定的学生模型基础。该策略也体现了本文模型压缩的基本原则，即压缩过程服从任务需求，而非单纯追求极限压缩率。

3.2.3 通道重要性评估与剪枝率设定

为识别模型中可压缩的冗余结构单元，本文采用基于通道重要性评估的方式对候选卷积层进行分析。设第 l 层第 i 个通道的重要性记为 s_i^l ，则可根据权重响应、缩放因子或特征贡献等指标对各通道进行排序。本文从任务稳定性与实现简洁性出发，采用统一的重要性评估准则对候选层通道进行排序，并根据排序结果剔除低重要性通道。

重要性评估完成后, 还需要进一步确定剪枝率。剪枝率过低时, 模型复杂度下降有限, 难以体现压缩方法的实际价值; 剪枝率过高时, 又容易导致特征表达能力显著退化, 从而影响检测、分割和盘点性能。因此, 剪枝率的设定本质上是模型复杂度与任务性能之间的平衡过程。本文采用逐步增加剪枝率的方式观察性能变化趋势, 并将不同剪枝率下的压缩结果在第 4 章中进行对比分析, 以确定更合理的压缩范围。

设某一层通道总数为 n_l , 预设剪枝率为 r , 则保留通道数可表示为:

$$\hat{n}_l = n_l(1 - r) \quad (3.2)$$

其中, $\hat{n}_l$ 表示剪枝后该层保留的通道数。通过对不同层采用一致或分层设定的剪枝比例, 可以得到具有不同复杂度水平的压缩模型。基于这一思想, 本文在后续实验中比较不同剪枝率下模型的综合性能变化, 并据此分析压缩方案的适用范围。

3.2.4 剪枝流程设计

本文采用的结构化剪枝流程主要包括以下四个步骤:

- (1) 训练原始 YOLO11-StackLite 模型。首先在 TBD 数据集上完成原始模型训练, 获得作为压缩基准的高性能模型。
- (2) 评估结构单元重要性。根据卷积通道的重要性指标, 对网络中待剪枝层的通道进行排序。本文采用基于通道重要性评估的方式识别冗余结构单元, 以确定剪枝对象。
- (3) 执行结构化剪枝。按照设定的剪枝比例, 对选定层中的低重要性通道进行裁剪, 得到初始剪枝模型。
- (4) 对剪枝模型进行微调。由于结构化剪枝会改变原始模型的特征分布, 因此需要对剪枝后的模型进行重新训练或微调, 以恢复其基础任务性能。

上述流程对应了本文压缩方法中的“先分析冗余、后裁剪结构、再恢复性能”这一基本思路。其中, 微调阶段具有关键作用, 因为剪枝操作改变了原模型参数分布和特征传递路径, 若缺少微调过程, 压缩模型往往难以稳定继承原始模型的识别能力。通过微调, 模型能够重新适应压缩后的结构形式, 为后续蒸馏补偿提供更好的初始化基础。

通过上述过程, 本文可获得参数量和计算复杂度均明显下降的轻量化模型。然而, 仅采用剪枝通常会带来不同程度的精度下降, 因此下一节进一步引入知识蒸馏方法, 对

压缩模型进行性能补偿。

3.3 基于知识蒸馏的精度恢复方法

3.3.1 知识蒸馏原理

知识蒸馏的核心思想是利用性能较强的教师模型指导轻量化学生模型训练，使学生模型在较小规模下尽可能继承教师模型的判别能力^[25]。在模型压缩任务中，剪枝能够有效降低模型复杂度，但也可能削弱模型的特征表达能力，进而导致检测、分割以及盘点性能下降。为缓解这一问题，本文在剪枝后引入知识蒸馏策略，通过教师模型向学生模型传递输出层响应和中间特征信息，从而提升压缩模型的性能恢复能力。

对本文任务而言，知识蒸馏的价值不仅体现在检测精度恢复上，还体现在对实例轮廓表达与盘点稳定性的间接提升上。由于后处理数量计算方法建立在检测与分割结果之上，一旦剪枝导致掩膜质量下降或结构识别不稳定，最终盘点准确率也会受到影响。因此，将蒸馏机制引入模型压缩流程，有助于在保持轻量化优势的同时稳定下游数量推理效果。

3.3.2 教师模型与学生模型构建

本文以第 2 章训练完成的 YOLO11-StackLite 作为教师模型。该模型在 TBD 数据集上具有较好的检测、分割和盘点性能，能够为轻量化模型提供较为充分的知识指导。学生模型则为结构化剪枝后得到的压缩模型，其参数量和计算复杂度明显低于教师模型，但在初始状态下存在一定性能损失。

通过将原始高性能模型作为教师模型、将剪枝模型作为学生模型，可以建立“高性能完整模型 - 轻量化压缩模型”之间的知识迁移关系，从而在保持压缩效果的同时尽可能恢复学生模型的任务性能。相比直接对剪枝模型进行长轮次微调，蒸馏训练能够为学生模型提供更稳定的优化目标，使其在有限模型容量下学习更有判别力的特征表示。

从结构对应关系来看，教师模型与学生模型共享相同的总体任务目标和大部分网络层级语义，只是在通道规模和部分结构容量上存在差异。这种“同构压缩”关系有利于教师模型中的高层语义信息和中间层结构信息向学生模型平稳传递，也使蒸馏过程更适合本文的实例分割与盘点联合任务。

3.3.3 蒸馏信息选择与约束方式

知识蒸馏的有效性在很大程度上取决于蒸馏信息的选择。若仅对输出类别响应进行约束，虽然能够在一定程度上恢复模型判别能力，但对于实例分割任务而言，仍可能无法充分恢复中间特征层中的结构表达信息。因此，本文在蒸馏过程中同时考虑输出层响应和中间层特征两类信息。

其中，输出层响应蒸馏用于约束学生模型在最终预测结果上向教师模型靠近，重点保证检测与分割结果的一致性；中间特征蒸馏则用于约束学生模型在特征表达层面学习教师模型的结构信息，重点提高其对复杂堆叠场景中边缘、轮廓和层间关系的建模能力。前者偏重结果一致性，后者偏重表示一致性，两者结合能够更有效地支撑压缩模型的性能恢复。

若记教师模型和学生模型在某一蒸馏层的特征分别为 F_t 和 F_s ，则特征蒸馏约束可写为：

$$L_{\text{feat}} = \|F_s - F_t\|_2^2 \quad (3.3)$$

若记教师模型和学生模型的输出响应分别为 P_t 和 P_s ，则输出响应蒸馏约束可抽象表示为：

$$L_{\text{resp}} = D(P_s, P_t) \quad (3.4)$$

其中， $D(\cdot)$ 表示学生模型与教师模型输出之间的距离度量。上述两类约束共同构成蒸馏学习的核心内容。

3.3.4 蒸馏损失设计

为提高学生模型对教师模型知识的学习能力，本文在原始任务损失的基础上引入蒸馏损失，构建联合优化目标。原始任务损失主要用于保证学生模型在目标检测与实例分割任务上的基本学习能力；蒸馏损失则用于约束学生模型在输出响应或中间特征层面向教师模型靠近。

设学生模型原始任务损失为 L_{task} ，蒸馏损失为 L_{distill} ，则总损失可表示为：

$$L = L_{\text{task}} + \lambda L_{\text{distill}} \quad (3.5)$$

其中， λ 为蒸馏损失权重系数，用于平衡原始任务学习与知识迁移之间的关系。

进一步地，蒸馏损失可由输出层蒸馏损失和特征层蒸馏损失共同构成，即：

$$L_{\text{distill}} = \alpha L_{\text{resp}} + \beta L_{\text{feat}} \quad (3.6)$$

其中， α 和 β 分别表示两类蒸馏信息的权重系数。通过调节不同损失项的权重，可使学生模型在保持任务目标一致的前提下，更充分地学习教师模型的判别能力和结构表达能力。

在具体实现中，本文采用以下两类蒸馏信息：

- (1) 输出层响应蒸馏。通过约束学生模型与教师模型在最终输出层上的预测响应一致性，增强学生模型的判别能力。
- (2) 中间特征蒸馏。通过约束学生模型与教师模型在中间层特征表达上的接近程度，帮助学生模型学习更加稳定的特征表示。

上述蒸馏方式能够在不显著增加推理成本的前提下，提高剪枝模型在复杂堆叠场景下的检测与分割性能，为后续盘点任务提供更可靠的识别基础。对于本文的联合任务而言，这种“任务损失 + 蒸馏损失”的优化方式能够兼顾基础识别能力和压缩模型的结构表达质量，是一种较为适合的性能恢复路径。

3.4 压缩模型构建与训练流程

综合结构化剪枝与知识蒸馏策略，本文的压缩模型构建流程如下：

- (1) 首先在 TBD 数据集上训练完整的 YOLO11-StackLite 模型，作为后续压缩与蒸馏的基准模型；
- (2) 然后基于通道重要性评估结果，对模型中选定的卷积结构执行结构化剪枝，得到初始轻量化模型；
- (3) 对剪枝模型进行微调，以恢复其基础检测与分割能力；
- (4) 以原始 YOLO11-StackLite 为教师模型，以剪枝模型为学生模型，引入知识蒸馏策略进行进一步训练；
- (5) 最终获得兼顾识别性能与模型复杂度的压缩模型。

该流程实现了“先压缩、后补偿”的模型优化思路。其中，结构化剪枝负责降低模型复杂度，知识蒸馏负责缓解精度下降。通过两者结合，可以在尽量保持实例分割与盘点性能的同时，为后续资源受限场景下的模型应用提供更好的部署基础。

从训练组织角度看，原始模型、剪枝模型和蒸馏后模型之间形成了逐步演进关系：原始模型提供高性能基准，剪枝模型提供复杂度下降后的轻量化结构，而蒸馏后模型则在保持轻量化结构的基础上进一步恢复性能。这种分阶段训练策略能够使不同阶段的优化目标更加清晰，避免在同一训练过程中同时承担过多优化任务，从而提高模型压缩过程的可控性。

此外，该流程还具有较好的扩展性。当后续需要进一步引入更细粒度的压缩策略或针对特定硬件平台开展部署优化时，仍可在现有流程基础上继续增加针对性步骤，而不需要完全改变当前模型压缩框架。因此，本文所构建的压缩流程不仅适用于当前研究任务，也为后续扩展研究保留了较好的接口。

3.5 本章小结

本章针对 YOLO11-StackLite 在边缘部署需求下仍存在一定参数冗余与计算冗余的问题，提出了结合结构化剪枝与知识蒸馏的模型压缩方案。首先，从边缘场景应用需求出发，分析了模型压缩的必要性，并明确了本文压缩研究需要兼顾检测、分割与盘点性能的基本要求；随后，采用结构化剪枝对模型冗余结构进行裁剪，从剪枝原理、剪枝对象选择、通道重要性评估以及剪枝流程设计等方面构建了轻量化策略；在此基础上，引入知识蒸馏策略缓解剪枝带来的性能退化，从教师模型与学生模型构建、蒸馏信息选择以及联合损失设计等方面形成了完整的性能恢复路径。

总体来看，本章构建了面向堆叠货物盘点任务的“结构化剪枝 + 知识蒸馏”模型压缩框架，使压缩模型在降低参数量和计算复杂度的同时，尽量保持实例分割与盘点相关性能。上述研究为后续围绕压缩模型检测、分割与盘点综合性能的实验评价提供了更充分的方法基础，也为全文进一步扩展到资源受限场景下的应用分析奠定了理论支撑。

第四章 实验与结果分析

4.1 实验数据集

本文构建了一个面向堆叠货物数量计算任务的图像数据集，命名为 TBD (Tobacco Box Dataset)。该数据集来源于烟草立体仓库中烟箱堆叠的真实场景图像，旨在为目标检测、实例分割和库存盘点等下游任务提供数据支撑。

TBD 共包含 794 张图像，均由仓库监控系统采集，图像分辨率统一为 1280×960。为增强模型对堆叠结构的泛化能力，数据集采用两类实例分割标注：down_box 表示位于非顶层的箱体，up_box 表示位于堆叠最上层的箱体。该标注方式能够同时刻画层间结构关系与目标轮廓信息，为后续实例分割与数量推理提供基础。

在数据划分方面，本文采用五折交叉验证 (5-fold cross-validation) 策略评估模型的稳定性与泛化能力。每一折中，80% 的样本用于训练，20% 的样本用于验证。除检测与分割标注外，每张图像还附带字段 layer_count，用于记录该图像在满层条件下每层堆叠箱体的数量，可为后续数量推理提供依据。记非顶层箱体层数为 N_{down} ，最上层箱体数量为 N_{up} ，则箱体总数记为 N_{total} 。

与常规通用实例分割数据集相比，TBD 的任务属性更具针对性。一方面，图像均来自真实仓储监控视角，存在固定拍摄角度、光照差异、局部遮挡和背景纹理相似等问题；另一方面，标注类别并非简单按照目标语义划分，而是显式区分顶层与非顶层箱体，从而将实例分割任务与后续数量推理过程关联起来。这意味着模型不仅需要识别目标轮廓，还需要具备一定的层次结构判别能力。正因如此，TBD 更适合作为本文所研究盘点任务的实验基础，也能够较好反映方法在真实仓储场景中的适用性。

采用五折交叉验证而非单次固定划分，也具有明确的实验意义。由于本文数据集规模相对有限，若仅采用单次训练集/验证集划分，实验结果容易受到样本偶然性的影响。五折交叉验证能够在不同数据划分下重复评估模型，使实验结果更能反映模型在不同场景组合下的稳定性。同时，本文后续各项实验均统一基于该划分策略开展，从而保证模块消融、模型对比和盘点实验之间具有一致的评价基础。

4.2 评价指标

为全面评估模型在实例分割与库存盘点任务中的性能，本文从检测分割精度、模型复杂度和盘点准确性三个方面设置评价指标。

在检测与分割精度评价方面，本文采用目标检测领域广泛使用的平均精度均值 mAP (mean Average Precision)，重点考察 COCO 评估标准下的 mAP@0.5:0.95，以衡量模型在不同 IoU (Intersection over Union) 阈值下的综合性能。其中，box mAP 用于评估目标边界框定位精度，mask mAP 用于评估预测掩膜与真实区域之间的一致性。两项指标共同反映模型在检测与分割任务中的整体表现。

在模型效率评价方面，本文采用以下两项指标：

a) GFLOPs (Giga Floating Point Operations)，表示模型单次前向推理所需的浮点运算量，用于衡量模型的理论计算复杂度；

b) Params (Parameters)，表示模型中可训练参数的总数，用于衡量模型的存储开销与部署成本。

在盘点任务评价方面，本文采用检测准确率 (Detection Accuracy, DA) 和盘点准确率 (Counting Accuracy, CA)。其中，DA 用于评估模型对上层与非顶层箱体识别结果的正确性；CA 用于评估模型对整幅图像箱体总数预测结果的准确性。通过上述指标，可以从“识别是否正确”和“最终盘点是否正确”两个层面综合分析模型的应用性能。

需要指出的是，本文实验评价并不局限于通用实例分割任务中的 box mAP 和 mask mAP。对于立体仓库堆叠货物盘点问题而言，检测与分割精度只是后续数量推理的基础，若模型在局部边界识别、顶层目标判别或上下层结构区分方面存在偏差，则最终盘点结果仍可能出现错误。因此，本文将 DA 和 CA 一并纳入评价体系，以反映模型性能是否真正能够转化为库存盘点能力。这样的指标设置也使得第 2 章方法改进与第 3 章压缩研究都能够围绕同一任务目标展开比较。

4.3 实验环境与参数设置

实验硬件环境包括 13th Gen Intel(R) Core(TM) i7-13620H CPU@2.40GHz 和 NVIDIA GeForce RTX 4090 GPU。实验开发环境为 PyCharm，Python 版本为 3.9.19，深度学习框架为 PyTorch 2.3.0，CUDA 版本为 12.1。

所提出的 YOLO11-StackLite 模型及其余 YOLO 对比模型均基于 Ultralytics YOLO 实例分割框架进行开发与训练，输入图像尺寸统一设置为 640×640。根据预实验结果，最终训练参数设置如下：训练轮数为 200，批次大小为 64，初始学习率为 0.01，优化器采用 SGD (Stochastic Gradient Descent)，动量参数设置为 0.937，权重衰减系数设置

为 0.0005。除特别说明外，所有对比实验均采用相同的数据划分方式和训练配置，以保证实验结果的可比性。

上述训练设置主要基于两方面考虑。其一，输入尺寸统一为 640×640，有利于在保证细节表达能力的同时控制显存开销和训练时间，使不同模型在统一尺度下进行公平比较。其二，训练轮数、优化器和学习率等参数均根据预实验结果进行设定，以兼顾模型收敛稳定性与实验效率。对于本文涉及的多组对比实验而言，若不同模型采用差异较大的训练策略，则结果易受到额外变量影响，因此本文尽可能统一训练条件，以保证性能差异主要来自模型结构本身而非训练配置差异。

对于第 3 章涉及的压缩模型实验，本文同样延续上述训练与评估设置，并在原模型、剪枝模型和剪枝蒸馏模型之间保持一致的数据划分与评价口径。这样可以确保压缩前后的性能变化能够真实反映模型复杂度调整所带来的影响，而不会被额外实验条件所掩盖。

4.4 结果与分析

为验证所提方法的有效性，本文依次开展消融实验、不同实例分割模型性能对比实验以及数量计算评估实验。实验从检测与分割精度、模型复杂度以及盘点准确率等多个角度，对 YOLO11-StackLite 的性能进行综合分析。

需要说明的是，本文实验分析遵循“模块有效性验证 - 综合性能比较 - 任务应用验证 - 压缩可行性评估”的逻辑展开。其中，消融实验用于分析第 2 章各模块设计的独立作用及协同关系；模型对比实验用于验证所提方法在主流实例分割模型中的综合竞争力；数量计算评估用于检验实例分割结果是否能够有效支撑盘点任务；模型压缩实验则进一步验证第 3 章提出的轻量化路线是否能够在保持主要性能的同时降低模型复杂度。通过这一实验链条，可以较为完整地支撑全文所提出的方法设计。

4.4.1 消融实验

消融实验的目的是验证 YOLO11-StackLite 中各关键模块的独立贡献及其协同作用。为此，本文在 TBD 数据集上开展五折交叉验证，对新提出的 C2SASA 注意力模块、SSConv 模块以及 C3K2-QDConv 模块进行逐项消融分析。实验结果如表 4-1 所示，其中“√”表示引入对应模块，Params 表示模型参数量，GFLOPs 表示模型的浮点运算量。

该实验的核心在于回答两个问题：一是第 2 章提出的各个改进模块是否分别对模

表 4-1 YOLO11-StackLite 各模块消融实验结果对比

Table 4-1 Ablation study results of YOLO11-StackLite with different modules

C2SASA	SSConv	C3K2-QDConv	Params/M	GFLOPs	Fold1		Fold2		Fold3		Fold4		Fold5		Avg	
					box	mask	box	mask	box	mask	box	mask	box	mask	box	mask
√			10.1	35.5	87.5	87.2	86.2	85.7	85.2	84.6	85.5	85.0	79.8	77.1	84.8	83.9
			10.0	35.3	88.2	87.6	86.6	86.4	85.9	85.0	85.8	85.1	80.4	77.9	85.4	84.4
	√		9.6	35.0	88.1	86.7	86.8	86.5	85.0	84.8	85.7	85.3	80.0	77.8	85.1	84.2
		√	9.9	35.5	87.8	87.3	86.7	86.6	85.6	84.8	85.8	85.3	80.0	77.3	85.2	84.3
	√	√	9.5	34.9	87.9	87.4	86.9	86.2	85.9	85.0	85.8	85.2	80.2	77.4	85.3	84.2
√	√	√	9.4	34.9	88.6	87.8	87.2	86.7	86.2	85.2	86.0	85.6	80.6	78.0	85.7	84.7

型性能产生积极作用；二是这些模块组合后是否能够形成稳定的性能增益。由于本文方法并非单一模块替换，而是从注意力建模、下采样结构和方向性空间表达三个层面同时改进基线模型，因此仅报告最终模型结果并不足以说明设计合理性。通过逐项消融，可以更清楚地分析各模块对应的功能定位与性能贡献。

由表 4-1 可见，第一行为未引入新增模块的基线 YOLO11s-Seg 模型。单独引入 C2SASA 后，模型的平均 box mAP 和平均 mask mAP 分别由 84.8% 和 83.9% 提升至 85.4% 和 84.4%，同时参数量与 GFLOPs 均略有下降。这说明该注意力机制在增强关键区域建模能力的同时，也具有一定的轻量化效果。

单独引入 SSConv 后，模型参数量下降至 9.6 M，GFLOPs 下降至 35.0，平均 box mAP 和平均 mask mAP 分别提升至 85.1% 和 84.2%。这一结果表明，SSConv 在降低下采样阶段计算开销的同时，仍能维持较好的特征表达能力。单独引入 C3K2-QDConv 后，模型平均 box mAP 和平均 mask mAP 分别达到 85.2% 和 84.3%，说明增强方向性空间建模后，模型对复杂堆叠结构的识别能力得到提升。

从组合实验结果来看，三者联合引入后模型在五折交叉验证中取得最优结果，平均 box mAP 提升至 85.7%，平均 mask mAP 提升至 84.7%，同时参数量下降至 9.4 M，GFLOPs 降至 34.9。该结果表明，三个模块在功能上具有互补性：C2SASA 负责增强关键区域注意力建模，SSConv 负责压缩下采样开销并提升多尺度特征提取效率，C3K2-QDConv 负责强化方向性结构建模。三者协同作用后，模型在精度与复杂度之间取得了更优平衡。

进一步来看，C2SASA 的改进效果主要体现在提升模型对关键区域的筛选与聚焦能力，这对堆叠场景中顶层箱体的识别尤为重要。SSConv 的作用则更偏向于以较低

计算代价保留多尺度特征，使模型在执行下采样时不至于过度损失边界与纹理信息。C3K2-QDConv 则从空间结构角度增强了模型对方向性边缘和堆叠轮廓的感知能力，从而提高了复杂遮挡条件下的识别鲁棒性。三者分别对应不同层面的改进目标，这也是联合使用后能够获得更稳定增益的重要原因。

此外，表 4-1 中各折结果也表明，YOLO11-StackLite 的提升并非仅来自个别数据划分下的偶然收益，而是在多数折次上均保持优于基线模型的趋势。这说明所提出模块对不同场景组合具有较好的适应能力，验证了模型改进方案的稳定性。对于面向实际仓储应用的盘点任务而言，这种跨折稳定性比单一场景下的局部最优结果更具有参考价值。

为更直观地展示改进前后模型的分割效果，本文选取典型样例对原始 YOLO11s-Seg 模型和改进后的 YOLO11-StackLite 模型进行可视化对比，结果如图 4-1 所示。

从图 4-1 可以看出，YOLO11s-Seg 在部分复杂场景下存在漏检和误检现象。例如，图 4-1(a) 对应场景中，基线模型较改进模型漏检了一个顶层箱体；图 4-1(c) 对应样例中，某顶层箱体置信度较低而被阈值过滤，同时还出现了底层误检；图 4-1(e) 所示基线结果在掩膜完整性方面也明显弱于图 4-1(f) 中的 YOLO11-StackLite。整体来看，改进后的模型在复杂堆叠场景中的检测稳定性与分割完整性均优于基线模型，这与表 4-1 中的定量结果保持一致。

4.4.2 不同实例分割模型性能对比

本节实验旨在验证 YOLO11-StackLite 相对于当前主流实例分割方法的综合性能优势。为保证实验条件的一致性，所有模型均在 TBD 数据集上采用五折交叉验证进行评估，其中 SOLOv2、QueryInst 和 SparseInst 基于 MMDetection 框架训练，并采用官方推荐配置。对比结果如表 4-2 所示。

选择这些模型作为对比对象，主要是为了覆盖不同技术路线下的代表性实例分割方法。QueryInst、SOLOv2、SparseInst 和 Mask2Former 分别代表查询式分割、位置编码分割、稀疏实例分割以及基于 Transformer 的统一分割框架；YOLOv8s-Seg 和 YOLO11s-Seg 则代表当前更适合实时应用的 YOLO 系列方法。通过同时比较传统高复杂度方法与轻量化实时方法，可以更全面地评估 YOLO11-StackLite 在复杂堆叠场景中的相对优势。




图 4-1 改进前后模型实例分割效果对比

Figure 4-1 Comparison of instance segmentation results before and after improvement

表 4-2 不同模型在实例分割任务中的五折交叉验证性能比较

Table 4-2 Five-fold cross-validation performance comparison of different instance segmentation models

Model	Params/M	GFLOPs	Fold1		Fold2		Fold3		Fold4		Fold5		Avg	
			box	mask	box	mask	box	mask	box	mask	box	mask	box	mask
QueryInst	172.0	130.0	78.8	78.0	76.3	75.5	77.5	76.2	74.4	73.5	67.2	65.7	74.8	73.8
SOLOv2	46.2	217.0	79.5	78.7	78.3	77.5	77.4	76.1	76.6	75.4	66.5	65.3	75.7	74.6
SparseInst	57.3	107.0	80.4	79.7	77.0	76.0	78.5	77.8	80.8	80.3	71.6	70.9	77.7	76.9
Mask2Former	44.0	195.0	84.0	83.3	82.4	81.6	81.0	79.9	77.1	76.0	70.3	69.3	80.0	78.0
YOLOv8s-Seg	10.5	37.6	88.0	87.3	86.5	85.9	86.4	85.2	85.6	85.2	77.9	77.4	84.9	84.2
YOLO11s-Seg	10.1	35.5	87.5	87.2	86.2	85.7	85.2	84.6	85.5	85.0	79.8	77.1	84.8	84.0
YOLO11-StackLite	9.4	34.9	88.6	87.8	87.2	86.7	86.2	85.2	86.0	85.6	80.6	78.0	85.7	84.7

由表 4-2 可见，在模型复杂度方面，YOLO11-StackLite 的参数量为 9.4 M，GFLOPs 为 34.9，显著低于 QueryInst、SOLOv2、SparseInst 和 Mask2Former 等传统方法，同时也低于 YOLOv8s-Seg 和 YOLO11s-Seg。这说明所提模型在结构设计上具有更好的轻量化特性，在资源受限场景下表现出更强的部署友好性。

在精度方面，YOLO11-StackLite 在五折交叉验证中的平均 box mAP 和平均 mask mAP 分别达到 85.7% 和 84.7%，均为所有对比模型中的最优结果。与基线 YOLO11s-Seg 相比，所提模型在参数量和 GFLOPs 略有下降的同时，box mAP 提升 0.9 个百分点，mask mAP 提升 0.7 个百分点；与 YOLOv8s-Seg 相比，所提模型在复杂度更低的情况下仍取得更优结果。这表明，YOLO11-StackLite 不仅能够保持 YOLO 系列模型的实时性优势，还能在复杂堆叠场景下获得更稳定的分割性能。

进一步分析可知，传统实例分割方法虽然在一般场景下具有较强的表达能力，但模型复杂度较高，且在本任务中的跨折稳定性不如 YOLO 系列模型。YOLO11-StackLite 在维持较低计算开销的同时取得更优精度，说明本文提出的结构改进更符合立体仓库堆叠货物场景对“精度-效率平衡”的实际需求。

这一结果也反映出，立体仓库堆叠货物场景与通用自然图像实例分割场景存在明显差异。该任务更强调规则堆叠结构中的局部边界识别、上下层关系区分以及复杂遮挡下的轮廓恢复能力。对于这类任务，模型不仅需要较强的表达能力，还需要尽可能减少无关信息干扰，并在较低复杂度下保持稳定输出。YOLO11-StackLite 正是围绕这些任务特征进行结构设计，因此在本实验中表现出更优的综合性能。

4.4.3 数量计算评估

本节实验主要评估不同实例分割模型在库存盘点任务中的应用效果。为此，本文采用检测准确率 (Detection Accuracy, DA) 与盘点准确率 (Counting Accuracy, CA) 两项指标。DA 用于评估模型对堆叠结构中上层与非顶层箱体识别结果的正确性；当模型预测的两类箱体数量均与标注一致时，判定该样本检测正确。CA 用于衡量模型对整幅图像箱体总数预测结果的准确程度，其定义为数量识别正确的图像占总图像数量的百分比，计算公式为：

$$CA = \frac{1}{M} \sum_{i=1}^M \mathbf{I}(N_{\text{pre},i} = N_{\text{GT},i}) \times 100\%$$

表 4-3 不同实例分割模型在检测与盘点任务中的准确率比较

Table 4-3 Comparison of detection and counting accuracy across instance segmentation models

Model	Fold1		Fold2		Fold3		Fold4		Fold5		Avg	
	DA	CA	DA	CA	DA	CA	DA	CA	DA	CA	DA	CA
QueryInst	92.30	92.30	81.53	81.53	78.34	76.58	85.63	85.63	78.53	77.91	83.27	82.79
SOLOv2	77.56	77.56	77.07	77.07	74.52	74.05	74.38	73.75	63.19	63.19	73.34	73.12
SparseInst	73.71	73.71	64.33	64.33	66.24	64.56	68.13	68.13	65.03	65.03	67.49	67.15
Mask2Former	97.44	96.79	95.54	94.90	96.18	95.97	93.75	93.13	89.57	88.34	94.50	93.83
YOLOv8s-Seg	96.15	96.15	95.54	94.90	98.08	95.56	95.63	93.13	87.73	86.50	94.62	93.25
YOLO11s-Seg	95.51	95.51	95.54	95.54	96.17	95.56	95.00	94.35	88.34	87.73	94.11	93.74
YOLO11-StackLite	98.17	97.43	95.54	95.54	96.81	96.20	98.10	95.00	90.79	90.18	95.88	94.87

其中, M 表示图像总数, $N_{\text{pre},i}$ 表示第 i 张图像的预测箱体数量, $N_{\text{GT},i}$ 表示第 i 张图像的真实箱体数量, $I(\cdot)$ 为指示函数。

与通用实例分割评价不同, 数量计算评估更关注模型输出能否被后处理算法有效利用。也就是说, 即便两个模型在 mAP 指标上接近, 若其中一个模型在顶层箱体识别、掩膜边界完整性或上下层区分方面更稳定, 则其在最终盘点环节仍可能表现更优。因此, 本节实验不仅用于比较最终数量预测结果, 也用于分析实例分割性能向数量推理性能传递的具体效果。

不同模型在五折交叉验证下的整体检测准确率与盘点准确率如表 4-3 所示。

由表 4-3 可见, YOLO11-StackLite 的平均 DA 为 95.88%, 平均 CA 为 94.87%, 均高于其余对比模型。与 YOLO11s-Seg 相比, 所提模型在平均 DA 和平均 CA 上分别提升 1.77 个百分点和 1.13 个百分点; 与 YOLOv8s-Seg 相比, 也表现出更优的整体盘点性能。这说明, 实例分割精度的提升能够有效传递到后续数量推理阶段, 从而提升最终盘点结果的正确性。

值得注意的是, DA 和 CA 的变化趋势虽然总体一致, 但二者并不完全等价。DA 更强调模型是否正确识别出上下层目标实例, 而 CA 则反映这些识别结果经过后处理推理后能否得到正确总数。因此, CA 对掩膜质量、结构关系判别以及异常样本处理过程更为敏感。YOLO11-StackLite 在两项指标上均取得较优结果, 说明其优势并非停留在单纯检测精度层面, 而是能够转化为更稳定的库存盘点能力。

为保证评估结果的全面性, 本文进一步对验证集样本按装载状态进行统计, 分为

表 4-4 不同装载状态图像在验证集各折中的数量分布

Table 4-4 Distribution of images with different loading states in each fold of the validation set

Fold1			Fold2			Fold3			Fold4			Fold5		
空	顶满	有效	空	顶满	有效	空	顶满	有效	空	顶满	有效	空	顶满	有效
39	87	30	38	88	31	39	88	31	40	88	32	41	90	32

表 4-5 各模型在验证集中“空货物图像”与“顶满图像”上的检测准确率对比

Table 4-5 Comparison of detection accuracy on empty-cargo and top-full images in the validation set

Model	Fold1		Fold2		Fold3		Fold4		Fold5	
	空	顶满	空	顶满	空	顶满	空	顶满	空	顶满
QueryInst	84.61	97.70	44.74	96.59	25.64	97.73	72.50	98.86	60.98	91.11
SOLOv2	41.02	97.70	26.32	96.59	25.64	97.73	37.50	98.86	14.63	88.89
SparseInst	43.59	97.70	7.89	96.59	5.13	97.73	22.50	98.86	31.71	90.00
Mask2Former	97.43	97.70	100.00	97.73	100.00	97.73	100.00	98.86	100.00	90.00
YOLOv8s-Seg	100.00	97.70	100.00	97.73	100.00	97.73	100.00	98.86	100.00	90.00
YOLO11s-Seg	100.00	97.70	100.00	97.73	100.00	97.73	100.00	98.86	100.00	92.22
YOLO11-StackLite	100.00	97.70	100.00	97.73	100.00	97.73	100.00	98.86	100.00	92.22

“空货物图像”“顶满图像”和“有效计数图像”三类。其中，“空货物图像”指未检测到任何实例的图像；“顶满图像”指缺乏完整顶层结构信息、无法进入完整数量推理流程的图像；“有效计数图像”指同时包含上层与下层结构信息、能够参与完整盘点的图像。各折验证集中三类样本的数量分布如表 4-4 所示。

由表 4-4 可见，五折验证集中三类样本分布较为均衡，其中顶满图像占比较高。这一分布特征有利于验证模型在不同装载状态下的稳定性，也为后续分状态性能分析提供了可靠的数据基础。

从任务角度看，这种分状态统计是必要的。若仅对全部样本进行整体平均，模型在某一类状态下的不足容易被其他样本掩盖，而库存盘点流程恰恰需要先区分“空货物”“顶满”和“有效计数”三种情形，再进入不同后处理路径。因此，将状态分布与后续状态判别准确率结合分析，能够更准确地反映模型在实际盘点流程中的适用性。

为评估各模型对不同装载状态的判别能力，本文进一步统计各模型在“空货物图像”和“顶满图像”上的检测准确率，结果如表 4-5 所示。

表 4-6 各模型在有效计数图像中的盘点准确率 (CA) 与检测准确率 (DA)

Table 4-6 Counting accuracy (CA) and detection accuracy (DA) of different models on effective counting images

Model	Fold1		Fold2		Fold3		Fold4		Fold5		Avg	
	CA	DA	CA	DA	CA	DA	CA	DA	CA	DA	CA	DA
QueryInst	86.67	86.67	83.87	83.87	80.65	87.10	65.63	65.63	62.50	65.63	75.86	77.78
SOLOv2	66.67	66.67	83.87	83.87	67.34	67.34	50.00	53.13	53.13	53.13	64.20	64.83
SparseInst	43.33	43.33	41.94	41.94	45.16	51.61	40.63	40.63	37.50	37.50	41.71	43.00
Mask2Former	90.00	93.33	80.65	83.87	83.87	83.87	68.75	71.88	68.75	75.00	78.40	81.59
YOLOv8s-Seg	86.67	86.67	80.65	83.87	83.87	93.55	68.75	81.25	59.34	65.63	75.86	82.19
YOLO11s-Seg	83.33	83.33	83.87	83.87	83.87	83.87	75.00	78.13	59.34	62.50	77.08	78.34
YOLO11-StackLite	86.67	93.33	83.87	83.87	87.10	87.10	75.00	78.13	71.88	75.00	80.90	83.49

从表 4-5 可以看出, YOLO 系列模型, 尤其是 YOLO11-StackLite, 在该类状态判别任务中表现更为稳定。所提模型在五折验证中的空货物识别准确率均达到 100%, 在顶满图像检测准确率上也保持在较高水平。这说明改进后的模型在装载状态判别阶段具有较强的鲁棒性, 有利于后续盘点流程中异常样本的筛除与流程分流。

这一结果对实际应用尤为重要。空货物图像识别准确率较高, 意味着系统能够快速过滤无效样本, 减少不必要的后处理计算; 顶满图像识别准确率较高, 则意味着模型能够更准确地进入适当的数量推理分支, 降低由错误状态判断带来的累计误差。从这一角度看, 状态判别能力实际上构成了盘点流程稳定性的第一道保障。

最后, 为进一步验证各模型在实际可盘点样本上的性能表现, 本文将验证集中空货物图像与顶满图像剔除, 仅保留能够参与完整数量推理的“有效计数图像”进行评估, 结果如表 4-6 所示。

由表 4-6 可见, 在仅保留有效计数图像的评估条件下, YOLO11-StackLite 在五折平均结果中仍取得最高的盘点准确率与检测准确率, 平均 CA 为 80.90%, 平均 DA 为 83.49%。这表明, 所提模型在复杂堆叠结构场景中能够提供更稳定的实例识别结果, 并有效支撑后续数量推理过程。

综合表 4-3、表 4-5 和表 4-6 的结果可以看出, YOLO11-StackLite 的优势不仅体现在检测与分割精度上, 还体现在装载状态判别和最终盘点结果上。实验结果表明, 本文提出的模型与后处理方法能够较好地适应立体仓库中的复杂堆叠场景, 具有较强的

表 4-7 压缩前后模型复杂度与性能比较（待实验验证）

Table 4-7 Comparison of model complexity and performance before and after compression (to be verified)

Model	Params/M	GFLOPs	box mAP/%	mask mAP/%	DA/%	CA/%
YOLO11s-Seg	10.1	35.5	84.8	84.0	94.11	93.74
YOLO11-StackLite	9.4	34.9	85.7	84.7	95.88	94.87
Pruned-YOLO11-StackLite	7.8	29.1	84.6	83.5	94.32	93.10
Pruned-Distilled-YOLO11-StackLite	7.8	29.1	85.2	84.1	95.10	94.02

工程应用潜力。

综合来看，本节实验验证了“实例分割改进 - 状态判别优化 - 数量推理提升”之间的传递关系。即第 2 章中针对注意力建模、下采样结构和方向性特征表达的改进，不仅提升了 box mAP 和 mask mAP，也通过更稳定的目标轮廓和类别判定，为后处理算法提供了更可靠的输入，最终体现在盘点准确率的提升上。这一结果说明，本文方法具有较完整的任务闭环，而非仅在单一视觉指标上取得局部改进。

4.4.4 模型压缩实验

为验证第 3 章所提模型压缩方法的有效性，本文进一步对 YOLO11-StackLite 在压缩前后的模型复杂度与任务性能进行比较。考虑到本文当前尚未在实际边缘硬件平台上完成部署测试，因此本节主要从参数量、浮点运算量、检测与分割精度以及盘点相关指标等方面，对压缩模型的部署友好性进行间接评估。为便于展示压缩实验的评价维度与结果组织方式，并为后续正式实验替换预留位置，本节结果暂以待实验验证的占位数据形式给出。

本节比较的模型包括基线 YOLO11s-Seg、第 2 章提出的 YOLO11-StackLite、仅经过结构化剪枝得到的 Pruned-YOLO11-StackLite，以及在剪枝基础上进一步结合知识蒸馏训练得到的 Pruned-Distilled-YOLO11-StackLite。对比结果如表 4-7 所示。

对于本文任务而言，模型压缩实验不能仅以 mAP 作为单一评价标准。原因在于，库存盘点任务最终依赖的是模型输出能否稳定支撑后处理数量推理，因此压缩后模型即便在检测精度上只出现小幅下降，也可能在 DA 和 CA 上产生更明显影响。基于这一考虑，本文在压缩实验中同时考察 Params、GFLOPs、box mAP、mask mAP、DA 和 CA，以从模型复杂度和任务性能两个层面共同评估压缩方案的可行性。

表 4-8 不同剪枝率下模型性能变化（待实验验证）

Table 4-8 Performance variation under different pruning ratios (to be verified)

Pruning Ratio/%	Params/M	GFLOPs	box mAP/%	mask mAP/%	DA/%	CA/%
10	8.9	32.8	85.4	84.4	95.63	94.55
20	8.4	31.0	85.0	83.9	95.27	94.18
30	7.8	29.1	84.6	83.5	94.32	93.10
40	7.1	27.3	83.8	82.6	93.41	92.02

由表 4-7 可见，在引入结构化剪枝后，YOLO11-StackLite 的参数量由 9.4 M 降至 7.8 M，GFLOPs 由 34.9 降至 29.1，说明剪枝策略能够有效降低模型复杂度，提升模型面向资源受限场景的部署友好性。然而，剪枝后的模型在 box mAP、mask mAP、DA 和 CA 等指标上均出现一定程度下降，这表明结构裁剪可能对模型特征表达能力产生一定影响。

在此基础上进一步引入知识蒸馏后，压缩模型在保持相同参数量和计算复杂度的前提下，box mAP、mask mAP、DA 和 CA 均得到不同程度恢复。与仅剪枝模型相比，Pruned-Distilled-YOLO11-StackLite 在检测、分割与盘点指标上均有提升，初步说明知识蒸馏有助于缓解结构化剪枝带来的性能退化问题，从而提升压缩模型在复杂堆叠货物场景中的应用稳定性。

从方法机理上看，这一现象是合理的。结构化剪枝通过直接移除低重要性通道降低模型复杂度，但与此同时也会削弱部分中间特征表达能力，尤其是在复杂遮挡和轮廓细节恢复方面更容易出现性能波动。知识蒸馏则通过教师模型向学生模型传递更稳定的判别信息，使剪枝模型能够在较小结构规模下尽可能保留原模型的表示能力。因此，剪枝与蒸馏的组合更适合作为本文任务的压缩路线，而不是单独依赖某一种方法。

为进一步分析不同剪枝率下模型复杂度与任务性能之间的变化规律，本文对 YOLO11-StackLite 在不同剪枝率设置下进行了对比分析，结果如表 4-8 所示。

结合表 4-8 可以看出，随着剪枝率的提高，模型参数量与浮点运算量持续下降，但检测、分割与盘点性能也呈现逐步下降趋势。当剪枝率较低时，模型复杂度下降幅度有限；当剪枝率过高时，模型性能退化较为明显。综合考虑模型复杂度与任务性能之间的平衡关系，30% 剪枝率可作为后续正式实验中重点验证的候选折中设置。从当前

结果组织方式和指标变化趋势来看，第3章提出的“结构化剪枝+知识蒸馏”压缩路线具备在尽量控制性能下降幅度的前提下降低模型复杂度的潜力，并为后续面向边缘部署需求的进一步验证提供了实验基础。

需要进一步说明的是，本文当前尚未在真实边缘硬件平台上完成部署测试，因此本节结果主要用于验证压缩路线在模型层面和任务层面的可行性，而不直接推导具体设备上的推理时延结论。尽管如此，Params 和 GFLOPs 的下降仍能够反映模型在部署成本方面的改善趋势，而 DA 和 CA 的保持情况则能够说明压缩后模型是否仍具备库存盘点应用价值。后续若结合实际边缘设备开展部署验证，可在此基础上进一步补充端侧时延、显存占用和吞吐性能等指标。

4.5 本章小结

本章首先介绍了 TBD 数据集的构建方式、评价指标以及实验环境与训练参数设置，并在统一实验条件下对所提方法进行了系统验证。在消融实验中，C2SASA、SSConv 和 C3K2-QDConv 模块均表现出明确的独立贡献，三者联合后进一步提升了模型在精度与复杂度之间的综合表现；在模型对比实验中，YOLO11-StackLite 相较多种主流实例分割模型取得了更优的精度与效率平衡；在数量计算评估中，所提模型在检测准确率、盘点准确率以及不同装载状态下的判别能力方面均表现出较强稳定性，说明改进后的实例分割结果能够有效支撑后处理数量推理过程；在模型压缩实验中，结构化剪枝与知识蒸馏相结合的压缩路线进一步显示出降低模型复杂度并尽量保持任务性能的潜力。综合上述实验结果，可以认为本文提出的方法在复杂堆叠货物场景下具有较好的有效性、稳定性和应用价值。

第五章 结论与展望

研究结论

针对立体仓库堆叠货物盘点任务中存在的目标遮挡严重、结构关系复杂、数量推断困难以及模型部署资源受限等问题,本文围绕复杂场景下的高精度盘点与面向边缘部署需求的模型轻量化两条主线开展研究。以实例分割为基础,结合后处理数量计算方法与模型压缩策略,构建了适用于立体仓库堆叠货物盘点任务的完整技术路线。全文的主要研究结论如下。

- (1) 针对复杂堆叠场景下现有实例分割模型易出现漏检、误检以及结构建模能力不足的问题,本文以 YOLO11s-Seg 为基线,提出改进模型 YOLO11-StackLite。该模型通过引入通道拆分注意力模块 C2SASA、重排分组卷积模块 SSConv 以及具有四向卷积结构的 C3k2_QDConv 模块,从注意力建模、下采样效率和方向性空间表达三个方面对网络结构进行了优化。实验结果表明,改进后的模型在检测精度、分割精度以及模型复杂度控制方面均取得了较好的综合表现,说明所提结构改进能够有效提升模型对立体仓库复杂堆叠场景的适应能力。
- (2) 针对仅依赖检测结果难以准确完成货物总数量推断的问题,本文结合实例分割掩膜信息与仓储场景中的堆叠规则,设计了后处理数量计算方法。该方法通过顶层满载检测算法和基于掩膜关键点的层间面积比估计算法,对堆叠货物的层次结构进行判别与推理,从而实现对货物总数量的估算。相关实验结果表明,所提出的后处理方法能够较好地利用实例分割结果中的轮廓与几何信息,提高库存盘点任务的可解释性与准确性。
- (3) 针对高精度实例分割模型在边缘侧应用中存在参数量较大、计算复杂度较高的问题,本文进一步研究了面向边缘部署需求的模型压缩方法。以 YOLO11-StackLite 为基础,采用结构化剪枝降低模型参数量与浮点运算量,并结合知识蒸馏缓解压缩带来的性能退化。实验分析表明,该压缩路线在降低模型复杂度方面具有较好潜力,并能够在一定程度上保持检测、分割与盘点相关性能,为后续面向实际资源受限场景的应用提供了方法基础。

综上,本文围绕立体仓库堆叠货物盘点任务,构建了“改进实例分割模型 - 后处理数量计算方法 - 模型压缩”的完整研究框架。相关研究结果验证了本文方法在复杂堆

叠场景下的有效性，为立体仓库库存盘点的自动化与智能化提供了可行的技术方案。

未来研究展望

尽管本文围绕立体仓库堆叠货物盘点任务开展了较为系统的研究，并取得了一定成果，但仍存在进一步完善和拓展的空间，主要体现在以下几个方面。

- (1) 在数据集构建方面，本文采用的 TBD 数据集来源于真实仓储场景，能够较好支撑当前研究，但在样本规模、场景多样性以及极端遮挡情形方面仍有进一步扩展空间。后续可进一步采集更多不同仓储条件、不同光照环境以及不同堆叠方式下的数据，以增强模型的泛化能力和鲁棒性。
- (2) 在数量计算方法方面，本文所提出的后处理算法主要基于实例分割掩膜与几何先验进行结构推理。对于更复杂的不规则堆叠、严重遮挡或局部缺失场景，现有方法仍可能受到一定影响。后续可考虑引入更强的结构约束、三维几何信息或多视角信息，以进一步提升数量推断的稳定性与准确性。
- (3) 在模型压缩与部署验证方面，本文已从参数量、浮点运算量以及相关任务指标等角度对压缩方法进行了分析，但尚未在实际边缘硬件平台上完成系统化部署测试。后续可结合具体边缘设备，对压缩模型的推理时延、资源占用与运行稳定性进行进一步验证，从而更全面地评估模型在实际仓储场景中的应用效果。
- (4) 在方法拓展方面，本文当前主要依赖单帧图像进行检测、分割与数量估计。未来可进一步结合视频时序信息、多模态感知信息或仓储管理系统中的先验业务信息，构建更加稳定和智能的库存盘点方法，以满足更复杂场景下的实际应用需求。

参考文献

- [1] JIE A L K, SWEE S K, LIANG L K. Review on Automated Storage and Retrieval System for Warehouse[J/OL]. Journal of Informatics and Web Engineering, 2024, 3(3): 77-97. DOI: [10.33093/jiwe.2024.3.3.5](https://doi.org/10.33093/jiwe.2024.3.3.5).
- [2] WANG H, CHEN S, XIE Y. An RFID-Based Digital Warehouse Management System in the Tobacco Industry: A Case Study[J/OL]. International Journal of Production Research, 2010, 48(9): 2513-2548. DOI: [10.1080/00207540903564918](https://doi.org/10.1080/00207540903564918).
- [3] LIU M, FENG Y H, ZHONG G L, et al. The Design of Cigarette WMS Based on RFID [C/OL]//Advanced Materials Research: vol. 712–715. 2013: 2991-2994. DOI: [10.4028/www.scientific.net/AMR.712-715.2991](https://doi.org/10.4028/www.scientific.net/AMR.712-715.2991).
- [4] VIS I F A. Survey of Research in the Design and Control of Automated Guided Vehicle Systems[J/OL]. European Journal of Operational Research, 2006, 170(3): 677-709. DOI: [10.1016/j.ejor.2004.09.020](https://doi.org/10.1016/j.ejor.2004.09.020).
- [5] XU L, KAMAT V R, MENASSA C C. Automatic Extraction of 1D Barcodes from Video Scans for Drone-Assisted Inventory Management in Warehousing Applications [J/OL]. International Journal of Logistics Research and Applications, 2018, 21(3): 243-258. DOI: [10.1080/13675567.2017.1393505](https://doi.org/10.1080/13675567.2017.1393505).
- [6] RADÁCSI L, GUBÁN M, SZABÓ L, et al. A Path Planning Model for Stock Inventory Using a Drone[J/OL]. Mathematics, 2022, 10(16): 2899. DOI: [10.3390/math10162899](https://doi.org/10.3390/math10162899).
- [7] ZHAO J, LI B, WEI X, et al. Recognition and Location Algorithm for Pallets in Warehouses Using RGB-D Sensor[J/OL]. Applied Sciences, 2022, 12(20): 10331. DOI: [10.3390/app122010331](https://doi.org/10.3390/app122010331).
- [8] CARION N, MASSA F, SYNNAEVE G, et al. End-to-End Object Detection with Transformers[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2020: 213-229.
- [9] ZHU X, SU W, LU L, et al. Deformable DETR: Deformable Transformers for End-to-End Object Detection[C/OL]//International Conference on Learning Representations (ICLR). 2021. <https://arxiv.org/abs/2010.04159>.

-
- [10] LIU S, LI F, ZHANG H, et al. DAB-DETR: Dynamic Anchor Boxes Are Better Queries for DETR[C/OL]//International Conference on Learning Representations (ICLR). 2022. <https://arxiv.org/abs/2201.12329>.
- [11] ZHANG H, LI F, LIU S, et al. DINO: DETR with Improved DeNoising Anchor Boxes for End-to-End Object Detection[J/OL]. CoRR, 2022, abs/2203.03605. <https://arxiv.org/abs/2203.03605>.
- [12] HE K, GKIOXARI G, DOLLÁR P, et al. Mask R-CNN[C]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). 2017: 2961-2969.
- [13] BOLYA D, ZHOU C, XIAO F, et al. YOLACT: Real-Time Instance Segmentation[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 9157-9166.
- [14] WANG X, KONG T, SHEN C, et al. SOLO: Segmenting Objects by Locations[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2020: 649-665.
- [15] WANG X, ZHANG R, KONG T, et al. SOLOv2: Dynamic and Fast Instance Segmentation[C]//Advances in Neural Information Processing Systems: vol. 33. 2020: 17721-17732.
- [16] FANG Y, PENG B, ZHANG W, et al. Instances as Queries[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 6910-6919.
- [17] CHENG T, WANG X, CHEN S, et al. Sparse Instance Activation for Real-Time Instance Segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 4433-4442.
- [18] CHENG B, MISRA I, SCHWING A G, et al. Masked-Attention Mask Transformer for Universal Image Segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 1290-1299.
- [19] Ultralytics. YOLO11[EB/OL]. 2025 [2026-03-18]. <https://docs.ultralytics.com/models/yolo11/>.
- [20] CHATTOPADHYAY P, GIRSHICK R, RAMANATHAN V, et al. Counting Everyday Objects in Everyday Scenes[C]//Proceedings of the IEEE Conference on Computer Vi-

- sion and Pattern Recognition (CVPR). 2017: 1135-1144.
- [21] LEMPITSKY V, ZISSERMAN A. Learning to Count Objects in Images[C]//Advances in Neural Information Processing Systems: vol. 23. 2010.
- [22] ZHANG C, LI H, WANG X, et al. Cross-Scene Crowd Counting via Deep Convolutional Neural Networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2015: 833-841.
- [23] COHEN J P, LO H Z, BENGIO Y, et al. Count-ception: Counting by Fully Convolutional Redundant Counting[J/OL]. CoRR, 2017, abs/1703.08710. <https://arxiv.org/abs/1703.08710>.
- [24] HAN S, MAO H, DALLY W J. Deep Compression: Compressing Deep Neural Networks with Pruning, Trained Quantization and Huffman Coding[J/OL]. International Conference on Learning Representations (ICLR), 2016. <https://arxiv.org/abs/1510.00149>.
- [25] HINTON G, VINYALS O, DEAN J. Distilling the Knowledge in a Neural Network [J/OL]. CoRR, 2015, abs/1503.02531. <https://arxiv.org/abs/1503.02531>.
- [26] HAN S, POOL J, TRAN J, et al. Learning both Weights and Connections for Efficient Neural Networks[C]//Advances in Neural Information Processing Systems: vol. 28. 2015.
- [27] LUO J, WU J, LIN W. ThiNet: A Filter Level Pruning Method for Deep Neural Network Compression[C]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). 2017: 5058-5066.
- [28] HE Y, ZHANG X, SUN J. Channel Pruning for Accelerating Very Deep Neural Networks[C]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). 2017: 1389-1397.
- [29] VASWANI A, SHAZEER N, PARMAR N, et al. Attention Is All You Need[C]//Advances in Neural Information Processing Systems: vol. 30. 2017.
- [30] SHI W, CABALLERO J, HUSZÁR F, et al. Real-Time Single Image and Video Super-Resolution Using an Efficient Sub-Pixel Convolutional Neural Network[C]//

- Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 1874-1883.
- [31] ZHANG X, ZHOU X, LIN M, et al. ShuffleNet: An Extremely Efficient Convolutional Neural Network for Mobile Devices[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 6848-6856.

攻读学位期间取得与学位论文相关的成果

发表和投稿与学位论文相关学术论文

- [1] 张三, 李四, 王五, 等. Jet electrochemical machining of micro dimples with conductive mask. Journal of Materials Processing Technology. 2018, 257:101-111. (SCI Impact Factor 3.647, WOS:000431161400010)
- [2] 李四, 张三, 王五, 等. Electrochemical direct-writing machining of micro- channel array. Journal of Materials Processing Technology. 2019, 265:138-149. (SCI Impact Factor 3.647, WOS:000451935100014)

申请发明专利

- [1] 李四, 张三, 王五. 一种微流道电解加工装置. 发明专利申请号: 201810467763.5.

致谢